Introduction à la compilation

Nicolas Bedon

Cours de L3 Université de Rouen

https://dpt-info-sciences.univ-rouen.fr/~bedonnic/ puis Enseignement/Compilation

Références

- Compilateurs: techniques, principes & outils A. Aho, M. Lam, R. Sethi et J. Ullman
- Flex & Bison : text processing tools
 J. Levine
- Manuels de Flex et Bison
- Cours de C
- Cours de théorie des langages
- Des notions de programmation fonctionnelle et de programmation objet sont bienvenues

Modalités

- 20h CM, 12h TD, 18h TP
- Contrôle :
 - Examen terminal E₁
 - Un partiel Pa et un projet Pr
 - Le projet est obligatoire : il compte pour un tiers de la note finale. Sa note Pr est définitive.
 - Note de session 1 = 2/3*Ecrit + Pr/3
 - écrit = $(E_1+Pa)/2$
 - Examen terminal E₂ de seconde session
 - Note de session 2 : $2/3 E_2 + Pr/3$
 - Les notes E₁ et Pa ne sont plus prises en compte
 - La note Pr de projet reste (elle ne se rattrape pas!)

Sur la nécessité de traduire

```
.rodata
.section
 .LC0:
      .string "Bonjour!"
     .text
 .globl main
     .type main, @function
 main:
 .LFB2:
     pushq %rbp
 .LCFi0:
     movq %rsp, %rbp
 .LCFI1:
            $16, %rsp
     subq
 .LCFI2:
            %edi, -4(%rbp)
     movl
     movq %rsi, -16(%rbp)
            $.LCÓ, %èdi
     movl
            $0, %eax
     movl
     call printf
            $0, %eax
     movl
     leave
     ret
```

- Proche du langage du processeur
- Impossible pour un être humain non informaticien
- Difficile même pour un informaticien

Principes élémentaires:

- registres
- adresses
- routines

Sur la nécessité de traduire

```
.section
            .rodata
 .LC0:
      .string "Bonjour!"
                                            int main(int argc, char *argv[]) {
      .text
                                              printf(« Bonjour ! »);
 .globl main
                                              return EXIT SUCCÉSS;
      .type main, @function
 main:
 .LFB2:
      pushq %rbp
 .LCFIO:
      movq %rsp, %rbp
                                            Notions élémentaires (C):
 .LCFI1:
                                            types
      subq $16, %rsp

    variables

 J CFI2:

    fonctions

      movl %edi, -4(%rbp)

    structures de contrôles évoluées

      movq %rsi, -16(%rbp)
      movl $.LC0, %edi
                                            Mais aussi (C++, Java)
            $0, %eax
      movl

    classes

      call printf
                                            objets
            $0, %eax
      movl

    méthodes

      leave
                                            Ou encore (ML)
      ret

    pattern-matching

                                            Ou encore (Prolog)


    résolution de contraintes
```

De la nécessité de traduire

Intérêt des langages de haut niveau:

- meilleure facilité d'expression
- séparation des concepts
 - · un concept -> un cadre d'utilisation
 - · un cadre d'utilisation -> un moyen formel de contrôler les erreurs
 - · plus de contrôles = moins d'erreurs
- meilleure lisibilité
 - · développement en équipe facilité
 - · maintenance facilitée

De la nécessité de traduire



Programmation et traductions en chaîne

Langage de haut niveau (ex: AspectJ = Java + aspects)

Traduction

Langage de niveau intermédiaire (ex: Java)

Traduction


Langage de bas niveau (ex: byte-code Java)

Traduction

Langage de la machine (processeur) destination

Catégories de traducteurs en programmation: compilateur

Compilateur




- > Analyse de l'entrée
- Représentation intermédiaire
- Génération sortie
- Exécution déléguée au processeur physique

Exemples:

- gcc
- javac
- as

Catégories de traducteurs en programmation: interprète

Interprète



- > Analyse de l'entrée
- > Représentation intermédiaire
- Le moteur simule l'action des instructions dans une implantation d'un modèle de calcul


Exemples:

- lisp
- MĹ
- java

Du code source au code exécutable

"squelette" de programme source code machine absolu chargeur préprocesseur bibliothèque éditeur de liens programme source pré-traité code relogeable assembleur compilateur programme cible en langage d'assemblage

Liens avec l'éditeur et le débogueur



```
#include <stdio.h>
#include <stdib.h>

int main(void) {
   printf("Hello world !\n");
   return EXIT_SUCCESS;
}
```


Les #include sont remplacés par le contenu des fichiers
Les macros sont remplacées par leur valeur
Des informations sont ajoutées pour permettre au compilateur d'avoir des messages d'erreurs significatifs

```
#1 "hello.c"
# 1 "<built-in>"
# 1 "<command-line>"
# 1 "/usr/include/stdio.h" 1 3 4
# 1 "/usr/include/features.h" 1 3 4
# 374 "/usr/include/features.h" 3 4
# 1 "/usr/include/x86_64-linux-gnu/sys/cdefs.h" 1 3 4
typedef unsigned char <u>u</u>char;
extern int printf (const char *__restrict __format, ...);
# 3 "hello.c" 2
int main(void) {
 printf("Hello world !\n");
 return 0:
```

gcc -fpreprocessed hello.i -S

(produit un fichier texte : hello.s)

```
"hello.c"
.file
.section
             .rodata
.LC0:
.string "Hello world!"
.text
.globl main
.type main, @function
main:
.LFB2:
.cfi startproc
pushq %rbp
.cfi def cfa offset 16
.cfi offset 6, -16
movq %rsp, %rbp
.cfi def cfa register 6
movl $.LC0, %edi
call puts
movl $0, %eax
popq %rbp
.cfi def cfa 7, 8
.cfi endproc
.LFE2:
.size main, .-main
.ident "GCC: (Debian 4.9.2-10) 4.9.2"
             .note.GNU-stack, "", @progbits
.section
```



- Produit un fichier binaire (chaque instruction assembleur a été traduite en son code opératoire)
- Les noms symboliques (variables, routines) des objets définis dans l'unité de compilation ont des adresses relatives
- Les autres pas encore

Id -m elf_x86_64 -dynamic-linker /lib64/ld-linux-x86-64.so.2 | l'édition / lib/gcc/x86_64-linux-gnu/4.9/../../x86_64-linux-gnu/crti.o / lib/gcc/x86_64-linux-gnu/4.9/../../x86_64-linux-gnu/crti.o / lib/gcc/x86_64-linux-gnu/4.9/crtbegin.o / lib/gcc/x86_64-linux-gnu/4.9/crtend.o / lib/gcc/x86_64-linux-gnu/4.9/crtend.o / lib/gcc/x86_64-linux-gnu/4.9/../../x86_64-linux-gnu/crtn.o | lib/gcc/x86_64-linux-gnu/4.9/../../x86_64-linux-gnu/crtn.o | l'édition / lib/gcc/x86_64-linux-gnu/crti.o | l'édition / l'édi

Code de réalisation de l'édition de lien dynamique

Code d'initialisation du processus, de la libc, de préparation de argc et argv, et d'appel à main(argv, argv)

Utilise la bibliothèque C (libc)

Code de terminaison de la libc et du processus


- Ajoute le code nécessaire à l'exécution du processus
- > Résout les liens entre les différents fichiers objets
- Spécifie comment doivent être résolus les autres liens (ici, chargement dynamique)
- Recalcule les adresses en prévision de la création du processus
- Créé l'exécutable a.out

nm a.out

```
00000000000600890 B bss start
00000000000600890 b completed.6661
0000000000000880 D data start
0000000000600880 W data start
0000000004003f0 t deregister tm clones
0000000000400470 t do global dtors aux
0000000000600668 t do global dtors aux fini array entry
0000000000600888 D dso handle
0000000000600678 d DYNAMIC
00000000000600890 D edata
00000000000600898 B end
0000000000400544 T fini
0000000000400490 t frame dummy
0000000000600660 t frame dummy init array entry
0000000000400658 r FRAME END
0000000000600850 d GLOBAL OFFSET TABLE
                w gmon start
```

```
0000000000400358 T init
0000000000600668 t init array end
                    init array start
0000000000600660 t
0000000000400550 R IO stdin used
                 w ITM deregisterTMCloneTable
                 w ITM registerTMCloneTable
00000000000600670 d JCR END
0000000000600670 d JCR LIST
                 w Jv RegisterClasses
0000000000400540 T libc csu fini
00000000004004d0 T libc csu init
                 U libc start main@@GLIBC 2.2.5
00000000004004b6 T main
                 U puts@@GLIBC 2.2.5
0000000000400430 t register tm clones
00000000004003c0 T start
0000000000600890 D TMC END
```

Structure interne d'un compilateur



Analyse lexicale


Analyse du programme source en constituants minimaux, les **lexèmes** On passe de

```
position = initial + vitesse * 60
à
[id, 1] [=] [id, 2] [+] [id, 3] [*] [60]
```

Les identificateurs rencontrés sont placés dans la table des symboles Les blancs et les commentaires sont éliminés

Analyse syntaxique


On reconstruit la structure syntaxique de la suite de lexèmes fournie par l'analyseur lexical



Représentation intermédiaire

```
int f(int x) {
    int y=x/2;
    if (y==0)
        return 1;
    else
        return 12/y;
}
```

Table des symboles f:entier->entier:infos f.x:entier:infos f.y:entier:infos



Génération de code intermédiaire

Programme pour une machine abstraite

Représentations utilisées

- Code à trois adresses

```
temp1 := inttoreal(60)
temp2 := id3 * temp1
temp3 := id2 + temp2
id1 := temp3
```

- Arbres syntaxiques

Optimisation de code

Élimination des opérations inutiles pour produire du code plus efficace.

id1 := temp3

La constante est traduite en réel flottant à la compilation, et non à l'exécution

La variable temp3 est éliminée

Génération de code cible

La dernière phase produit du code en langage d'assemblage Un point important est l'utilisation des registres

temp1 := id3 * 60.0 MOVF id3, R2

id1 := id2 + temp1 MULF #60.0, R2

MOVF id2,R1


ADDF R2, R1

MOVF R1, id1

F = flottant.

La première instruction transfère le contenu de id3 dans le registre R2 La seconde multiplie le contenu du registre R2 par la constante 60.0

Vue d'ensemble



Outils

Outils d'aide à la construction de compilateurs

Générateurs d'analyseurs lexicaux

Engendrent un analyseur lexical (*scanner*, *lexer*) sous forme d'automate fini à partir d'une spécification sous forme d'expressions rationnelles

Flex, Lex (C)

Générateurs d'analyseurs syntaxiques

Engendrent un analyseur syntaxique (*parser*) à partir d'une grammaire Bison, Yacc (C)

Générateurs de traducteurs

Engendrent un traducteur à partir d'un schéma de traduction (grammaire + règles sémantiques) Bison, Yacc (C)

TP

- Processeur simplifié (virtuel) : SImple PROcessor (SIPRO), outil « maison »
- Assembleur pour SIPRO : ASIPRO, outil « maison »

Analyse lexicale

Rôles


- Filtre permettant de « nettoyer » le code source des informations inutiles aux autres phases de compilation
 - suppression des commentaires
 - suppression de l'espacement (espaces, tabulations, retours à la ligne)
- > Première analyse :
 - découpage du flot d'entrée en lexèmes

Lexème (unité lexicale, token) = groupe de caractères consécutifs

Les lexèmes ont des *catégories* et des *attributs* Exemples de catégories : mots clefs, constante entière, constante réelle, chaîne de caractères Les attributs sont souvent (mais pas obligatoirement) la valeur


Flot de caractères -> flot de lexèmes

```
if ( nom != (void *)0 ) { // Nom défini
        printf(« Bonjour %s!\n », nom) ;
} else { // Nom indéfini
        fprintf(stderr, « nom indéfini!\n ») ;
}
```



Flot de caractères -> flot de lexèmes

```
if ( nom != (void *)0 ) { // Nom défini
        printf(« Bonjour %s!\n », nom) ;
} else { // Nom indéfini
        fprintf(stderr, « nom indéfini!\n ») ;
}
```



Comment choisir les catégories ?

- L'analyseur lexical transforme un flot de caractères en un flot de lexèmes
- Le flot de lexème est ensuite transmis à l'analyseur syntaxique
 - La catégorie des lexèmes sert de base à l'analyse syntaxique
 - Les attributs ne sont (typiquement) pas utilisés avant l'analyse sémantique
- Le choix des catégories n'est pas unique mais, par exemple,
 - la virgule est en C à la fois un séparateur d'arguments/paramètres et un opérateur
 - l'étoile est en C à la fois un constructeur de type et un opérateur
 - les parenthèses sont à la fois des éléments de construction des expressions, des éléments de syntaxe encadrant les conditions, et des opérateurs
- Comment choisir leur catégorie ?
- > Ça sera à l'analyseur syntaxique de décider, en fonction du contexte (de la virgule, de l'étoile, ...)
- L'analyseur lexical doit juste transmettre la virgule (ou l'étoile, etc) à l'analyseur syntaxique, qui décidera de son interprétation (séparateur, opérateur, etc)
 - > la virgule forme donc, à elle seule, sa propre catégorie (idem pour l'étoile, les parenthèses)

Comment choisir les catégories ?

Pour les langages de programmation, les catégories les plus courantes sont :

- une catégorie pour chaque mot-clef
- une catégorie pour chaque type numérique
 - entiers
 - réels
- une catégorie pour les caractères
- une catégorie pour les booléens
- une catégorie pour les chaînes de caractères
- une catégorie pour chaque symbole de ponctuation
- une catégorie pour les identificateurs
 - > fonctions
 - variables
 - paramètres
 - types
 - > ...

Flex et Bison

Années 70 : Lex & Yacc

Lex : Lexical analyser (analyseur lexical)

Yacc : Yet Another Compiler Compiler (analyseur syntaxique)

Lex et Yacc sont conçus pour fonctionner en binôme

Outils d'écriture de compilateurs en C Outils propriétaires (laboratoires Bell)

Années 90 : Flex et Bison

Flex (Fast Lex): version libre de Lex

Bison (jeu de mot sur Yacc) : version libre de Yacc

- Adaptations en C++, ocaml, etc
- Il existe aussi de nombreux autres outils pour écrire des compilateurs
- Ces deux là sont des standards largement répandus
- Utilisés pour analyser Ruby, Php, Go, Bash, Lilypond, PostgreSQL, GNU Octave, Perl 5
- > Ont été utilisés pour GCC, mais GCC utilise maintenant une descente récursive manuelle

Flex

Principe:

- Analyse l'entrée standard
- Génère un flot texte (le flot de lexèmes) sur la sortie standard
- Les catégories sont définies par des expressions rationnelles
- > A chaque catégorie est associée du code C à exécuter quand elle est reconnue

Détails de fonctionnement :

- La configuration de flex est décrite dans un fichier texte (extensions .l ou .lex)
- Flex traduit les expressions rationnelles en automates
- Le code C associé à chaque catégorie est associé aux états finaux de l'automate de la catégorie
- Les automates, et le programme qui les fait fonctionner sur l'entrée standard, sont générés dans un fichier C (typiquement yy.lex.c)
- lex.yy.c peut être lié à la bibliothèque C Flex (-Ifl) pour former un programme

mon_analyseur.l

flex -D_POSIX_SOURCE -DYY_NO_INPUT --nounput

lex.yy.c

lex.yy.c — ▶

gcc -std=c11 -pedantic -Wall -Ifl

Flex: un premier exemple (simpliste)

```
cat ex1.txt
if ( nom != (void *)0 ) { // Nom défini
     printf(« Bonjour %s!\n », nom) ;
} else { // Nom indéfini
     fprintf(stderr, « nom indéfini!\n ») ;
cat ex1.l
%%
              printf("IF");
              printf("THEN");
then
              printf("ELSE");
else
              printf("VOID");
void
\"[^"]*\"
              printf("CHAINE");
[a-zA-Z]+
[0-9]+
            printf("ID");
              printf("INT");
              printf("NEQ");
              /* Ne rien faire */
%%
```

```
flex -D_POSIX_SOURCE --nounput
     -DYY_NO_INPUT ex1.l
gcc -std=c11 -pedantic -Wall lex.yy.c -lfl
./a.out <ex1.txt
IF ( ID NEQ (VOID *)INT ) {
     ID(CHAINE, ID) ;
} ELSE {
     ID(ID, CHAINE) ;
}</pre>
```

Format d'un fichier flex

```
%{
    Code C
%}
Définitions flex

%%
regexp<sub>1</sub> code<sub>1</sub>
...
regexp<sub>n</sub> code<sub>n</sub>
%%

Code C
```

Exemple

```
%{
#include <stdlib.h>
static size t keyword count = 0;
static size t string count = 0;
static size t id count = 0;
static size_t int_count = 0;
static size t op count = 0;
static size_t type_count = 0;
static size_t comment_count = 0;
static size t other count = 0;
static void print_count(void);
%}
NUMBER [[:digit:]]+
ID [a-zA-Z]+[[:digit:]a-zA-Z]*
STRING \"[^"]*\"
%%
```

```
if
              ++keyword count;
then
              ++keyword count;
else
         ++keyword count;
void
         ++type count;
{STRING}
              ++string count;
\{ID\}
              ++id count;
{NÚMBER}
              ++int count;
              ++op count;
₩.*
              ++comment count;
              ++other count;
.|\n
<<EOF>>
            { print count(); return 0; }
%%
static void print count(void) {
printf( "#keyword=%zu\n" "#string=%zu\n" "#id=%zu\n"
 "#int=%zu\n" "#op=%zu\n" "#type=%zu\n"
 "#comment=%zu\n" "#other=%zu\n",
 keyword count, string count, id count, int count,
 op count, type count, comment count, other count);
```

Ou bien...

```
<même section que précédemment>
%%
             ++keyword count;
             ++keyword count;
then
             ++keyword_count;
else
void
             ++type count;
{STRING}
             ++string_count;
{ID}
             ++id count;
{NÚMBER}
             ++int count;
             ++op count;
\\\.*
             ++comment count;
.|\n
             ++other count;
<<EOF>> { print_count(); return 0; }
%%
<même fonction print_count() que précédemment>
int main(int argc, char *argv[]) {
 yylex();
 print_count();
 return EXIT_SUCCESS;
```

Format des expressions rationnelles de flex

Essentiellement, mais pas exactement, les expressions rationnelles étendues POSIX

```
caractères « standards »
> . : tout sauf la fin de ligne
> \n : la fin de ligne
> [caractères] : classe de caractères. Les caractères entre [] sont en général despécialisés
       [abc] : {a,b,c}
       [a-zA-Z] : les caractères des alphabets minuscules et majuscules.
             Les intervalles sont définis en utilisant le code machine des caractères (ex : code ASCII)
       [^caractères] : classe de caractères définie par négation
       [a-z]{-}[mn] : classe de caractères définie par différence ensembliste
^ : début de ligne
> $: fin de liane
* : s'applique à un ensemble, pour le répéter un nombre quelconque de fois (y compris 0 fois)
> + : s'applique à un ensemble, pour le répéter un nombre quelconque de fois (au moins une fois)
> {nombre} : s'applique à un ensemble, pour le répéter nombre fois
{nombre1.nombre2} : s'applique à un ensemble pour le répéter entre nombre1 et nombre2 fois
> \caractère : despécialisation du caractère
» « ... » : tout ce qui se trouve entre les « » est interprété littéralement
> | : la disjonction
> :digit: : la classe des chiffres (il existe d'autres classes définies de cette manière)
> / : expression rationnelle contextuelle (ex : 0/1 signifie 0, mais seulement quand il est suivi de 1)
> beaucoup d'autres choses : cf. le manuel de flex
```

 $[-+]?([0-9]*\.?[0-9]+|[0-9]+\.)(E(+|-)?[0-9]+)?$: nombres en Fortran

Ambiguïtés (plusieurs candidats)

Quand plusieurs expressions rationnelles peuvent être utilisées pour consommer l'entrée :

- flex sélectionne celles qui consomment le plus de caractères sur l'entrée
- > s'il n'y en a qu'une, c'est elle qui est utilisée
- > s'il y en a plusieurs, alors c'est la première apparaissant dans le fichier flex qui est utilisée

```
%%
                                                    %%
[[:digit:]]+ printf("Nombre");
.* /* Rien */
                                                                 /* Rien */
                                                    [[:digit:]]+ printf("Nombre");
% cat ex.txt
                                                    % cat ex.txt
un mot
                                                    un mot
456456
                                                    456456
123 45
                                                    123 45
                                                    % ./a.out <ex.txt
% ./a.out <ex.txt
Nombre
%
                                                    %
```

Aucun candidat

Quand aucune expression rationnelle ne peut être sélectionnée pour lire l'entrée la règle par défaut s'applique :

- > recopier le caractère courant sur la sortie
- passer au caractère suivant

L'analyseur lexical le plus court recopie le flot d'entrée sur le flot de sortie :

```
$ cat ex.l
%%
%%
$ ./a.out <ex.l
%%
%%
$
```

Contextes (start conditions)

Il est possible d'activer/désactiver des expressions rationnelles au fur et à mesure de l'analyse

```
%x comment
%%
"/*"

<comment>[^*\n]*

<comment>"*"+[^*\n]*

<comment>\n
<comment>"*"+"/"

BEGIN(comment);

/* consomme ce qui n'est pas un '*' */

/* consomme les * qui ne sont pas suivies par un / */

<comment>\n
<comment>\n

BEGIN(INITIAL);
```

- Le contexte « comment » active les 4 expressions rationnelles quand /* a déjà été lu
- > Toute expression est activée dans un contexte. Le contexte initial s'appelle INITIAL
- BEGIN permet de changer de contexte (il n'y a pas de END!)
- Les contextes peuvent être déclarés exclusifs (%x) ou pas (%s)

```
%s exemple
%%

<exemple>toto
titi

%x exemple
%%

<exemple>toto
cexemple>toto
<exemple,INITIAL>titi
```

 L'utilisation des contextes peut permettre d'éviter d'écrire des expressions rationnelles trop complexes, ou permet de reconnaître des ensembles de lexèmes non rationnels

Pile de contextes

Les noms des contextes sont en fait des entiers

Flex met à la disposition du programmeur un mécanisme de pile pour les contextes %option stack

La pile grossit dynamiquement.

- void yy_push_state (int new_state)
 Sauve le contexte courant sur la pile et réalise un BEGIN new_state
- void yy_pop_state ()
 Retire un contexte c du sommet de pile et réalise un BEGIN c
- int yy_top_state ()
 Retourne le contexte en sommet de pile en le laissant dans la pile

Quelques variables et macros utiles de flex

- > yytext : contient le motif lu
 - char * ou char[YYLMAX] (voir %option)
 - contenu modifiable par l'utilisateur, à condition de ne pas changer la longueur !
- > yyleng : longueur du motif lu
- ECHO : envoie le motif lu sur yyout
- > REJECT:
 - cette expression rationnelle rejette le motif, l'analyse reprend avec les autres expressions rationnelles
- yyin : le flot d'entrée de yylex
- yyout : le flot de sortie de yylex

Il y en a bien d'autres. Par exemple, pour permettre d'empiler les flots (gestion des #include en C). Voir le manuel.

```
%%
a ECHO; REJECT;
ab ECHO; REJECT;
abc ECHO; REJECT;
abcd ECHO; REJECT;
%%
```

Sur l'entrée abcd, sort abcdabcabaabcd

Quelques fonctions utiles de flex

- yymore() : indique à flex que le prochain motif doit être concaténé au courant dans yytext plutôt que de le remplacer
- yyless(n) : indique à flex que le motif courant privé de son préfixe de taille n doit être remis sur l'entrée
- > unput(c) : le caractère c doit être remis sur l'entrée (attention : détruit yytext si c'est un char *)
- input() : lit le prochain caractère de l'entrée
- > yyterminate() :
 - peut remplacer un return dans yylex().
 - termine l'analyseur lexical
 - > retourne 0 à l'appelant
 - c'est une macro, qui peut être redéfinie.

yywrap()

- Appelée par flex quand il rencontre EOF sur yyin
- > Retourne 1 pour indiquer à flex que l'analyse est terminée
- Retourne 0 pour indiquer à flex qu'il faut continuer : dans ce cas, yywrap() aura au préalable fait le nécessaire pour assurer que le flot d'entrée continue
- En fait, c'est une macro

```
%{
int q argc;
char **g argv;
int current;
size t cc=0, lc=0, wc=0;
%}
SÉP
       [ \t]
NSEP [^\t\n]
%%
{NSEP}+
              cc += yyleng; ++wc;
{SEP}+
              cc += yyleng;
              ++lc; ++cc;
\n
%%
int yywrap() {
 if ( yyin != stdin ) fclose(yyin);
 if (current == g argc-1) return 1;
 if ( ( yyin = fopen(g_argv[++current], "r") ) == NULL ) {
  perror(g argv[current]); exit(EXIT FAILURE);
 return 0;
```

```
int main(int argc, char *argv[]) {
    g_argc = argc;
    g_argv = argv;
    if ( argc == 1 ) {
        yyin = stdin;
        current = 1;
    } else {
        current = 1;
    if ( ( yyin = fopen(argv[current], "r") ) == NULL ) {
            perror(argv[current]);
            return EXIT_FAILURE;
        }
    }
    yylex();
    printf("%8zu %8zu %8zu\n", lc, wc, cc );
    return EXIT_SUCCESS;
}
```

main() de flex

Celui de la bibliothèque de flex appelle yylex() dans une boucle

while (yylex()) ;

> Celui généré par %option main se contente d'appeler yylex()
int main(int argc, char *argv[]) {
 yylex();
 return 0;
}

> L'utilisateur peut toujours écrire le sien !
 A préférer pour une meilleure maîtrise du programme (environnement, locale, etc)

%option

- > array : yytext est déclaré comme un tableau de YYLMAX caractères
- > pointer : yytext est un char *, dont la taille varie dynamiquement en fonction des besoins
- main : lex intègre un main dans le code qu'il produit, qui se contente d'appeler yylex()
- never-interactive : le code généré considère que son entrée n'est pas interactive (ex : un terminal)
- > always-interactive : opposé de %never-interactive
- > stdinit : yyin et yyout sont initialisées à stdin et stdout
- yylineno : lex compte le numéro de la ligne analysée dans une variable globale yylineno
- yywrap : lex appelle yywrap() en fin de flot d'entrée
- > noyywrap : lex n'appelle pas yywrap() en fin de flot d'entrée
- > outfile= : change le nom de la sortie (lex.yy.c) par un autre (=option -o de flex)
- prefix= : change le prefixe « yy » utilisé pour tous les identificateurs du code généré,
 par un autre (=option -P de flex)

La bibliothèque de flex

Contient deux implantations par défaut pour

- yywrap : retourne toujours 1
- > main : appelle yylex() dans une boucle while (yylex()) ;

Utilisation : -Ifl en fin de ligne de compilation gcc

Si aucune des deux implantations par défaut ci-dessus n'est nécessaire, autant ne pas l'utiliser!

Analyse syntaxique

Analyse syntaxique

Entrée : un flot de lexèmes

Sortie : au choix, typiquement un arbre et une table des symboles

But : analyser la structure du flot de lexèmes

Types (usuels):

analyses descendantes usuelles : LL(k)

analyses ascendantes usuelles : LR(k), SLR(k), LALR(k), GLR(k)

Outil formel usuel : grammaires

Outil de programmation : pour nous, Bison (analyse de type LALR(1))

Grammaires algébriques (non contextuelles)

G = (S,N,T,P) avec

T un ensemble (non vide) de symboles appelés *terminaux* (qui pour nous seront les lexèmes)

N un ensemble (non vide) de symboles appelés *non-terminaux* (N disjoint de T)

S un symbole de N, appelé axiome

P un ensemble de productions

Production : objet de la forme A -> γ avec

A un non-terminal, appelé *membre gauche* de la production

y une suite d'éléments de T et de N (un mot sur l'alphabet TυN), appelé *membre droit* de la production

```
Exemple : G=(S,N,T,P) avec T=\{0,1,...,9,+,-,*,/\},\ N=\{E\},\ S=E, P=\{\ E->E+E,\ E->E-E,\ E->E'E,\ E->E/E\}\ \cup\ \{E->x:x\in\{0,1,...,9\}\}
```

Dérivation

Remplacement, dans un mot γ , d'un non-terminal X par le membre droit d'une production de la forme X -> β

Exemple: E+E se dérive en E+E+E (ou E+E+E), mais aussi en 4+E, en E+5, en E-E+E, en E+E/E, en 1+2, etc

La relation de dérivation se note =>, sa fermeture transitive et réflexive =>*

Exemple : E => E+E => E+E-E => 1+E-E => 1+E-4 => 1+E/E-4 => 1+E/3-4 => 1+2/3-4 E =>
$*$
 1+2/3-4

Le langage d'une grammaire est l'ensemble des mots sur ses terminaux qu'on obtient à partir de l'axiome

Exemple : le langage de la grammaire G précédente est l'ensemble des expressions arithmétiques sur les chiffres

Un langage est algébrique s'il peut être défini par une grammaire algébrique Tous les langages ne sont pas algébriques (cf. cours de théorie des langages)

Arbre de dérivation


Les dérivations successives appliquées sur un non-terminal peuvent être représentées graphiquement sous la forme d'un arbre, appelé *arbre de dérivation*

$$E \Rightarrow E + E \Rightarrow E + E - E \Rightarrow 1 + E - E \Rightarrow 1 + E - 4 \Rightarrow 1 + E / E - 4 \Rightarrow 1 + E / 3 - 4 \Rightarrow 1 + 2 / 3 - 4$$

Un arbre de dérivation pour 1+2/3-4 à partir de E

La suite des feuilles lues de la gauche vers la droite est 1+2/3-4


L'arbre de dérivation donne la structuration des lexèmes entre eux



Grammaire ambiguë

Une grammaire est *ambiguë* s'il existe plusieurs arbres de dérivation pour un mot *u* à partir d'un non-terminal X (donc, plusieurs structurations des lexèmes entre eux)


La grammaire de l'exemple précédent est ambiguë car il existe plusieurs arbres de dérivation pour 1+2/3-4 à partir de E



Arbre de syntaxe abstraite (AST)

Version simplifiée, sans les non-terminaux, de l'arbre de dérivation


Comme l'arbre de dérivation, l'AST donne une structuration des lexèmes entre eux d'après les productions de la grammaire




Retour sur l'ambiguïté


Notre grammaire pour les expressions arithmétiques est ambiguë car

Elle ne prend pas en compte l'associativité des opérateurs (ex : $E = >^* 1+2+3$)



Elle ne prend pas en compte la priorité des opérateurs (ex : E = * 1 + 2*3)






Transformer la grammaire pour supprimer les ambiguïtés

On supprime les ambiguïtés liées à l'associativité de la somme en changeant


- $^{>}$ E -> E+E par E -> E+x, x ∈ {0,1,...,9} :
 - > on impose l'associativité à gauche par des productions récursives gauches
 - → 1+2+3 est interprété comme (1+2)+3



les arbres penchent à gauche

- > ou E -> E+E par E -> x+E1, x ∈ $\{02,1,...,9\}$:
 - > on impose l'associativité à droite par des productions récursives droites
 - 1+2+3 est interprété comme 1+(2+3)

les arbres penchent à droite




Transformer la grammaire pour supprimer les ambiguïtés

Pour rendre * prioritaire sur +, il faut imposer que

- * apparaissent plus bas, dans les arbres, que +
- ou, de manière équivalente, que la production pour + soit plus proche de l'axiome que *

E-> E+F, E->F, F->F*x, F->x,
$$x \in \{0,1,...,9\}$$



Une grammaire complète pour les expressions arithmétiques

- > On peut toujours s'arranger pour que l'axiome n'apparaisse qu'en membre gauche
- A partir de maintenant on notera toujours l'axiome S, les terminaux en minuscules et les non-terminaux en majuscules
- > On notera X -> γ | γ' quand X -> γ et X -> γ' sont des productions

- Les associativités des opérateurs sont fixées à gauche (elles auraient pu l'être à droite)
- Les priorités sont correctement gérées
- Le parenthésage a été ajouté pour permettre (1+2)*3, par exemple
- Les constantes ont maintenant un nombre quelconque de chiffres


Un autre exemple: if...then...else...

S -> I
I -> if E then I else I | if E then I
E -> true | false | ...

I: les instructions

E : les expressions booléennes

if true then if true then I else I



Un autre exemple: if...then...else...

Le else doit porter sur le if le plus proche if/then est plus haut, dans l'arbre, que if/then/else : on utilise le même système que pour l'expression de la priorité de * sur +

I': les instructions sans le if

```
S \rightarrow A
A \rightarrow if E then B \mid B
B -> if E then B else A | I' | { A }
if true then
     if true then I
else l
n'a plus d'arbre de dérivation
mais
if true then {
     if true then I
} else l
en a un. Lequel?
```

```
if E then B
true if E then B else A
true l' B
```

Algorithmes d'analyse syntaxique

Ils doivent être à la fois pratiques

- > sens de lecture du flot de lexèmes de la gauche vers la droite (left-to-right)
- les grammaires doivent être le plus simple possible à écrire et analyser
 et les plus efficaces possibles en temps d'exécution et mémoire utilisée.
- Deux grandes classes d'algorithmes d'analyse syntaxique sont utilisées en pratique
- l'analyse prédictive (ou descendante) : Left-to-right Leftmost (LL): la lecture du flot de lexèmes se fait de gauche à droite, et on essaie d'abord de dériver le non-terminal le plus à gauche des productions
- l'analyse ascendante : Left-to-right Rightmost (LR) : la lecture du flot de lexèmes se fait de gauche à droite, et on essaie d'abord de dériver le non-terminal le plus à droite
- Les analyses LL(k) ou LR(k) lisent d'avance k lexèmes (qu'on assimilera à des *caractères*) pour tenter de prédire les actions à réaliser. Souvent, k=1.

Algorithmes d'analyse syntaxique

On suppose k=1 à partir de maintenant. La généralisation à k>1 n'est pas difficile.

Les deux classes d'algorithmes calculent les ensembles suivants sur la grammaire :

- Annulable (Nullable): l'ensemble des non-terminaux X tels que X =>* ε
- Premier(X) (First(X)): l'ensemble des terminaux a tels que X =>* ay
- > Suivant(X) (Follow(X)) : l'ensemble des terminaux a tels que $S = >^* \gamma Xa\gamma'$ en résolvant des systèmes d'équations ensemblistes.

Ces trois ensembles sont utilisés pour produire, à partir d'une grammaire donnée et si c'est possible, des analyseurs descendants ou ascendants avec un caractère de prédiction.

Annulable

Ensemble des non-terminaux X tels que $X = >^* \epsilon$

```
\begin{array}{lll} S \to XYS \mid a & Y \text{ est annulable car } Y => E \\ Y \to c \mid E & X \text{ est annulable car } X => Y \text{ et } Y \text{ est annulable} \\ X \to a \mid Y & S \text{ n'est pas annulable} \\ \hline\\ Tmp <- \left\{\right\} \\ Annulable <- \left\{X : X \to E\right\} \\ Tant que Annulable != Tmp \\ Tmp <- Annulable \\ Annulable += \left\{X : X \to X_1...X_n , X_i \in Tmp \text{ pour tout } i \in 1..n\right.\right\} \\ \end{array}
```

Premier(X)

Ensemble des terminaux a tels que $X = >^* ay$

```
S -> E$
E -> E+F | E-F | F
F -> F*T | F/T | T
T -> (E) | C
C -> 0 | 1 | ... | 9
```

```
Premier(C) = { 0,1, ..., 9 }
Premier(T) = { ( } U Premier(C)
Premier(F) = Premier(T)
Premier(E) = Premier(F)
Premier(S) = Premier(E)
```

Premier(X) est le plus petit ensemble vérifiant :

- > si X -> ay alors a \in Premier(X)
- $^{>}$ si X -> Yy alors Premier(Y) ⊆ Premier(X)
- ⇒ si X -> $X_1^*...X_n$ ay et $X_1...X_n$ ∈ Annulable alors a ∈ Premier(X) et Premier(X_i) ⊆ Premier(X) pour tout i ∈ 1...n
- si $X \to X_1...X_nY_Y$ et $X_1...X_n \in Annulable$ alors $Premier(Y) \subseteq Premier(X)$ et $Premier(X_i) \subseteq Premier(X)$ pour tout $i \in 1...n$

Premier(X)

Ensemble des terminaux a tels que $X = >^* ay$

```
\begin{array}{lll} S \rightarrow XYS \mid b & \text{Annulable} = \{ \ X, \ Y \ \} \\ Y \rightarrow c \mid \epsilon & \\ X \rightarrow a \mid Y & \text{Premier}(X) = \{ \ a \ \} \ \cup \ \text{Premier}(Y) \\ & \text{Premier}(Y) = \{ \ c \ \} \\ & \text{Premier}(S) = \{ \ b \ \} \ \cup \ \text{Premier}(X) \ \cup \ \text{Premier}(Y) \\ & = \{ \ a, \ b, \ c \ \} \end{array}
```

Suivant(X)

Ensemble des terminaux a tels que $S = * \gamma Xa\gamma'$

```
Suivant(X) est le plus petit ensemble vérifiant :  si \ Y \to \gamma Xay' \ alors \ a \in Suivant(X)   si \ Y \to \gamma XZy' \ alors \ Premier(Z) \subseteq Suivant(X)   si \ Y \to \gamma X \ alors \ Suivant(Y) \subseteq Suivant(X)   si \ Y \to \gamma XZ_1...Z_nay \ et \ Z_1...Z_n \ sont \ Annulable \ alors \ a \in Suivant(X)   et \ Premier(Z_i) \subseteq Suivant(X) \ pour \ tout \ i \in 1...n   si \ Y \to \gamma XZ_1...Z_nKy \ et \ Z_1...Z_n \ sont \ Annulable \ alors \ Premier(K) \subseteq Suivant(X)   et \ Premier(Z_i) \subseteq Suivant(X) \ pour \ tout \ i \in 1...n   si \ Y \to \gamma XZ_1...Z_n \ et \ Z_1...Z_n \ sont \ Annulable \ alors \ Suivant(Y) \subseteq Suivant(X)   et \ Premier(Z_i) \subseteq Suivant(X) \ pour \ tout \ i \in 1...n   Par \ convention, \ \$ \ est \ dans \ les \ suivants \ de \ l'axiome
```

Suivant(X)

Ensemble des terminaux a tels que $S = * \gamma Xa\gamma'$

```
S -> E$
E -> E+F | E-F | F
F -> F*T | F/T | T
T -> (E) | C
C -> 0 | 1 | ... | 9
```

```
Annulable = {} Premier(C) = { 0, ..., 9 } Premier(S) = Premier(E) = Premier(F) = Premier(T) = { (, 0, ..., 9 } Suivant(E) = { +, -, ), $ } Suivant(T) contient Suivant(F) Suivant(F) contient Suivant(E) et { *, / } Suivant(F) = { +, -, *, /, ), $ } Suivant(C) = Suivant(T) Suivant(S)={$}
```

```
S -> XYS | b
Y -> c | ε
X -> a | Y
```

```
Annulable = \{X, Y\}
Premier(X) = \{a, c\}
```

Premier(S) =
$$\{a, b, c\}$$

Suivant(X) = Premier(Y)
$$\cup$$
 Premier(S) = { a, b, c } Suivant(Y) = Premier(S) \cup Suivant(X) = { a, b, c } Suivant(S) = {\$}

Annulable, Premier, Suivant

```
\begin{array}{lll} S -> E \$ & \text{Annulable} = \{ \ O \ \} \\ E -> EOE \ | \ F & \text{Premier}(F) = \{ \ n, \ ( \ \} & \text{Premier}(O) = \{ \ +, \ - \ \} \\ O -> + \ | \ - \ | \ E & \text{Premier}(E) = \{ \ n, \ ( \ \} & \text{Premier}(S) = \{ \ n, \ ( \ \} \\ & \text{Suivant}(S) = \{ \ \} \\ & \text{Suivant}(O) = Premier(E) = \{ \ n, \ ( \ \} \\ & \text{Suivant}(E) = \{ \ ), \$ \ \} \ \cup \ Premier(O) \ \cup \ Premier(E) = \{ \ n, \ (, \ ), \ +, \ -, \$ \ \} \\ & \text{Suivant}(F) = Suivant(E) = \{ \ n, \ (, \ ), \ +, \ -, \$ \ \} \end{array}
```

```
\begin{array}{lll} S -> E \$ & \text{Annulable} = \{ \ T', \ E' \ \} \\ E -> TE' & \text{Premier}(F) = \{ \ n, \ ( \ \} & \text{Premier}(T') = \{ \ ^*, \ / \ \} & \text{Premier}(T) = \{ \ n, \ ( \ \} \\ E' -> +TE' \ | \ -TE' \ | \ \epsilon & \text{Premier}(E') = \{ \ +, \ - \ \} & \text{Premier}(E) = \{ \ n, \ ( \ \} & \text{Premier}(S) = \{ \ n, \ ( \ \} \\ E' -> +TE' \ | \ -TE' \ | \ \epsilon & \text{Premier}(E') = \{ \ +, \ -, \ \} & \text{Suivant}(E') = Suivant}(E') = \{ \ +, \ -, \ ), \ \$ \} \\ E' -> T' -> *FT' \ | \ /FT' \ | \ \epsilon & \text{Suivant}(T) = \text{Premier}(E') \cup \text{Suivant}(E) \cup \text{Suivant}(E') = \{ \ +, \ -, \ ), \ \$ \} \\ E' -> E
```

Extension de Annulable et Premier

Ils peuvent s'étendre à une suite de terminaux et non-terminaux

X₁...X_n est annulable si tout les X_i le sont

 $F \rightarrow n \mid (E)$

```
a \in \text{Premier}(X_1...X_na_Y) \text{ si } n=0 \text{ ou tous les } X_i \text{ sont annulables} \text{Premier}(X_n) \subseteq \text{Premier}(X_1...X_n\gamma) \text{ si tous les } X_j, j < n, \text{ sont annulables} \text{Premier}(X\gamma) = \text{Premier}(X) \text{ si } X \text{ n'est pas annulable}
```

```
\begin{array}{lll} S -> E \$ & & Annulable = \{ \ T', \ E' \ \} \\ E -> TE' & & Premier(F) = \{ \ n, \ ( \ \} \\ E' -> +TE' \ | \ -TE' \ | \ \epsilon & Premier(E') = \{ \ +, \ - \ \} \\ T -> FT' & Premier(T) = \{ \ n, \ ( \ \} \\ T' -> *FT' \ | \ /FT' \ | \ \epsilon & Premier(TE) = Premier(T) \end{array}
```

 $Premier(T'E) = Premier(T') \cup Premier(E)$

Grammaire transformée, prédiction

Dans les algorithmes d'analyse syntaxique, on utilise en général une grammaire légèrement transformée :

- l'axiome n'apparaît jamais en membre droit de production
- > la fin de flot est marquée par un caractère spécial : \$

On remplace l'axiome S par un nouveau non-terminal S', et on ajoute S' -> S\$

$$S \rightarrow Yd \mid \epsilon$$

Y -> Sc | ϵ

devient

Les algorithmes d'analyse syntaxique peuvent utiliser k caractères (lexèmes) lus en avance sur le flot d'entrée, pour déterminer ce qu'ils doivent faire : ce sont les *caractères de prédiction*. Souvent, k=1.

Analyse descendante LL(k): Left-to-right Leftmost derivation

Left-to-right : le flot de lexèmes est lu de la gauche vers la droite Leftmost derivation : dans le membre droit de la production en cours d'utilisation, on dérive d'abord le non-terminal le plus à gauche k caractères de prédiction sont utilisés (pour nous, k=1)

On démarre de la production S -> S'\$

Une pile est utilisée : elle contient γ , le mot sur l'alphabet des terminaux et des non-terminaux qu'il reste à analyser pour une analyse réussie

Au départ, γ vaut « S ». Supposons que le caractère de prédiction soit a (la fin de flot est marquée par \$)

Si $y = X_1...X_n ay'$, $n \ge 0$, et tous les X_i sont annulables On consomme le prochain lexème et on remplace γ par γ' . Si a=\$ l'analyse est terminée. Elle est réussie ssi γ' est vide Si $y = X_1...X_nYy'$, n>0, $a \in Premier(Y)$ et tous les X_i sont annulables On remplace γ par $Y\gamma'$ Si $\gamma = X\gamma'$, $a \in Premier(X)$, $X \rightarrow \gamma''$ avec $a \in Premier(\gamma'')$ On remplace γ par $\gamma''\gamma'$

On recommence

Si pendant l'analyse plusieurs choix sont possibles, ou aucun choix n'est possible, l'analyse échoue.

LL(1) en pratique

Par soucis d'efficacité, on ne programme pas le principe précédent tel quel.

On préfère traiter la grammaire avant de démarrer l'analyse, afin de garantir :

- > qu'aucun choix multiple ne se produira pendant l'analyse
- > que le choix de l'action à réaliser pendant l'analyse se fasse en temps constant

On construit une table qui indique, pour chaque terminal possible et pour chaque non-terminal X en sommet de pile, l'unique production X -> y à utiliser si elle existe Si cette table ne peut pas être construite, on dit que la grammaire n'est pas LL(1)

Pour construire la table T (lignes : les non-terminaux, colonnes : les terminaux):

➤

```
Pour chaque X non terminal et a terminal
   on calcule T[X,a] le plus petit ensemble vérifiant :
   Si X → y ∈ P avec y annulable, et a ∈ Suivant(X)
   y ∈ T[X,a]
   Si X → y ∈ P avec a ∈ Premier(y)
   y ∈ T[X,a]
   Si |T[X,a]|>1 erreur
```

Suppression de la récursivité à gauche

Hypothèse de départ : pas d'e-production (cf. cours de Théorie des langages pour les supprimer)

```
Récursivité gauche immédiate (cas simple (\gamma' ne commence pas par A))
A \rightarrow A\gamma | \gamma' produit \gamma', \gamma'\gamma, \gamma'\gamma\gamma, ... = \gamma'\gamma^* et se transforme en A -> \gamma'B, B\rightarrow \gammaB | \epsilon
```

Récursivité gauche immédiate (cas général (les
$$\gamma'$$
 ne commencent pas par A)) A \rightarrow A γ_1 | ... |A γ_n | γ'_1 |...| γ'_m se transforme en A \rightarrow γ'_1 B | ... | γ'_m B, B -> γ_1 B | ... | γ_n B | ϵ

Algorithme général d'élimination de la récursivité gauche, immédiate ou non : Soit G une grammaire sans cycle (A->A) et sans production vide (A-> ϵ) Commencer par ordonner les non-terminaux de G : A_1, \ldots, A_n

Pour i allant de 1 à n

Pour j allant de 1 à i-1 Remplacer chaque production de la forme $A_i -> A_j y$ par $A_i \rightarrow y'_1 y | ... | y'_k y$ quand $A_j \rightarrow y'_1 | ... | y'_k$ sont toutes les productions dont A_j est membre gauche Éliminer la récursivité gauche immédiate des productions dont A_j est membre gauche

Construction de la table LL(1)

Pour chaque X non terminal et a terminal on calcule T[X,a] le plus petit ensemble vérifiant :

```
    Si X → γ ∈ P avec γ annulable, et a ∈ Suivant(X) γ ∈ T[X,a]
    Si X → γ ∈ P avec a ∈ Premier(γ)
```

Si X → y ∈ P avec a ∈ Premier(y)
 y ∈ T[X,a]

Annulable = { T', E' }
Les Premier se calculent
 facilement
Suivant(S) = { \$ }
Suivant(E) = {), \$ }
Suivant(E') = Suivant(E)
Suivant(T) = { +, -,), \$ }
Suivant(T') = Suivant(T)
Suivant(F) = { *, /, +, -,), \$ }

	n	+	-	*	1	()	\$
S	E\$					E\$		
Е	TE'					TE'		
E'		+TE'	-TE'				3	3
Т	FT'					FT'		
T'		3	3	*FT'	/FT'		3	3
F	n					(E)		

$$\begin{array}{l} S \rightarrow E \$ \\ E \rightarrow TE' \\ E' \rightarrow +TE' \mid -TE' \mid \epsilon \\ T \rightarrow FT' \\ T' \rightarrow *FT' \mid /FT' \mid \epsilon \\ F \rightarrow n \mid (E) \end{array}$$

Utilisation de la table LL(1)

```
X <- sommet de pile</li>
a <- caractère courant dans le flot d'entrée</li>
Tant que X!= $
si X est un terminal ou $
Si X = a
dépiler X, avancer d'un caractère sur le flot d'entrée
Sinon erreur
sinon
Si T[X,a] = X₁...X<sub>n</sub>
Dépiler X, empiler X<sub>n</sub>,...,X₁, émettre X → X₁...X<sub>n</sub> en sortie
Sinon erreur (car T[X,a] est vide)
Si la fin du flot n'est pas atteinte, erreur
```

	n	+	-	*	1	()	\$
S	E\$					E\$		
Е	TE'					TE'		
E'		+TE'	-TE'				3	3
Т	FT'					FT'		
T'		3	3	*FT'	/FT'		3	3
F	n					(E)		


Entrée 1+2*3\$	Pile S	Sortie
1+2*3\$ 1+2*3\$	E\$ TE'\$	S→ E\$ E→ TE'
1+2*3\$ 1+2*3\$	FT'E'\$ 1T'E'\$	T→ FT' F→ n
+2*3\$ +2*3\$	T'E'\$ E'\$	T'→ ε
+2*3\$ 2*3\$	-Ψ +ΤΕ'\$ ΤΕ'\$	E'→ +TE
2*3\$ 2*3\$	FT'E'\$ 2T'E'\$	T→ FT' F→ n
*3\$ *3\$	Τ'Ε'\$ *FT'E'\$	T'→ *FT'
3\$	FT'E'\$ 3T'E'\$	F→ n
3\$ \$ \$	T'E'\$ E'\$	
<u> </u>	\$	T'→ ε E'→ ε
Fin (succ	Jes)!	

Utilisation de la table LL(1)

Pile	Sortie
	o =+
	S→ E\$
•	E→ TE' T→ FT'
•	r→ ri F→ n
	1 / 11
	T'→ ε
	E'→ +TE'
TE'\$	
FT'E'\$	T→ FT'
	F→ n
	T, FT,
	T'→ FT'
	F→ n
	1 -7 11
F'\$	$T' \rightarrow \epsilon$
	E'→ ε
ès)!	
	S \$ \\$ \\$ \\$ \\$ \\$ \\$ \\$ \\$ \\$ \\$ \\$ \\$ \

La lecture de la sortie du haut vers le bas donne une dérivation gauche

L'arbre de dérivation peut être reconstruit à partir des changements de pile (sortie)



Programmation récursive de LL(1)

```
bool analyse E(const char **s) {
 switch (**s) {
 case '0': case '1': case '2': case '3': case '4':
 case '5': case '6': case '7': case '8': case '9': return analyse T(s) && analyse Ep(s); /* E -> TE' */
case '(': return analyse T(s) && analyse Ep(s); /* E -> TE' */
 default: return false:
                                                                                                   Facile!
bool analyse_Ep(const char **s) {
 switch (**s) {
                                                                                                   Pile de l'algorithme
 case '+': case '-': ++*s; return analyse T(s) && analyse Ep(s); /* E' -> (+|-)TE' */
 case ')': case '$': return true; /* E' -> epsilon */
 default: return false:
                                                                                                  = pile des appels récursifs
bool analyse_T(const char **s) {
switch (**s) {
case '0': case '1': case '2': case '3': case '4': case '5': case '6': case '8': case '9': return analyse F(s) && analyse Tp(s); /* T -> FT' */
 case '(': return analyse F(s) && analyse Tp(s); /* T -> FT' */
 default: return false;
bool analyse Tp(const char **s) {
 switch (**s) {
case '*': case '/': ++*s; return analyse_F(s) && analyse_Tp(s); /* T' -> (*|/)FT' */
 case '+': case '-': case ')': case '$': return true; /* T' -> epsilon */
 default: return false:
bool analyse F(const char **s) {
 switch (**s) {
 case '0': case '1': case '2': case '3': case '4': case '5': case '6': case '7': case '8': case '9': ++*s; return true; /* F-> chiffre */
 case '(': ++*s; return analyse E(s) && ( **s==')' ? ++*s, true : false ); /* F ->(E) */
 default: return false:
```

Conflits LL(1)

Une grammaire récursive gauche bien définie génère un conflit

 $E \rightarrow E+n \mid n : T[E,n]$ peut être E+E ou n

On peut toujours la transformer en grammaire récursive droite

 $E \rightarrow n + E \mid n$

Une grammaire avec deux productions X -> γ et X -> γ' telles que Premier(γ) \cap Premier(γ') $\neq \emptyset$ génère un conflit.

 $E \rightarrow n+E \mid n$

Dans ce cas, il faut factoriser

$$E \rightarrow nY$$

$$E \rightarrow nY$$
 $Y \rightarrow +E \mid \epsilon$

Problèmes:

- > les grammaires obtenues par ces transformations sont peu naturelles, difficiles à comprendre, et les arbres de dérivations, les AST le seront aussi
- > les grammaires LL(1) ont de fortes contraintes : il peut être très difficile, voire impossible, d'écrire une grammaire LL(1) pour un langage donné

Analyse ascendante LR(k): Left-to-right Rightmost derivation

Left-to-right : le flot de lexèmes est lu de la gauche vers la droite Rightmost derivation : dans le membre droit de la production en cours d'utilisation, on dérive d'abord le non-terminal le plus à droite k caractères de prédiction sont utilisés (pour nous, k=1)

Le principe est de considérer toutes les productions possibles à un instant donné de l'analyse.

On matérialise, pour chacune de ces productions, où on en est dans son analyse par un • (*production marquée*)

E -> E • +E signifie que l'analyse d'une somme est en cours, que le membre gauche de la somme a déjà été analysée, et que le prochain caractère attendu sur l'entrée pour progresser est +.

Si le prochain lexème est +, alors quand il sera consommé on passera à E -> E+ • E (décalage par +) Sinon, le flot d'entrée n'est pas une somme et on abandonnera l'analyse de E-> E+E au profit d'autres productions

- E -> E+E signifie qu'on va tenter de dériver un E sous la forme de E+E, et que dans l'analyse de E+E rien n'a été encore lu
- E -> E+E signifie que les derniers caractères lus dans le flot d'entrée sont de la forme E+E, donc E (réduction de E+E en E)

Départ de l'analyse :

On démarre l'analyse de l'axiome : S -> • γ\$ pour chaque production dont S est membre gauche ldem pour tout non-terminal à gauche du point (opération de *fermeture*)

Fin de l'analyse :

 $S \rightarrow Y$ en fin de flot

Fermeture

Soit C un ensemble de productions marquées.

Fermeture de C : pour toute production de C où • est à la gauche d'un non-terminal X, on ajoute à C toutes les productions dont X est membre gauche, avec un • complètement à gauche. on recommence jusqu'à stabilité du calcul de la fermeture

Exemple : Grammaire : S -> E\$ E -> EOE | F O -> + | - | ϵ F -> n | (E) C = { S -> •E\$ } Fermeture(C) = { S -> •E\$, E -> •EOE, E -> •F, F-> •n, F-> •(E) }

Automate d'analyse LR

Les états sont des ensembles fermés de productions marquées compatibles avec l'analyse en cours


L'état initial est le plus petit contenant S -> •γ\$ pour toute production S -> γ\$ dont S est membre gauche (hypothèse : grammaire augmentée)

L'état final est celui contenant une production marquée S -> γ\$•


(hypothèse : grammaire augmentée)

Les états sont reliés par des actions :

- décalage par lecture d'un terminal ou non-terminal X :
 - similaire à une transition étiquetée X,
 - consomme X sur l'entrée si X est un terminal, ne consomme rien si X est un non-terminal
 - on passe d'un état contenant X -> γ•Xγ' vers un autre contenant X -> γX•γ'
- réduction :
 - ne consomme pas l'entrée
- on passe d'un état contenant X -> γ (signalant la fin de l'analyse de γ, donc de X),
 vers un autre contenant une transition marquée de la forme Y -> γ'X γ"
 Le choix de l'action doit être déterminé de manière unique en fonction de ce qu'il y a à lire sur l'entrée



Toutes les actions sont déterminées de manière unique en fonction de ce qu'il y a à lire, la grammaire est LR(0)



Plusieurs états avec plusieurs possibilités d'action, la grammaire n'est pas LR(0)

Utilisation de l'automate d'analyse

Hypothèse : grammaire où

- les productions dont l'axiome S est membre gauche sont de la forme S -> γ\$
- S n'apparaît pas dans le membre droit d'une production

E: ensemble d'états de la machine LR

Une pile contenant un mot de E((T∪N)E)*

Au départ, la pile contient l'état initial 0

Tant qu'on ne réduit pas l'axiome

x <- prochain symbole de l'entrée

Si action(état de sommet de pile,x) = réduction par $X \rightarrow X_1...X_n$

dépiler, dans l'ordre, s_n, X_n, s_{n-1}, ..., s₁, X₁


empiler X

empiler l'état pointé par la transition par X et partant de l'état en sommet de pile

Sinon /* décalage */

empiler x et l'état pointé par la transition par x et partant de l'état en sommet de pile (erreur s'il n'existe pas)

L'analyse est réussie si on réduit l'axiome tout en atteignant la fin du flot !



Conflits LR

Deux types de conflits (choix non déterministe d'action) :


- Réduction/réduction (reduce/reduce, R/R):
 dans le même état il est possible de réduire deux productions différentes
- Décalage/réduction (shift/reduce, S/R) : un état contient à la fois une réduction et une possibilité de décalage

Stratégies pour résoudre les conflits : regarder ce qu'il y a à lire, jusqu'à k caractères (symboles de prédiction)

- ŠĽR (Simple ĽR) : utilisátion de Suivant(X) avec la même machine
 - en cas de conflit entre une réduction X ->γ• et une réduction X' -> γ'•,
 si l'intersection de Suivant(X) et Suivant(X') est vide, alors le conflit n'existera plus à l'exécution
 - en cas de conflit entre une réduction X ->γ• et un décalage X ->γ'• cγ"
 si c ∉ Suivant(X), décaler par c
- LR(k) : les k suivants possibles de chaque production sont stockés dans les états
- LALŔ(k) : même chose, avec simplification

> ...

```
Suivant(E) = \{+, \}, \}
Suivant(F) = \{+, *, \}, \}
Suivant(T) = \{+, *, \}, \}
```



Les suivants permettent de résoudre les conflits, la grammaire est SLR

Entrée 1+2+3\$	Pile	Action			
+2+3\$	0112	dec. 0 par 1			
+2+3\$	0T10	red. T->n			
+2+3\$	0F11	red. F->T			
+2+3\$	0E2	red. E->F			
2+3\$	0E2+4	dec. 2 par +			
+3\$	0E2+4212	dec. 4 par 2			
+3\$	0E2+4T10	red. T->n			
+3\$	0E2+4F5	red. F->T			
+3\$	0E2	red E->E+F			
3\$	0E2+4	dec. 2 par +			
	0E2+4312	dec. 4 par 3			
\$ \$ \$	0E2+4T10	red. T->n			
\$	0E2+4F5	red. F->T			
\$	0E2	red E->E+F			
	0E2\$	dec. 2 par \$			
Acceptation, car il faut réduire S->E\$!					

La lecture des réductions dans la colonne « action » du bas vers le haut donne une dérivation droite

L'arbre de dérivation peut être reconstruit à partir des actions

Analyse LR(k), k>0

Même principe que LR(0), mais on mémorise pour chaque production dans les états, l'ensemble des mots de longueur ≤ k par lesquels la réduction de la production peut être suivie

Il s'agit d'un *raffinement* de la notion de suivant dans SLR, qui va donc permettre de résoudre plus de conflits : il y aura davantage de grammaires LR(1) que de grammaires SLR(1).

On note X -> y, E la production de X en cours d'utilisation, dans un contexte où les suivants de X sont les éléments de E


Fermeture de C : pour toute production de X -> γ • Yγ', E, avec Y non-terminal, on ajoute à C toutes les productions dont Y est membre gauche, avec un • complètement à gauche, avec

- Premier(γ') comme contexte droit si γ n'est pas annulable
- Premier(γ')∪E comme contexte droit sinon on recommence jusqu'à stabilité du calcul de la fermeture

Une transition d'un état vers un autre laisse invariants les contextes droits associés à une production.

Un état ne peut pas contenir deux fois la même production, avec le • au même endroit, avec des contextes droits différents : si $X \to \gamma \bullet Y\gamma'$, E et $X \to \gamma \bullet Y\gamma'$, E' avec E!=E' sont des productions devant apparaître dans le même état, alors c'est $X \to \gamma \bullet Y\gamma'$, $E \cup E'$ qu'il faut mettre dans l'état

\$ est considéré comme suivant de l'axiome



Cette grammaire n'est pas LR(0) car en retirant les contextes droits de chaque production, il existe un conflit S/R

Elle est LR(1)

car les suivants de chaque production permettent de résoudre le conflit S/R :

- dans l'état 4, il n'y a pas de • avant un \$: si le caractère à venir est \$, on réduit, sinon on décale.

```
Entrée
         Pile
                          Action
1+2+3$ 0
+2+3$
         013
                          déc. 0 par 1
+2+3$
         0T4
                          red. T->n
2+3$
         0T4+5
                          déc. 4 par +
+3$
         0T4 + 523
                          déc. 5 par 2
+3$
+3$
$$
$$
$$
         0T4 + 5T4
                          red. T->n
         0T4+5T4+5
                          déc. 4 par +
         0T4+5T4+533
                          déc. 5 par 3
         0T4+5T4+5T4
                          red. T->n
         0T4+5T4+5E6
                          red. E->T
         0T4 + 5E6
                          red. E->T+E
         0E1
                          red. E->T+E
         0E1$2
                          déc. 1 par $
Acceptation, car il faut réduire S->E$!
```

LR(0), SLR(1), LR(1), ...

LR(0):

Peu de grammaires « naturelles » (langages de programmation, etc) Nombre d'états de la machine = 2^{M|P|} en théorie dans le pire des cas, acceptable en pratique (M=plus grande taille de membre droit)

SLR(1):

Ùn peu plus de grammaires « naturelles » que LR(0), mais toujours insuffisant Nombre d'états : pareil que pour LR(0) Taille des suivants : |N||T|

LR(1):


La très grande majorité des grammaires « naturelles » Nombre d'états : 2^{M|P|2^|T|} trop important

LALR(1): LookAhead LR

Simplification de la machine LR(1) pour rendre le nombre d'états acceptable Une grosse majorité de grammaires « naturelles »

LR(0), SLR(1), LR(1), ...





Grammaire LL(1) et non LALR(1)

 $S \rightarrow aA \mid bB$

A -> Ca | Db

B -> Cb | Da

D -> E

E -> ε

Décidable

Indécidable


Analyse LALR(1)

Idée : simplification de la machine LR(1) par

- fusion des états contenant exactement les mêmes productions avec le point à la même position (sans regarder les contextes droits associés aux productions)
- pour chaque pròduction, les contextes droits sont l'union des contextes droits de la production dans les états qui sont fusionnés

Machine LR(1) $X_{1} \rightarrow Y_{1} \bullet Y_{1} Y_{1}, E_{1}$ $X_{n} \rightarrow Y_{n} \bullet Y_{n} Y_{n}, E_{n}$ $X_{1} \rightarrow Y_{1} \bullet Y_{1} Y_{1}, E_{1} \cup E_{1}'$ $X_{2} \rightarrow Y_{1} \bullet Y_{1} Y_{1}, E_{1} \cup E_{1}'$ $X_{3} \rightarrow Y_{1} \bullet Y_{1} Y_{1}, E_{1}'$ $X_{4} \rightarrow Y_{1} \bullet Y_{1} Y_{1}, E_{1}'$ $X_{5} \rightarrow Y_{1} \bullet Y_{1} Y_{1}, E_{1}'$ $X_{6} \rightarrow Y_{1} \bullet Y_{1} Y_{1}, E_{1}'$ $X_{7} \rightarrow Y_{1} \bullet Y_{1} Y_{1}, E_{1}'$

- Il s'agit d'un raffinement de SLR(1), mais d'une stratégie plus grossière que LR(1)
- Le nombre d'états de la machine LALR(1) est celui de la machine LR(0)
- La machine LALR(1) peut aussi se construire sans construire la machine LR(1) (compliqué)



A partir de tout état, une seule action possible : la grammaire est LALR(1)

Analyse montante et AST

La suite des actions réalisées pendant une analyse montante correspond à un parcours en profondeur et post-fixe de l'arbre de dérivation :

- décalage (terminal) : passage au frère droit, visite d'une feuille
- réduction : passage au père après les fils, visite d'un nœud interne (non-terminal)
- On peut en profiter pour construire très facilement un AST, ou reconstruire l'arbre de dérivation en mémoire
 - En supposant qu'il existe un mécanisme qui permet de calculer et de retourner quelque chose pour chaque action, décalage ou réduction, qui permet, au moment où on dérive X->γ, de récupérer la valeur calculée pour chaque terminal et non-terminal de γ. Bison possède un tel mécanisme.

```
Grammaire : E -> E+E | n Analyse de 1+2
```

```
décalage par '1' r<-nouveau nœud(1) ; retourner r
réduction E->n retourner le nœud issu de l'analyse de n
décalage par '+' r<-nouveau nœud(+) ; retourner r
décalage par '2' r<-nouveau nœud(2) ; retourner r
réduction E->n retourner le nœud issu de l'analyse de n
réduction E->E+E r<-nouveau nœud dont les fils sont issus de l'analyse de E, de + et de E
```

Mécanismes de résolution de conflits

Les conflits peuvent être résolus en transformant la grammaire

- > peut être difficile
- peut rendre la grammaire compliquée, peu naturelle, et rendre difficile la construction de l'AST

Des mécanismes peuvent aussi être intégrés à l'analyse montante pour prioriser décalages et réductions en cas de conflit.

Exemple: E -> E+E | n

La machine LR a un état contenant E->E+E • et E->E • +E :

conflit S/R car + est dans les suivants de E+E

Si on souhaite + associatif à gauche, il faut privilégier la réduction sur le décalage, sinon l'inverse

attribuer des associativités aux terminaux permet de résoudre des conflits S/R

Exemple : $E \rightarrow E + E \mid E^*E \mid n$

La machine LR a un état contenant E->E+E • et E->E • *E :

conflit S/R car * est dans les contextes droits de E+E

Si on souhaite * prioritaire sur +, il faut privilégier le décalage sur la réduction, sinon l'inverse

attribuer des priorités aux terminaux permet de résoudre des conflits S/R

Mécanismes de résolution de conflits

Une grammaire ambiguë n'est pas LR

Un conflit R/R est souvent signe que la grammaire est mal écrite : il faut la refaire

Souvent, les analyseurs LR disposent de mécanismes de résolution de conflits S/R par priorité et associativité.

- on fixe priorité et associativité aux terminaux
- on en déduit des priorités pour les productions :
 priorité production = priorité du dernier terminal de la production
- > on peut aussi parfois définir explicitement une priorité pour les non-terminaux
- Résolution du conflit
 - on compare la priorité de la production par rapport à celle du terminal de décalage
 - si elle est supérieure, on réduit
 - > si elle est inférieure, on décale
 - > à priorité égale on regarde l'associativité
 - associativité à gauche on réduit
 - > associativité à droite on décale

Ces mécanismes permettent d'utiliser des grammaires non LR « naturelles » dans des analyseurs LR, comme par exemple E-> E+E | E*E | n

Traiter les erreurs

Il peut être simple de récupérer les erreurs de syntaxe dues à l'absence d'action de décalage sur le terminal en entrée.

Les analyseurs LR ont deux manières principales de traiter les erreurs :

- par insertion/suppression automatique de terminaux, pour tenter de récupérer l'erreur
 - Exemple : on lit (*3) pour E->(E). au moment de la lecture de *, l'analyseur attend un nombre ou une (. L'analyseur peut décider d'afficher le message « nombre attendu », insérer un terminal « nombre » dans le flot et continuer
- par utilisation d'un non-terminal *error* dans la grammaire
 - la grammaire prévoit les erreurs syntaxiques sur l'entrée par règles de la forme E -> (error)

signifie que si une erreur de syntaxe intervient après une '(', il faut

- abandonner la partie de l'analyse qui a eu lieu juste après le décalage par '('
 - > troncature de pile
- lire l'entrée jusqu'à une ')'
- reprendre l'analyse

Bison

Analyseur LR(1), LALR(1), GLR, ...

Principe:

Construit un analyseur LALR(1) à partir de la description d'une grammaire contenue dans un fichier texte (extension usuelle : .y)


Produit du code C implantant l'analyseur

L'analyseur récupère les terminaux un par un en appelant une fonction d'analyse lexicale int yylex() // Retourne un identifiant>0 de terminal, 0 si il n'y a plus rien à lire

Elle peut être écrite directement par le programmeur

Elle peut aussi être celle de flex !

Du code C peut être inséré dans les règles de grammaire : il sera exécuté au fur et à mesure des décalages et des réductions



Un premier exemple

```
#include <ctype.h>
 #include <stdio.h>
 int yylex();
 void yyerror (char const *);
%token NUMBER;
S: S E '\n' | S '\n' | E '\n' | '\n';
E: E'+' F | F;
F:F'*'T|T;
T: '(' E ')' | NUMBER;
int yylex() {
 int c:
 while ((c=getchar())!= EOF && isblank(c)) // eat spaces
 if(c == EOF)
  return 0; // Nothing left to read
 if ( isdigit(c) ) {
  while ( (c=getchar())!= EOF && isdigit(c) ) // eat other digits
  ungetc(c, stdin);
  return NUMBER;
 } else {
  return c;
```

```
void yyerror (char const *s) {
  fprintf(stderr, "%s", s);
}
```

```
bison expr.y
gcc -std=c11 -pedantic -Wall expr.tab.c
./a.out
1+2+3
4
*5
syntax error
```

Voir la machine générée : mode texte

```
option -v de bison
bison expr.y -v
génère aussi expr.output
```

Extrait

```
État 6
6 E: F.
7 F: F. '*' T
'*' décalage et aller à l'état 14
$défaut réduction par utilisation de la règle 6 (E)


État 7
8 F: T.
$défaut réduction par utilisation de la règle 8 (F)
```

Voir la machine générée mode graphique

option --graph de bison bison expr.y --graph génère aussi expr.dot

Pour ouvrir un fichier au format dot, on peut employer par exemple xdot

xdot



Voir ce que fait bison à l'exécution

```
%{
  #include <ctype.h>
  #include <stdio.h>
  int yylex();
  void yyerror (char const *);
  // Activer dynamiquement la trace
  int yydebug = 1;
  %}
  %token NUMBER;
  %%
  S: S E '\n' | S '\n' | E '\n' | '\n';
  E : E '+' F | F;
  F : F '*' T | T;
  T: '(' E ')' | NUMBER;
  %%
  ...
```

Compiler le code pour tracer : gcc -DYYDEBUG y.tab.c

```
Starting parse
Entering state 0
Reading a token: Next token is token NUMBER ()
Shifting token NUMBER ()
Entering state 1
Reducing stack by rule 10 (line 14):
 $1 = token NUMBER ()
-> $$ = nterm T ()
Stack now 0
Entering state 7
Reducing stack by rule 8 (line 13):
  $1 = nterm T()
\rightarrow $$ = nterm F'()
Stack now 0
Entering state 6
Reading a token: Next token is token '+' ()
Reducing stack by rule 6 (line 12):
$1 = nterm F ()
-> $$ = nterm E ()
Stack now 0
Entering state 5
Next token is token '+' ()
Shifting token '+' ()
Entering state 13
Reading a token: Next token is token NUMBER () Shifting token NUMBER ()
Entering state 1
Reducing stack by rule 10 (line 14):
  $1 = token NUMBER ()
-> $$ = nterm T ()
Stack now 0 5 13
Entering state 7
Reducing stack by rule 8 (line 13):
  $1 = nterm T()
\rightarrow $$ = nterm F'()
Stack now 0 5 13
Entering state 17
Reading a token: Next token is token '\n' ()
```

```
Reducing stack by rule 5 (line 12):
  $1 = nterm E()
 $2 = token '+' ()
 $3 = nterm F()
\rightarrow $$ = nterm E'()
Stack now 0
Entering state 5
Next token is token '\n' ()
Shifting token '\n' ()
Entering state 12
Reducing stack by rule 3 (line 10):
 $1 = nterm E()
  $2 = token '\n'()
-> $$ = nterm S ()
Stack now 0
Entering state 4
Reading a token: Now at end of input.
Shifting token $end ()
Entering state 9
Stack now 0 4 9
Cleanup: popping token $end ()
Cleanup: popping nterm S ()
```

Format d'un fichier bison

```
%{
    Code C
%}
Définitions bison

%%
production,; // Les productions peuvent être annotées par du code C
...
production,;
%%

Code C
```

Même exemple en utilisant flex

```
%{ /* expr2.l */
#include "expr2.tab.h"
%}
%option noyywrap
%%
[[:digit:]]+ return NUMBER;
[[:blank:]]
.\\n return yytext[0];
%%
```

```
Avec l'option -d, bison génère, en plus de expr2.tab.c, un fichier expr2.tab.h contenant entre autres les définitions C pour les tokens (terminaux) qu'il utilise bison -d expr2.y flex -D_POSIX_SOURCE -DYY_NO_INPUT --nounput expr2.I gcc -std=c11 -pedantic -Wall expr2.tab.c -c gcc -std=c11 -pedantic -Wall lex.yy.c -c L'option -ly permet d'utiliser le main de la bibliothèque bison Attention : pas le même comportement que le main par défaut de flex gcc expr2.tab.o lex.yy.o -ly
```

```
%{ /* expr2.y */
 #include <ctype.h>
 #include <stdio.h>
 int yylex();
 void yyerror (char const *);
%}
%token NUMBER
%%
S: S E '\n' | S '\n' | E '\n' | '\n';
\mathsf{E} : \mathsf{E}' + \mathsf{F} \mid \mathsf{F};
F:F'*'T|T;
T: '(' E ')' | NUMBER;
%%
void yyerror (char const *s) {
 fprintf(stderr, "%s", s);
```

```
Un Makefile s'impose
SHELL=/bin/sh
LEX=flex
YACC=bison
CC=acc
CFLAGS=-g -std=c11 -pedantic -Wall
LDFLAGS=-lv
# --nounput: ne génère pas la fonction yyunput() inutile
# -- DYY NO_INPUT: ne prend pas en compte la fonction input() inutile
# -D POSIX SOURCE: déclare la fonction fileno()
LEXOPTS=-D POSIX SOURCE -DYY NO INPUT --nounput
YACCOPTS=
PROG=expr2
$(PROG): lex.yy.o $(PROG).tab.o
     $(CC) $+ -0 $@ $(LDFLAGS)
lex.vv.c: $(PROG).I $(PROG).tab.h
     $(LEX) $(LEXOPTS) $<
lex.yy.h: $(PROG).l
     $(LEX) $(LEXOPTS) --header-file=$@ $<
$(PROG).tab.c $(PROG).tab.h: $(PROG).y lex.yy.h
     $(YACC) $(YACCOPTS) $< -d -v
%.o: %.c
     $(CC) $(CFLAGS) $< -c
clean:
     -rm $(PROG) *.o lex.yy.* $(PROG).tab.* *.err *.output *.out *.dot
```

Autre exemple

```
%{
                                                   bison expr3.y -v
 #include <ctype.h>
                                                   expr3.y: avertissement: 4 conflits par
 #include <stdio.h>
                                                        décalage/réduction [-Wconflicts-sr]
 int yylex();
                                                   Extrait de expr3.output
 void yyerror (char const *);
                                                   Etat 12 conflits: 2 décalage/réduction
                                                   Etat 13 conflits: 2 décalage/réduction
%}
%token NUMBER
                                                   ...
État 12
%%
ligne : ligne E '\n' | ligne '\n' | E '\n' | '\n';
                                                     5 E: E . '+' E
                                                     5 | E'+' E.
6 | E.'*' E
E : E '+' E | E '*' E | NUMBER;
%%
                                                      '+' décalage et aller à l'état 9
void yyerror (char const *s) {
                                                        décalage et aller à l'état 10
 fprintf(stderr, "%s", s);
                                                            [réduction par utilisation de la règle 5 (E)]
                                                            [réduction par utilisation de la règle 5 (E)]
                                                      $défaut réduction par utilisation de la règle 5 (E)
```

..

Levée des ambiguïtés : mécanisme de priorisation/associativité de bison

```
%{
 #include <ctype.h>
                                                 > +,-,*,/ sont tous déclarés associatifs à gauche
 #include <stdio.h>
                                                 + et – ont une priorité identique
 int yylex();
                                                 * et / ont une priorité identique
 void yyerror (char const *);
                                                 ▶ la priorité de + et – est inférieure à celle de * et /
%token NUMBER
%left '+' '-'
%left '*' '/'
%%
                                                         ordre croissant de priorité
ligne: ligne E '\n' | ligne '\n' | E '\n' | '\n';
E: E'+' E | E'*' E | E'-' E | E'/' E | NUMBER;
%%
void yyerror (char const *s) {
 fprintf(stderr, "%s", s);
                                    → 1+2+3 est analysé comme (1+2)+3
                                                                             [associativité à gauche de +]
                                      on favorise la réduction de E->E+E par rapport au décalage par +
                                    > 1+2-3 est analysé comme (1+2)-3
                                                                             [associativité à gauche de +]
                                      on favorise la réduction de É->E+E par rapport au décalage par -
                                    > 1+2*3 est analysé comme 1+(2*3)
                                                                             [priorité de * sur +]
                                      on favorise le décalage par * sur la réduction E->E+E
```

Levée des ambiguïtés : mécanisme de priorisation/associativité de bison

Pour attribuer des priorités/associativités aux terminaux :

- » %left : associativité à gauche
 - dans le conflit S/R on favorise R
- %right : associativité à droite
 - dans le conflit S/R on favorise S
- %nonassoc : pas d'associativité
 - Déclaration à bison que le conflit, même s'il existe dans la machine LALR(1), ne sera jamais utilisé à run-time.
 - Le conflit n'est plus indiqué par bison.
 - Si, au cours de l'exécution de la machine LALR(1), on se trouve dans l'état du conflit et que le prochain symbole d'entrée est celui du conflit, production d'une erreur de syntaxe
- %precedence : sert à déclarer une priorité sans fournir d'information d'associativité

Levée des ambiguïtés : mécanisme de priorisation/associativité de bison

Bison se sert des priorités des terminaux pour attribuer des priorités aux productions = priorité du terminal le plus à gauche dans son membre droit

Pour résoudre un conflit S/R, on compare la priorité de la production avec celle du terminal à suivre

plus forte : on réduitplus faible : on décale

Il est possible d'imposer à bison une priorité pour une production

```
%left '+' '-'
%left '*' '/'
%left OPUNAIRE
%%
E : E '+' E | E '-' E | E '*' E | E '/' E | '-' E %prec OPUNAIRE | '+' E %prec OPUNAIRE;
%%
```

lci, on déclare un terminal (factice, car jamais produit par l'analyseur lexical) OPUNAIRE, dont la priorité est plus forte que celle des autres opérateurs Le %prec dans la production E -> '-'E indique que cette production a la priorité la plus forte, ce qui favorise la réduction sur le décalage

Du code C dans les productions

- > Peut apparaître n'importe où, mais pour l'instant on en mettra seulement en fin de production
- Le code C est exécuté quand le dans la production est juste devant le code
- > Donc, si le code est en fin de production, au moment de la réduction de la production

```
En changeant un peu les exemples précédents %left '+' '-'
%%
ligne : ligne E '\n' | ligne '\n' | E '\n' | '\n';
E : E '+' E { printf("Oh, une somme !\n"); }
| E '-' E { printf("Ah, une différence !\n"); }
| NUMBER { printf("Tiens, un nombre !\n"); }
;
%%

En changeant l'associativité :
%right '+' '-'
```

Compilation, exécution: 1+2-3
Tiens, un nombre!
Tiens, un nombre!
Oh, une somme!
Tiens, un nombre!
Ah, une différence!

Compilation, exécution: 1+2-3
Tiens, un nombre!
Tiens, un nombre!
Tiens, un nombre!
Ah, une différence!
Oh, une somme!

Attribut d'un lexème

La fonction yylex() retourne

- > la catégorie de la prochaine unité lexicale sous la forme d'un entier (int) >0
- > 0 s'il n'y a plus rien à lire

L'attribut de l'unité lexicale est stocké dans une variable globale yylval de type YYSTYPE

- par défaut YYSTYPE est int
- il peut être changé par
 - un typedef (à éviter)
 - un #define (à éviter)
 - %define api.value.type
 - %union quand YYSTYPE doit être une union

Au niveau de bison, le ième élément du membre droit d'une production a le type YYSTYPE et la valeur \$i. Quand c'est un terminal, \$i est l'attribut de l'unité lexicale.

Fixer l'attribut d'un lexème dans flex

```
%{
 #include <math.h>
 #include "expr3.tab.h" // Contient la définition de YYSTYPE à partir de bison
 void string to double(double *v, const char *s);
%option noyywrap
%%
[[:digit:]]+ { string to double(&yylval, yytext); return NUMBER; }
[[:blank:]]
                return yytext[0];
.|\n
%%
void string to double(double *v, const char *s) {
 char *p;
 errno = 0:
 v = strtod(s, &p);
 if (*p!= '\0' || (errno == ERANGE && (*v == HUGE VALF || *v == -HUGE VALF))){
  fprintf(stderr, "Error converting string to double\n");
  exit(EXIT_FAILURE);
```

Les valeurs des terminaux et nonterminaux dans bison

```
%{
 #include <stdio.h>
 int yylex();
 void yyerror (char const *);
%define api.value.type {double}
%token NUMBER
%right '+' '-'
%%
ligne : ligne E '\n' | ligne '\n' | E '\n' | '\n';
E : E '+' E {
 printf("Oh, une somme (\%f+\%f=\%f)!\n", $1, $3, $1+$3);
 $$=$1+$3:
 printf("Ah, une différence (%f-%f=%f)!\n", $1, $3, $1-$3);
 $$=$1-$3:
 NUMBER {
 printf("Tiens, un nombre %f!\n", $1);
 $$=$1:
void yyerror (char const *s) {
 fprintf(stderr, "%s", s);}
```

Les valeurs des terminaux et nonterminaux dans bison

Les terminaux et non-terminaux peuvent avoir plusieurs types : en C, YYSTYPE devient alors une union de types.

Directive bison:

Quand l'union contient un type non standard du C, on définit ce type dans un fichier .h, qu'on inclut dans les fichiers bison et flex

Construction de l'AST

```
#ifndef _SIMPLE_TREE_TYPES_H
#define _SIMPLE_TREE_TYPES_H

typedef enum { NO_OP, ADD_OP, SUB_OP, MUL_OP, DIV_OP } op_type;

typedef struct _node {
    struct _node *left, *right;
    op_type op;
    double val;
} node_type;

#endif
```

Construction de l'AST

```
%{
 #include <stdlib.h>
 #include <stdio.h>
 #include "simpleTreeTypes.h"
 int yylex();
 void yyerror (char const *);
 static node type *node_alloc(const node_type *);
 static void infix node printer(FILE *out, const node type *p);
%}
%union {
 double dValue:
 node type *nValue;
%token NUMBER
%left '+' '-'
%left '*' '/'
%type<dValue> NUMBER
%type<nValue> E
%%
sligne: sligne ligne | %empty;
ligne : E '\n' {
 infix_node_printer(stdout, $1);
| ˈ\n'
```

```
E: E'+' E {
    node_type n = {
        .left=$1, .right=$3,
        .op=ADD_OP, .val=0.0 };
    $$ = node_alloc( &n );
}
...
| NUMBER {
    node_type n = {
        .left = NULL, .right = NULL,
        .op = NO_OP, .val = $1 };
    $$ = node_alloc( &n );
};

%%

void yyerror (char const *s) {
    fprintf(stderr, "%s", s);
}
```

Construction de l'AST

```
%{
 #include <math.h>
 #include "simpleTreeTypes.h" // Contient la définition du type des nœuds
#include "simpleTree.tab.h" // Contient la définition de YYSTYPE à partir de bison
 void string to double(double *v, const char *s);
%}
%option noyywrap
%%
[[:digit:]]+ { string to double(&yylval.dValue, yytext); return NUMBER; }
[[:blank:]]
.|\n
        return yytext[0];
%%
void string to double(double *v, const char *s) {
 char *p;
 errno = 0:
 ^*v = strtod(s, &p);
 if (*p!= '\0' || (errno == ERANGE && (*v == HUGE VALF || *v == -HUGE VALF))) {
  fprintf(stderr, "Error converting string %s to double\n", s);
  exit(EXIT_FAILURE);
```

Analyse sémantique

Elle donne une couche de sens à ce qui a été syntaxiquement analysé.

```
Détection d'autres erreurs :
Typage statique
     int add(int x, int y);
     void f(void) {
          bool b:
          add(b); /* Syntaxiquement correct, mais le nombre d'arguments est incorrect */
                    /* Syntaxiquement correct, mais l'argument n'est pas du bon type
                    /* Syntaxiquement correct, mais b est utilisé avant d'avoir été initialisé */
                   /* Syntaxiquement correct, mais valeur de retour non utilisée
```

- Gestion de la portée des identificateurs
- Rejet de constructions syntaxiquement correctes mais auxquelles on ne peut attribuer de sens
 Détection de variables non initialisées avant utilisation
- Détection de code inaccessible (code mort)

Préparation finale des structures de données avant la phase de génération de code

Certaines étapes de l'analyse sémantique peuvent être intégrées à l'analyse syntaxique. D'ailleurs, beaucoup de phases de compilation postérieures à l'analyse syntaxique peuvent être intégrées à l'analyse syntaxique (traduction dirigée par la syntaxe)

Traduction dirigée par la syntaxe

Pour plus d'efficacité et de simplicité, elle mélange la phase d'analyse syntaxique avec des phases qui lui sont postérieures : analyse sémantique, production de code, etc.

Ajoute des actions portant sur les attributs des terminaux et des non-terminaux Les actions sont exécutées au fur et à mesure de l'analyse syntaxique

Analyse descendante :

Dans le cas d'une programmation récursive, les paramètres des fonctions d'analyse servent à transmettre des attributs le retour de ces fonctions aussi Dans le cas d'une programmation par table/pile les attributs sont placés sur la pile

Analyse ascendante:

Les attributs sont des valeurs associées aux terminaux et aux non-terminaux lls sont placés dans la pile d'exécution Mécanisme implanté par bison par les \$\$ et \$i vus précédemment

Définition dirigée par la syntaxe

Règles sémantiques : code à exécuter par le compilateur pour réaliser son travail

Les règles sémantiques impliquent des dépendances entre les attributs

- -> ordre d'évaluation des règles sémantiques
- -> l'application des règles sémantiques permet effectivement le calcul des attributs


Les règles sémantiques du compilateur sont partiellement ordonnées

Grammaire attribuée : CFG dans laquelle chaque élément X de TUN a des attributs X.a,,...,X.a, qui peuvent être synthétisés ou hérités

Attributs synthétisés et hérités

Attribut synthétisé: dans une production A->γ associée à un nœud N d'un arbre de dérivation, un attribut synthétisé de A en membre gauche est défini par une règle sémantique de N qui ne dépend que des autres attributs dans N et dans ses fils

Attribut hérité: dans une production X->γΥγ' associée à un nœud N d'un arbre de dérivation, un attribut hérité de Y en membre droit est défini par une règle sémantique du père de N qui ne dépend que des autres attributs dans N, dans son père et dans ses fils



Attribut synthétisé : exemple

Définition d'une calculette dirigée par la syntaxe

Un attribut synthétisé *val* par terminal et non-terminal de chaque production (on numérote les terminaux et non-terminaux dans chaque production pour lever les ambiguïtés de nommage. Le membre gauche n'a pas de numéro.)

Production

Règle sémantique

 $E \rightarrow E + T$

 $E.val := E_1.val + T.val$

E -> T

E.val := T.val

T -> T * F

T.val := T₁.val * F.val

 $T \rightarrow F$

T.val := F.val

F -> (E)

F.val := E.val

F -> nombre

F.val := nombre.val

nombre.val est la valeur du nombre

Les terminaux ne peuvent avoir que des attributs synthétisés (typiquement, par l'analyseur lexical)

Attribut hérité: exemple

Déclaration de variables en C

Un attribut hérité *val* par terminal et non-terminal de chaque production (on numérote les terminaux et non-terminaux dans chaque production pour lever les ambiguïtés de nommage. Le membre gauche n'a pas de numéro.)

 $D \rightarrow T L$ L.type := T.type

T -> **int** T.type := int.type (=entier)

T -> **float** T.type := float.type (=réel)

 $L \rightarrow L$, id L_1 .type := L.type (qui est donc fixé par le nœud père)

id.type := L.type (qui est donc fixé par le nœud père)

L -> **id** id.type := L.type (qui est donc fixé par le nœud père)

L'attribut L.type est hérité

Attributs hérités et synthétisés

Les attributs hérités sont utiles quand la structure des AST diffère de celle des arbres de dérivation

Production	Règles sémantiques
------------	--------------------


 $T \rightarrow FT'$ T'.val := F.val

T.val:=T'.val

T'.val:=T,'.val

 $T' \rightarrow \varepsilon$ T'.val:=T'.val

 $F \rightarrow n$ F.val:=entier(n)



Évaluation des attributs d'une grammaire attribuée

Si tous les attributs sont synthétisés : pas de problème ! Donné un arbre de dérivation T, n'importe quel parcours feuilles -> racine de T convient

Si des attributs sont hérités, des dépendances circulaires peuvent exister

Production Règle sémantique

 $A \rightarrow B$ A.s = B.i

B.i:=A.s+1

D'une manière générale, il est algorithmiquement difficile de dire, donnée une grammaire attribuée, s'il existe un arbre de dérivation avec des circularités d'évaluations.

Heureusement, pour certaines formes de grammaire, cette question se décide facilement.

Grammaire S-attribuée

Tous les attributs sont synthétisés.

Exemple : (on suppose qu'on dispose d'un type de listes et d'opérations associées)

```
\begin{array}{lll} L \rightarrow [\ S\ ] & L.val \coloneqq S.val \\ L \rightarrow [\ ] & L.val \coloneqq emptyList() \\ S \rightarrow S\ ,\ e & S.val \coloneqq S_1.val.addLast(e) \\ S \rightarrow e & S.val \coloneqq valeur(e) \end{array}
```

Autre exemple :

```
S \rightarrow E\$ S.val:= E.val E \rightarrow T+E E.val:=T.val+E.val E \rightarrow T E.val:=T.val T \rightarrow n T.val:=valeur(n)
```

Grammaire S-attribuée et analyse LR

L'analyse LR est naturellement adaptée à l'utilisation des attributs synthétisés. La pile de l'analyseur LR peut servir au calcul des attributs.

```
Pile
                                               Action
Entrée
1+2+3$ 0
+2+3$ 013
                                               déc. 0 par 1
+2+3$ 0T(val=1)4
                                               red. T->n
2+3 OT(val=1)4+5
                                               déc. 4 par +
+3$
                                               déc. 5 par 2
       0T(val=1)4+523
+3$
        0T(val=1)4+5T(val=2)4
                                               red. T->n
        0T(val=1)4+5T(val=2)4+5
3 $ $ $ $ $ $ $
                                               déc. 4 par +
        0T(val=1)4+5T(val=2)4+533
                                               déc 5 par 3
        0T(val=1)4+5T(val=2)4+5T(val=3)4
                                               red. T->n
        0T(val=1)4+5T(val=2)4+5E(val=3)6
                                               red. E->T
        0T(val=1)4+5E(val=5)6
                                               red. E->T+E
        0E(val=6)1
                                               red. E->T+E
        0E(val=6)1$2
                                               déc. 1 par $
Acceptation, car il faut réduire S->E$!
```

Grammaire L-attribuée

```
    tout attribut est synthétisé ou hérité;
    dans une règle A -> X<sub>1</sub> X<sub>2</sub> ... X<sub>n</sub>, si un attribut X<sub>i</sub>.val est calculé dans l'action associée,
    il ne dépend que des attributs des variables X<sub>1</sub> X<sub>2</sub> ... X<sub>i-1</sub> (qui sont à gauche de X<sub>i</sub>, d'où le L)
    ou des attributs hérités de A
```

Le calcul des attributs peut être réalisé par un parcours en profondeur des arbres de dérivation

```
parcours(nœud n) {
    pour chaque fils m de n {
        calculer les attributs hérités de m ;
        parcours(m) ;
    }
    calculer les attributs synthétisés de n ;
}
```

Grammaire L-attribuée

Exemple : la grammaire suivante est L-attribuée

Production Règles sémantiques


 $T \rightarrow FT'$ T'.val := F.val

T.val:=T'.val

T'.val =T,'.val

 $T' \rightarrow \varepsilon$ T'.val:=T'.val

 $F \rightarrow n$ F.val:=entier(n)



5

3

Exemple : n'importe quelle grammaire contenant la règle suivante n'est pas L-attribuée

$$A \rightarrow BC$$
 A.val:=B.val

B.val:=f(C.val, A.val)

Grammaire L-attribuée et analyse LL

Une implantation récursive d'analyse LL est naturellement adaptée pour les grammaires LL L-attribuées. Une implantation par table peut imiter l'implantation récursive. Les paramètres et retour de fonction peuvent servir à la transmission des attributs hérités et synthétisés.

```
bool analyse_E(const char **s, int inherited, int *synthetised) {
    switch (**s) {
        case '0': case '2': case '3': case '4':
        case '5': case '6': case '8': case '9':
        return analyse_T(s, 0, synthetised) && analyse_Ep(s, *synthetised, synthetised); /* E -> TE' */
        case '(':
        return analyse_T(s, 0, synthetised) && analyse_Ep(s, *synthetised, synthetised); /* E -> TE' */
        default: return false;
    }
}
bool analyse_Ep(const char **s, int inherited, int *synthetised) {
        switch (**s) {
        case '+': ++*s; return analyse_T(s, 0, synthetised) && analyse_Ep(s, inherited + *synthetised, synthetised); /* E' -> +TE' */
        case '+': ++*s; return analyse_T(s, 0, synthetised) && analyse_Ep(s, inherited - *synthetised, synthetised); /* E' -> -TE' */
        case '): case '$': *synthetised = inherited; return true; /* E' -> Epsilon */
        default: return false;
}
```

$$\begin{array}{ll} S \rightarrow E \$ & T \rightarrow FT' \\ E \rightarrow TE' & T' \rightarrow *FT' \mid /FT' \mid \epsilon \\ E' \rightarrow +TE' \mid -TE' \mid \epsilon & F \rightarrow n \mid (E) \end{array}$$

Schéma de traduction dirigée par la syntaxe

Grammaire contenant des actions dans son membre droit.

Les actions (on utilisera une syntaxe « à la C ») peuvent apparaître à n'importe quelle condition, mais

- > si une action calcule un attribut d'un non-terminal du membre droit, elle doit être placée avant lui
- > si une action utilise un attribut d'un non-terminal du membre droit, elle doit être placée après lui

```
Exemple : le schéma suivant est mal formé S \rightarrow A A \{ A_1.val = 1 ; A_2.val = 2 ; \} A \rightarrow a \{ affiche A.val ; \}
```

Celui-ci est correct

```
S \rightarrow \{A_1.val = 1;\} A \{A_2.val = 2;\} A
A -> a { affiche A.val;}
```

Un schéma de traduction peut toujours s'implanter en construisant les arbres de dérivation et en les parcourant en profondeur.

Implantation des schémas de traduction

Un schéma de traduction peut toujours s'implanter en construisant les arbres de dérivation et en les parcourant en profondeur fils gauche d'abord.

On peut aussi utiliser facilement les implanter sans construire explicitement d'arbre de dérivation :

- pendant une analyse LL :
 - dans une implantation récursive, les actions s'insèrent facilement aux endroits appropriés dans le code des fonctions associées aux productions
- > pendant une analyse LR:
 - > on remplace Z-> γ {actions} γ ' par Z-> γ X γ ' avec X-> ϵ {actions}.
 - les attributs hérités dans γ' et provenants de {actions} seront alors des attributs synthétisés de X : ils sont dans la pile
 - les attributs hérités en provenance du père peuvent poser difficulté (insurmontable)

Implantation des schémas de traduction : analyse LR

```
\begin{array}{ll} D \rightarrow T \; \{ \; L.type = T.type \; ; \} \; L \; '\ n' \\ T \rightarrow int \; \{ \; T.type = integer \; ; \} \\ T \rightarrow float \; \{ \; T.type = float \; ; \} \\ L \rightarrow L, \; id \; \{ \; add\_symbol\_table(id.val, \; L.type); \} \\ L \rightarrow id \; \{ \; add\_symbol\_table(id.val, \; L.type); \} \\ L \rightarrow id \; \{ \; add\_symbol\_table(id.val, \; L.type); \} \\ L \rightarrow id \; \{ \; add\_symbol\_table(id.val, \; STACK(-4).type); \} \\ L \rightarrow id \; \{ \; add\_symbol\_table(id.val, \; STACK(-2).type); \} \\ \end{array}
```

```
int x,y n
x,y n
                  0int1
x,y n
                  0 < T, int > 4
                  0 < T, int > 4 < A, int > 6
x,y\n$
,y\n$
                  0 < T, int > 4 < A, int > 6x7
                  0 < T, int > 4 < A, int > 6L8
,y\n$
                  0<T,int>4<A,int>6L8,10
y\n$
\n$
\n$
$
$
                  0<T,int>4<A,int>6L8,10y11
                  0 < T, int > 4 < A, int > 6L8
                  0<T,int>4<A,int>6L8\n9
                  0D3
                  0D3$5
Acceptation
```

État 1

2 D: T @1 L '\n'

Etat 8

2 D: T @1 L '\n'

Etat 8

2 D: T @1 L '\n'

Etat 9

2 D: T @1 L '\n'

Etat 10

Send

R1

Acc

Etat 8

2 D: T @1 L '\n'

Etat 8

2 D: T @1 L '\n'

Etat 9

2 D: T @1 L '\n'

Etat 10

Stat 11

Stit 1','''x'

Etat 11

\$0, \$-1, \$-2 : on remonte dans la pile. Attention : bison ne peut pas typer ce qu'il va y trouver ! (au programmeur de le faire correctement !)

```
decl: type { $<type>$=$1 ; } id list '\n'
type : INT { $$=INT_TYPE ; }
| FLOAT { $$=FLOAT_TYPE ; }
id_list: id_list',' ID { add_symbol_table($3, $<type>0); }
ID
                     { add symbol table($3, $<type>0); }
                                                     Attention : dans le code de @1
est transformé par bison en
                                                     $$ est relatif à @1
                                                     Comme la règle @1 n'est pas typée,
decl: type @1 id list \n'
                                                         il faut explicitement y typer $$
                                                     $1 a la même signification qu'avant
la transformation!
id_list : id_list ',' ID { add_symbol_table($3, $<type>0); }
                     { add symbol table($3, $<type>0); }
 ID
```

```
La génération de règles automatiques @n peut amener des conflits
bloc : { code de préparation pour les déclarations } '{' decls instrs '}'
| '{' instrs '}';

Conflit : faut-il exécuter le code ou pas quand le prochain caractère est '{' ?

Solution : toujours l'exécuter
bloc : { code de préparation pour les déclarations } '{' decls instrs '}'
| { code de préparation pour les déclarations } '{' instrs '}';
mais ça ne fonctionne pas car bison génère deux règles @ différentes

Le programmeur doit le faire lui-même :
bloc : code '{' decls instrs '}'
| code '{' instrs '}';
code : % empty { code de préparation pour les déclarations } ;
```

```
Pile
Entrée
                                                 $1
int x,y n
x,y n
             0int1
x,y\n$
             0<tvpe,INT TYPE>4
x,y n
             0<tvpe.INT TYPE>4<@1.INT TYPE>6
                                                               Réduction id list -> ID
             0<type,INT TYPE>4<@1,INT TYPE>6x7
,y\n$
             0<type,INT TYPE>4<@1,INT TYPE>6id list8
,y\n$
v\n$
             0<type,INT TYPE>4<@1,INT TYPE>6id list8,10
                                                              Réduction id list -> id list ',' ID
\n$
             0<type,INT_TYPE>4<@1.INT_TYPE>6id_list8
\n$
             0<type,INT_TYPE>4<@1,INT_TYPE>6id_list8\n9
                                                                $3
             0decl3
             0decl3$5
Acceptation
                                                  $1
                                         $0
```

Priorité des opérateurs en C

Opérateur	Symbole	Exemple	Assoc.
Indexation		t[i][j]	
Accès struct.	>	c.reel	->
Appel fct.	()	fact(30U)	
Adresse	&	&v	
Déréférecmnt.	*	*p	
Taille objets	sizeof	sizeof(int)	
Transtypage	()	(float)4	
Nég. Logique	!	!b	<-
Cplt à un	~	~0022	
pl/neg unaires	+ -	+1 -1	
pré/post inc.	++	++i i++	
pré/post dec.		i i	

+

Priorité

Priorité des opérateurs en C

Opérateur	Symbole	Exemple	Assoc.
Produit	*	a*b	->
div/modulo	/ %	a/b a%b	
somme/diff.	+ -	a+b a-b	->
Décalages	<< >>	a<<1 a>>1	->
Ordre	< <= => >	a <b< td=""><td>-></td></b<>	->
égalité/diff.	== !=	a==0	->
Et bit à bit	&	a&0022	->
XOR bit à bit	٨	a^0022	->
OU bit à bit		a 0022	->
ET logique	&&	a&&b	->
OU logique		a∥b	->
expr. cond.	?:	x>0 ? x: -x	<-
affectation	=	a=3	<-
affect. étendue	+= -=	a <<= 3U	
expr. comp.	1	i=2, j=6	->

Environnement d'exécution

```
Mécanisme final d'exécution du programme stockage des données représentation des données gestion des données accès registre, tas, pile, zone globale, zone des constantes fonctionnalités instruction sémantique d'exécution (effets sur l'environnement) fonctions passage des arguments appel valeur de retour fonctions de la bibliothèque sémantique
```

Rôle du compilateur

implantation des abstractions du langage source dans l'environnement d'exécution traduction du stockage des données traduction des fonctionnalités du langage source

Typage

L'analyse de types fait partie de l'analyse sémantique

Le système de typage sert à :

- vérifier que les opérations faites sur les objets sont bien autorisées
- calculer la place nécessaire à la représentation des données en mémoire

Il peut être spécifié par des schémas de traduction

Il peut être

- statique : les opérations de typage sont réalisées par le compilateur.

Elles garantissent une exécution correcte (en ce qui concerne les types)

Le langage est souvent déclaratif

Difficultés de réutilisation de code

Permet des changements de type automatiques réalisées par le compilateur (gain de temps)

Exemples: C, C++, Java

- dynamique : les opérations de typages sont effectuées pendant l'exécution du programme Implique des surcoûts dans les temps d'exécution et l'espace mémoire utilisés

Permet au programmeur de n'avoir qu'une connaissance partielle des types (souplesse)

Exemples : ocaml, Java

- mixte : combine les deux approches

Exemple: Java

Types

Un type définit

- un ensemble de valeurs
- pour certains types, une représentation (donc une taille) pour les valeurs

Des opérations permettent de manipuler les valeurs

Ils sont

- fournis par le langage
- définis par l'utilisateur

et peuvent être combinés en utilisant des constructeurs de types

Types de base en C:

- void (type spécial), int, float, double, char, ...


Constructeurs de types en C :

- t * : pointeur sur t
- t[] : tableau de t
- union : union de types
- struct : produit de types
- (): fonction

Expression de types

```
struct a {
    int (*f)(struct a *);
    int (*(*t[12])(struct a))(double);
}

Représentation par arbre
```



Expression de types

```
struct a {
                                                                  Représentation par DAG : on s'arrête en revenant au tableau
     int (*f)(struct a *);
     int (*(*t[12])(struct a))(double);
                                                                        struct
  int
 char
 float
                                                                                                       12
                                                 fonction
 double
  struct a
                                                                                       fonction
                                                                          fonction
```

Expression de types

```
Représentation par graphe :
struct a {
                                                               on continue après le tableau (en le
    int (*f)(struct a *);
    int (*(*t[12])(struct a))(double);
                                                               court-circuitant)
                                                                struct
 int
 char
 float
                                                                                           12
                                            fonction
 double
 struct a
                                                                             fonction
                                                                 fonction
```


Équivalences de types

```
Équivalence structurelle : équivalence des graphes représentant les types (en posant
         que la table est court-circuitée)
    struct a { int a ; } ~ struct b { int a ; }
Équivalence par nommage : équivalence des DAG
    struct a { int a ; } ≁ struct b { int a ; }
    Exemple du C
         struct a { int a ; } v1 ;
         struct b { int a ; } v2 ;
         v1 = v2; // Erreur : types incompatibles
    Attention aux synonymes!
         Exemple du C
             struct a { int a; };
             typedef struct a ap ; // ap et struct a sont la même entrée dans la table des types
             struct a v1;
             ap v2;
             v1 = v2; // Correct
```

Calcul d'un arbre/DAG/graphe pour le type

Exemple du C : int *t[5][3]

t est un tableau de 5 tableaux de 3 pointeurs sur int
[] est prioritaire sur *



Arbre pour le type

Contrôle de type Un exemple simple

```
decls: decls decl | decl ;
decl: type ID ':' { add symbol table($2,$1); }
type:
INT
                                { $$ = get_type_node(INT_TYPE) ; }
                                 $$ = get_type_node(BOOLEAN_TYPE);}
 BOOLEAN
 ARRAY OF type 'I' NUMBER 'I'
                                { $$ = new_type_node(ARRAY_TYPE) ; $$->size = $5 ; $$->fg = $3 ; }
                                 $$ = new_type_node(POINTER_TYPE); $$->fg = $2;}
 FUNCTION type TO type
                                { $$ = new_type_node(FUNCTION_TYPE) ; $$->fg = $2 ; $$->fd = $4 ; }
instrs: instrs instr | instr :
IF expr THEN instr ELSE instr ';' { if (!equiv_type( $2, get_type_node(BOOLEAN_TYPE) )) erreur ; }
                                if (!equiv_type( $2, get_type_node(BOOLEAN_TYPE) )) erreur ; }
IF expr THEN instr ';'
                                if (!equiv_type( $2, get_type_node(BOOLEAN_TYPE) )) erreur ; i
WHILE expr THEN instr ':'
ID AFF expr ';'
                                symbol_table_entry *ste; if ( (ste = get_symbol_table( $1 )) == NULL ) erreur;
                                if (!equiv type( ste->type, $3 )) erreur : }
TRUE
                { $$ = get_type_node(BOOLEAN_TYPE) ; }
                    [$$ = get type node(BOOLEAN TYPE);}
FALSE
                 $$ = get type node(INT TYPE);}
 NUMBER
                 symbol_table_entry *ste ; if ( (ste = get_symbol_table( $1 )) == NULL ) erreur else $$ = ste->type ; }
 ID
                { if (!equiv_type($1, $3)) erreur else $$ = get_type_node(BOOLEAN_TYPE); }
 expr EQ expr
                { if ($1->type!= FUNCTION TYPE | !equiv type($3, $1->fg) ) erreur else $$ = $1->fd; }
 expr '(' expr ')'
                { if ($1->type != ARRAY_TYPE || ! equiv_type($3), get_type_node(INT_TYPE) ) erreur else $$ = $1->fg;}
 expr '[' expr ']'
 '*' expr
                { if ($2->type!= POINTER TYPE) erreur else $$ = $2->fg ; }
```

prog: decls instrs:

Conversion de type

v :t -> v' :t'

Trouver, dans le type t', une valeur v' « correspondant » à v de type t

Implique souvent (mais pas toujours) un changement de représentation. Peut impliquer aussi un changement de la valeur.

Promotion: conversion implicite.

But : normaliser la manipulation de certaines catégories de données par la machine Ne devrait pas engendrer de perte de données.

Conversion implicite : réalisée automatiquement par le compilateur.

Ne devrait pas engendrer de perte de données Ça n'est pas le cas en C et en Java, par exemple

Conversion explicite : le programmeur doit indiquer sa volonté de convertir (et donc, qu'il sait qu'il peut y avoir perte de données)

Ne pas confondre conversion et sous-typage. En Java par exemple // A est un super-type de B

A a = new B(); // Aucune conversion

B b = (B) a; // Aucune conversion : le programmeur indique juste au compilateur qu'il sait // que la référence a désigne un objet de type B.

Promotion : Exemple de la promotion entière en C et en Java

Plusieurs types d'entiers : char, short, int (et pour chacun, un type *unsigned* en C)

En termes ensemblistes, char \subseteq int, short \subseteq int

Le type int étant le type « naturel » des entiers pour la machine, la somme int*int -> int est la plus efficace

Plutôt que d'avoir une somme pour chaque combinaison de types possibles :

char*char -> char, short*short -> short, int*int -> int

on en utilise une seule:

int*int -> int

Il faut donc convertir les arguments en int avant de réaliser la somme.

La conversion est automatique pour ne pas alourdir la syntaxe des programmes

L'exécution de la somme est efficace, mais il faut réaliser la conversion de ses opérandes avant

Promotion:

Exemple de la promotion entière en C et en Java

```
En C:
(signed+unsigned)(char+short int)
                                                               int+unsigned int
                                              Promotion entière
Si int contient le type d'origine, alors conversion en int, sinon en
unsigned int
La promotion entière est donc machine dépendante
En Java:
short s = 5;
                       // Erreur à la compilation:
S = S + S:
                       // Explicit cast needed to convert int to short.
System.out.println(s + s);
                               // Affiche 10. C'est System.out.println(int) qui est appelée
                                // Correct (affectation étendue)
S += S;
```

Conversion implicite : exemple en C

```
#include <stdlib.h>
                                                  Long double
#include <stdio.h>
                                                                   Les petits types d'entiers (char, short)
                                                                   subissent la promotion entière
                                                   Double
unsigned f(unsigned int u) {
 return u;
                                                    Float
                                                                   L'utilisation des unsigned rend la
                                                                   conversion machine-dépendante
int main(int argc, char *argv[]) {
                                                Unsigned long int
 unsigned int u = argc; // 1
 printf("%u", argc);
                                            Long int Long int Unsigned int
 f(argc);
 return EXIT_SUCCESS;
                                           Unsigned int

    Si long int contient unsigned int

gcc -std=c11 -pedantic -Wall -> OK
                                                     Int


    Sinon

gcc -std=c11 -pedantic -Wall -Wconversion
     -> Warnings pour 1 et 3
```

Dangereux :

perte de données possible
trop difficile à bien maîtriser

Conversion implicite en Java



Consiste à avoir plusieurs opérateurs (resp. fonctions, méthodes) dénotés par le même symbole, mais avec des types différents.

Le choix de l'opérateur (resp. de la fonction, méthode) dépend du contexte d'utilisation.


Exemples:

```
System.out.println(1); // C'est System.out.println(int) qui est appelée
System.out.println('c'); // C'est System.out.println(char) qui est appelée
```

```
1+2; // Somme de deux entiers : calcule un entier
1.0+2.0; // Somme de deux réels (opération différente de la première) : calcule un réel
```

Opérations de produit :

Deux types (entiers e, complexes c), trois produits : e*e->e, c*c->c, e*e->c



- Une remontée récursive pour calculer les types possibles Si pas unicité du type possible à la racine : erreur Descente récursive pour fixer les types

- Si pas unicité erreur

Consiste à avoir plusieurs opérateurs (resp. fonctions, méthodes) dénotés par le même symbole, mais avec des types différents.

Le choix de l'opérateur (resp. de la fonction, méthode) dépend du contexte d'utilisation.


Exemples:

System.out.println(1); // C'est System.out.println(int) qui est appelée System.out.println('c'); // C'est System.out.println(char) qui est appelée

1+2; // Somme de deux entiers : calcule un entier 1.0+2.0; // Somme de deux réels (opération différente de la première) : calcule un réel

Opérations de produit :

Deux types (entiers e, complexes c), trois produits : e*e->e, c*c->c, e*e->c



- 1) Une remontée récursive pour calculer les types possibles
- 2) Si pas unicité du type possible à la racine : erreur
- 3) Descente récursive pour fixer les types
- Si pas unicité erreur

Consiste à avoir plusieurs opérateurs (resp. fonctions, méthodes) dénotés par le même symbole, mais avec des types différents.

Le choix de l'opérateur (resp. de la fonction, méthode) dépend du contexte d'utilisation.


Exemples:

System.out.println(1); // C'est System.out.println(int) qui est appelée System.out.println('c'); // C'est System.out.println(char) qui est appelée

1+2; // Somme de deux entiers : calcule un entier 1.0+2.0; // Somme de deux réels (opération différente de la première) : calcule un réel

Opérations de produit :

Deux types (entiers e, complexes c), trois produits : e*e->e, c*c->c, e*e->c



- 1) Une remontée récursive pour calculer les types possibles
- 2) Si pas unicité du type possible à la racine : erreur
- 3) Descente récursive pour fixer les types
- 4) Si pas unicité erreur

Consiste à avoir plusieurs opérateurs (resp. fonctions, méthodes) dénotés par le même symbole, mais avec des types différents.

Le choix de l'opérateur (resp. de la fonction, méthode) dépend du contexte d'utilisation.


Exemples:

System.out.println(1); // C'est System.out.println(int) qui est appelée System.out.println('c'); // C'est System.out.println(char) qui est appelée

1+2; // Somme de deux entiers : calcule un entier 1.0+2.0 ; // Somme de deux réels (opération différente de la première) : calcule un réel

Opérations de produit :

Deux types (entiers e, complexes c), trois produits : e*e->e, c*c->c, e*e->c



- 1) Une remontée récursive pour calculer les types possibles
- 2) Si pas unicité du type possible à la racine : erreur
- 3) Descente récursive pour fixer les types
- 4) Si pas unicité erreur

Consiste à avoir plusieurs opérateurs (resp. fonctions, méthodes) dénotés par le même symbole, mais avec des types différents.

Le choix de l'opérateur (resp. de la fonction, méthode) dépend du contexte d'utilisation.


Exemples:

System.out.println(1); // C'est System.out.println(int) qui est appelée System.out.println('c'); // C'est System.out.println(char) qui est appelée

1+2; // Somme de deux entiers : calcule un entier 1.0+2.0 ; // Somme de deux réels (opération différente de la première) : calcule un réel

Opérations de produit :

Deux types (entiers e, complexes c), trois produits : e*e->e, c*c->c, e*e->c



- 1) Une remontée récursive pour calculer les types possibles
- 2) Si pas unicité du type possible à la racine : erreur
- 3) Descente récursive pour fixer les types
- Si pas unicité erreur

Surcharge Exemple de Java

On peut aussi décider, quand plusieurs types sont possibles, d'établir des priorités

```
class Surcharge {
    static interface I {}
    static class A implements I {}
    public static void m(I a, I b) {
        System.out.println("II");
    }
    public static void m(I a, A b) {
        System.out.println("IA");
    }
    public static void m(A a, I b) {
        System.out.println("AI");
    }
    public static void main(String[] args) {
        A a = new A();
        A b = new A();
        A b = new A();
        m(a,b);
    }
}
```

Quand la méthode avec les bons arguments n'est pas trouvée, on remonte l'arbre des types sur tous les arguments, en affectant un poids aux remontées Il doit y avoir une remontée unique avec un poids minimal et amenant à une méthode.

Surcharge Exemple de Java

On peut aussi décider, quand plusieurs types sont possibles, d'établir des priorités

```
class SurchargeConversion {
  public static void m(long a, long b) {
    System.out.println("LL");
  public static void m(long a, double b) {
    System.out.println("LD");
  public static void m(double a, long b) {
    System.out.println("DL");
  public static void m(double a, double b) {
    System.out.println("DD");
  public static void main(String[] args) {
    m(1,2); // LL
```

Polymorphisme

Les types des fonctions ne sont pas entièrement fixés à l'avance.

Faciliter la ré-utilisabilité

Présent dans les langages fonctionnels, mais aussi en Java 8, par exemple.

La liste en paramètre peut être contenir des éléments de n'importe quel type (tous les éléments sont du même type).

Le type des éléments, inconnu, est noté 'a.

Inférence de type : trouver le type d'une expression

Unification

Trouver, à partir de deux expressions de type e et e', une substitution S qui à chaque variable de type associe un type de telle manière que S(t)=S(t')

Exemple : soient les deux expressions de type suivantes

Les deux substitutions S et S' suivantes définissent chacune une unification de e et e'

En effet

$$S(e) = (('c -> 'b)*'c list) -> 'b list$$

 $S(e') = (('c -> 'b)*'c list) -> 'b list$

et
$$S'(e) = (('a -> 'a)^*'a list) -> 'a list$$

 $S'(e') = (('a -> 'a)^*'a list) -> 'a list$

S est plus générale que S', puisque

en substituant dans S 'c et 'b par 'a on obtient S'

il n'existe pas de substitution permettent d'obtenir S à partir de S'

L'unificateur de e et e' est la substitution *la plus générale* (aux noms de variables près) permettant d'unifier e et e'

Trouver un type général pour une fonction : l'inférence de type

Donc f:'a list->'a list->'a list

Un algorithme d'unification

Entrée : deux graphes de représentation de type d'expression

Sortie : les deux graphes dont les nœuds sont regroupés en classes d'équivalence de types

Chaque classe contient un nœud représentatif de la classe. Dans la mesure du possible,

ce nœud représentatif n'est pas une variable.

Retour : vrai si l'unification est un succès, faux sinon

booléen unification(nœud n, nœud m)

Soient s et t respectivement les nœuds représentatifs de la classe de n et de celle de m

Sis = t

Retourner vrai

Sinon si s et t représentent le même type de base

Retourner vrai

Sinon si s et t sont des opérateurs de même type et de fils respectifs s₁, s₂, t₁, t₂

Mettre s et t dans la même classe c.

Si l'un des deux n'est pas une variable il devient représentant de c

Sinon n'importe lequel des deux devient représentant de c

Retourner unification(s₁,t₁) && unification(s₂,t₂)

Sinon si s ou t est une variable

Mettre s et t dans la même classe c.


Si l'un des deux n'est pas une variable il devient représentant de c


Sinon n'importe lequel des deux devient représentant de c


Retourner vrai

Sinon

Retourner faux








е

->


Exemple




x S(x)
a a
b b
c a
d b
e list b

let rec f = function [] -> (function
$$x -> x$$
) | $x::m ->$ (function $I -> f m x::I$)

'a 'b 'c 'c 'd 'e 'd




On ajoute à l'algorithme les règles suivantes : Si s est de la forme App(f,g) Soient 'a et 'b deux nouvelles inconnues retourner unification(f, 'a->'b) && unification(g,'a) && unification(s,'b)




let rec f = function [] -> (function x -> x) | x::m -> (function I -> f m x::I)

'a 'b 'c 'c 'd 'e 'd


'a






let rec f = function [] -> (function x -> x) | x::m -> (function I -> f m x::I)


'a 'b 'c 'c 'd 'e 'd






let rec f = function [] -> (function x -> x) | x::m -> (function I -> f m x::I)

'a 'b 'c 'c 'd 'e 'd




f: list 'b -> list 'b -> list 'b


Ramasse-miettes: reference counting




Ramasse-miettes: reference counting




Ramasse-miettes: reference counting



Ramasse-miettes: reference counting



Ramasse-miettes: reference counting



Ramasse-miettes: reference counting

Algorithme utilisé par Perl 5

- Algorithme simple
- Données de gestion: un entier dans chaque objet
- Temps de calcul majoré par le nombre total d'objets (car libération transitive éventuelle)
- Temps de calcul important si les changements de références sont courants
 - Changement de l'entier
 - Test de l'entier
 - Autres opérations éventuelles
- Temps de calcul correct en moyenne, et sans arrêt intempestif de l'application
- Permet une récupération immédiate de l'espace mémoire
- Libération partielle pour les objets avec cycles !!
- Fragmentation ?

Représentation des types

Représentation en mémoire Taille Utilisation de l'espace

Caractéristiques de stockage Alignement Zones de stockage

Exemple : type « entier » de taille fixe Taille : 8 cellules de mémoire

Représentation des valeurs positives ou nulles : base 2, little endian

Représentation des valeurs négatives : complément à deux

Alignement : les entiers doivent être stockés à des adresses multiples de 8

Zone de stockage : toutes sont autorisées

Exemple : type « liste » de taille variable

Taille : structure+taille de chacun des maillons

Représentation : celle de la structure et celle des maillons

Alignement : celui de la structure


Zone de stockage : toutes pour la structure, tas pour les maillons

Quand ils existent, le compilateur peut utiliser les types implantés par le processeur. Mais il peut aussi choisir de ne pas le faire : il faut alors qu'il les implante

programmes plus lents et plus gros


Rappels sur la structure physique d'une machine

Constantes + variables non automatiques



Registres (chaque registre contient un *mot machine*)


La mémoire



Adressage de la mémoire par le processeur (modèle simplifié)

Deux espaces d'adressage:

- E: celui de la mémoire physique
- Reg+: celui du processeur




f: application de Reg+ dans E. Surjective, mais pas injective

g: fonction de E dans ensemble des cellules. Ni injective ni surjective

Adressage de la mémoire par le processeur (modèle simplifié)

Deux espaces d'adressage:

- E: celui de la mémoire physique
- Reg+: celui du processeur



f: application de Reg+ dans E. Surjective, mais pas injective

g: fonction de E dans ensemble des cellules. Ni injective ni surjective

Adressage de la mémoire par le processeur: un exemple réel

Processeur: i8086 (Registres 16 bits, cellule=octet, mémoire adressable: 1Mo,1978)

CS: 1010010101001010


IP: 1011101010100101

f((CS,IP)): 10110000111101000101

f-1f((CS,IP)) pas unique: deux adresses processeurs différentes peuvent désigner la même cellule mémoire !!

Adressage processeur

Adressage mémoire physique



Adressage de la mémoire par le processeur: un autre exemple

Processeur: ? (registres 16 bits, cellule=octet, mémoire adressable 32Ko)

Registre d'adresse: RA instruction de transfert Accumulateur: AX

Bit de poids faible de RA: toujours à 0 pour les adresses valides

1: génération d'une erreur (exception)

Le fait de calculer une mauvaise adresse (transfert de AX vers RA d'une valeur d'adresse invalide (terminant par 1)) peut provoquer une erreur au niveau du processeur, sans même avoir mis cette adresse sur le bus d'adresses.

Le mot machine

Groupe de cellules consécutives sur lequel le processeur fait la plupart de ses opérations.

Taille: machine dépendante (registre)

Ordre de placement des cellules dans le groupe: machine dépendant

Cellules de 6 bits, Mots de 3 cellules, $(10915)_{10} = (0000101010101010101)_2$

Gros boutistes: on commence par le poids fort


Petits boutistes: on commence par le poids faible

0 1 2 3 4 5 6 7 8

Représentation des types entiers

Valeurs positives ou nulles: codage en base 2

Ex: 678 = 29 + 27 + 25 + 22 + 21



Valeurs négatives: codage machine dépendant

- codage avec bit de signe
- codage avec complément à deux
-

Intervalle des valeurs représentées

Codage sur n (machine dépendant) bits

Codage de 2ⁿ valeurs

Valeurs entières naturelles: [0,2ⁿ[

Valeurs entières relatives:

Le nombre de valeurs positives et négatives dépend du codage choisi (machine dépendant). En général, le codage est bon et le nombre de valeurs positives ou nulles est égal au nombre de valeurs négatives.

L'intervalle des valeurs représentées est alors [-2ⁿ⁻¹,2ⁿ⁻¹[

Un codage avec bit de signe

Codage de x

Un bit (par exemple le plus à gauche) est réservé pour le signe

Une valeur de ce bit (par exemple 1) indique que la valeur est négative, l'autre valeur qu'elle est positive ou nulle.

Le reste des bits sert à coder:

- x si x>=0
- abs(x)-1 si x<0

Ex: codage de -678 sur 16 bits

1000001010100101 11111111110000000000 98765432109876543210

Le codage par complément à deux

De loin le plus utilisé

Complément à deux = complément à un + 1

Ex: codage de – 678 sur 16 bits

	000001010100110
Poids du bit	11111111110000000000 98765432109876543210
4	1111110101011001
Poids du bit	11111111110000000000 98765432109876543210
4	1111110101011010
Poids du bit	11111111110000000000000009876543210

Rem: le bit de poids fort donne le signe

Justification du complément à deux

- L'algorithme d'addition est le même (bit à bit) que les valeurs soient positives ou négatives
- Le calcul du dépassement de capacité est simple
 - si les deux opérandes ne sont pas de même signe, débordement impossible
 - si le signe du résultat n'est pas celui des deux opérandes, débordement
 - si le bit de retenue entrante dans le bit de poids fort est différent du bit de retenue sortante, débordement (équivalent au principe précédent)

Exemples d'addition en complément à deux avec dépassement

8 bits, valeurs entières relatives, valeurs négatives: complément à deux

Bit perdu

Opérations sur les valeurs arithmétiques

Opérateurs arithmétiques:

Opérateurs unaires: + -

Opérateurs binaires:+ - * / %

Opérateurs de manipulation de bits: ~ << >> & | ^

~x: négation bit à bit

x << y: décalage des bits de x de y crans vers la gauche

x >> y: décalage des bits de x de y crans vers la droite

x & y: ET bit à bit x | y: OU bit à bit

x ^ y: OU exclusif bit à bit

entiers uniquement

Sémantique des opérations sur les valeurs arithmétiques

Opérateurs arithmétiques (-+-+*/%): usuelles

Opérateurs de manipulation de bits

```
~a: complément à un (négation bit à bit) 
~ (1\ 0\ 0\ 0\ 1\ 1\ 1\ 0)_2 = (0\ 1\ 1\ 1\ 0\ 0\ 0\ 1)_2
```


a & b: ET bit à bit
$$(10001110)_2$$
 & $(10011110)_2$ = $(10001110)_2$

a | b: OU bit à bit
$$(10001110)_2 | (10011111)_2 = (10011111)_2$$

a ^ b: OU exclusif bit à bit
$$(10001110)_2$$
 ^ $(10011110)_2$ = $(0001001)_2$

Le code ASCII

Code ASCII originel: 7 bits



Code ASCII étendu: 8 bits

>=128: caractères semi-graphiques

Table ASCII

0 NUL	16 DLE	32 ESP	48 0	64 @	80 P	
1 SOH	17 DC1	33!	49 1	65 A	81 Q	
2 STX	18 DC2	34 "	50 2	66 B	82 R	
3 ETX	19 DC3	35 #	513	67 C	83 S	
4 EOT	20 DC4	36 \$	52 4	68 D	84 T	
5 ENQ	21 NAK	37 %	53 5	69 E	85 U	
6 ACK	22 SYN	38 &	54 6	70 F	86 V	
7 BEL	23 ETB	39 '	55 7	71 G	87 W	
8 BS	24 CAN	40 (568	72 H	88 X	
9 TAB	25 EM	41)	57 9	73 I	89 Y	
10 LF	26 SUB	42 *	58:	74 J	90 Z	
11 VT	27 ESC	43 +	59;	75 K		123 {
12 FF	28 FS	44,	60 <	76 L		124
13 RC	29 GS	45 -	61 =	77 M		125 }
14 SO	30 RS	46.	62 >	78 N		126 ~
15 SI	31 US	47 /	63?	79 O		127 DEL

Le code EBCDIC





Caractères de contrôle

Caractères alphanumériques divers



Alphabet minuscule

Alphabet majuscule

Chiffres

Table EBCDIC

0 NUL	16 DLE	32 DS	48	64 SP	80 &	96 -	112
1 SOH	17 DC1	33 SOS	49	65	81	97 /	113
2 STX	18 DC2	34 FS	50 SYN	66	82	98	114
3 ETX	19 TM	35	51	67	83	99	115
4 PF	20 RES	36 BYP	52 PN	68	84	100	116
5 HT	21 NL	37 LF	53 RS	69	85	101	117
6 LC	22 BS	38 ETB	54 UC	70	86	102	118
7 DEL	23 IL	39 ESC	55 EOT	71	87	103	119
8	24 CAN	40	56	72	88	104	120
9	25 EM	41	57	73	89	105	121
10 SMM	126 CC	42 SM	58	74 ¢	90!	106	122:
11 VT	27 CU1	43 CU2	59 CU3	75.	91 \$	107,	123 #
12 FF	28 IFS	44	60 DC4	76 <	92 *	108 %	124 @
13 CR	29 IGS	45 ENQ	61 NAK	. 77 (93)	109 _	125 '
14 SO	30 IRS	46 ACK	62	78 +	94;	110 >	126 =
15 SI	31 IUS	47 BEL	63 SUB	79	95 ¬	111?	127 "

Table EBCDIC

128	144	160	176	192	208	224	240 0
129 a	145 j	161	177	193 A	209 J	225	241 1
130 b	146 k	162 s	178	194 B	210 K	226 S	242 2
131 c	147 l	163 t	179	195 C	211 L	227 T	243 3
132 d	148 m	164 u	180	196 D	212 M	228 U	244 4
133 e	149 n	165 v	181	197 E	213 N	229 V	245 5
134 f	150 o	166 w	182	198 F	214 O	230 W	246 6
135 g	151 p	167 x	183	199 G	215 P	231 X	247 7
136 h	152 q	168 y	184	200 H	216 Q	232 Y	248 8
137 i	153 r	169 z	185`	201 I	217 R	233 Z	249 9
138	154	170	186	202	218	234	250
139	155	171	187	203	219	235	251
140	156	172	188	204	220	236	252
141	157	173	189	205	221	237	253
142	158	174	190	206	222	238	254
143	159	175	191	207	223	239	255

Norme IEEE 754-1985

- 4 formats de représentation
 - Simple précision (32 bits) :
 - 1 bit de signe,
 - 8 bits d'exposant,
 - 23 bits de mantisse
 - 1 bit implicite
 - Simple précision étendue (plus de 43 bits : obsolète)
 - Double précision (64 bits : 1 sgn, 11 exp, 52 mantisse, 1 implicite)
 - Double précision étendue (plus de 79 bits)
- Valeurs spéciales
- Modes d'arrondi (pris en charge dans gcc par des options)
 - Au plus près
 - Vers 0
 - Vers +Infty
 - Vers -Infty
- Opérations arithmétiques : +-*/ sqrt arrondi reste
- Cinq exceptions (pour détecter les erreurs, prises en charge dans gcc par options)


Norme IEEE 754-1985 Valeurs spéciales

Not A Number (NaN)
+0.0
+Infinity
-0.0
-Infinity

+	NaN	-Infinity	+Infinity	У	0
NaN	NaN	NaN	NaN	NaN	NaN
-Infinity	NaN	-Infinity	NaN	-Infinity	-Infinity
+Infinity	NaN	NaN	+Infinity	+Infinity	+Infinity
X	NaN	-Infinity	+Infinity	х+у	X
0	NaN	-Infinity	+Infinity	У	0

```
float x=0.0/0.0; /* Correct en IEEE 754!! */
printf(« %s », x==x ? « yes » : « no »); /* no en IEEE 754!! */
```

Norme IEEE 754-1985 Représentation de la précision simple



Si E différent de 0

$$x=(-1)^{S}*2^{E-127}*(1+M)$$

•Si E = 0

$$x = (-1)^{S} * 2^{-127} * M$$

Ex:
$$14.4 = 2^3 * (1+0.8) = 2^3 * (1+(1.6*2^{-1})) = 2^3 * (1+((1+0.6)*2^{-1}))$$

 $2^3 * (1+((1+(1+0.2)*2^{-1})*2^{-1}))$
 $2^3 * (1+((1+(1+(1.6*2^{-3}))*2^{-1})*2^{-1}))$

S=1, E=130=10000010, M=11001100...1100...

Norme IEEE 754-1985 Représentation de la précision simple

- Tous les nombres ne sont pas représentables (Ex:14.4)
- Pas associatif:


Alignement

Le processeur n'accède qu'à un seul mot mémoire à un temps donné

Il charge naturellement (et donc rapidement) les données dont l'adresse est un multiple de la taille d'un mot mémoire.


bus de données

temps 1



Alignement

Plusieurs accès mémoire peuvent être nécessaires pour transférer des données non alignées :



Alignement

Le compilateur peut arranger les données pour qu'elles soient alignées correctement : le programme s'exécutera plus rapidement

les données prendront plus de place en mémoire

Il peut aussi ne pas le faire :

le programme s'exécutera plus lentement (dans certains cas, très significativement) les données prendront moins de place mémoire (dans certains cas, très significativement)

Très souvent, on préfère aligner.

L'alignement peut avoir des conséquences sur les tailles des pointeurs.

Exemple:

si les adresses des entiers sont des multiples de 4, les deux derniers bits sont inutiles si les adresses des réels sont des multiples de 8, les trois derniers bits sont inutiles les adresses « génériques » utilisent tous les bits.

Le compilateur peut décider de tailles différentes pour les pointeurs (ou pas)

```
padding = (align - (offset mod align)) mod align
new offset = offset + padding = offset + (align - (offset mod align)) mod align
```

Si par ailleurs on souhaite que taille(T[n])=n*taille(T) alors il faut ajouter du padding en fin de type

$$sizeof(struct\ nom) \ge \sum_{i=1}^{i=n} sizeof(type_i)$$

Suivants leurs types, les adresses d'objets peuvent avoir des propriétés différentes (machine dépendantes). Sur chaque machine, il existe une classe d'adresses regroupant les contraintes de toutes les autres.

Exemples:


- Adresses de char: quelconques
- Adresses d'int: multiples (en cellules) de la taille d'un int
- Adresses de float: multiples (en cellules) de la taille d'un int
-

struct complexe { signed char reel; int imaginaire; };

```
padding = (align - (offset mod align)) mod align
new offset = offset + padding = offset + (align - (offset mod align)) mod align
```

Exemple:


```
type car: taille 1, pas de contrainte d'alignement
tpe entier: taille 4, contrainte d'alignement: multiple de 4
type reel: taille 8, contrainte d'alignement: multiple de 8
struct { car a; entier b; car c; reel d; car e; }
```



```
padding = (align - (offset mod align)) mod align
new offset = offset + padding = offset + (align - (offset mod align)) mod align
```

Exemple:

```
type car: taille 1, pas de contrainte d'alignement
tpe entier: taille 4, contrainte d'alignement: multiple de 4
type reel: taille 8, contrainte d'alignement: multiple de 8
struct { car a; entier b; car c; reel d; car e; }
```




car a

```
padding = (align - (offset mod align)) mod align
new offset = offset + padding = offset + (align - (offset mod align)) mod align
```

Exemple:

```
type car: taille 1, pas de contrainte d'alignement
tpe entier: taille 4, contrainte d'alignement: multiple de 4
type reel: taille 8, contrainte d'alignement: multiple de 8
struct { car a; entier b; car c; reel d; car e; }
```



car a

```
placement de b

offset = 1


align = 4

padding = (4-(1 mod 4))mod 4 = 3
```

```
padding = (align - (offset mod align)) mod align
new offset = offset + padding = offset + (align - (offset mod align)) mod align
```

Exemple:

type car: taille 1, pas de contrainte d'alignement tpe entier: taille 4, contrainte d'alignement: multiple de 4 type reel: taille 8, contrainte d'alignement: multiple de 8 struct { car a; entier b; car c; reel d; car e; }



car a entier b


placement de b offset = 1 align = 4 padding = (4-(1 mod 4))mod 4 = 3 new offset = 1+3

```
padding = (align - (offset mod align)) mod align
new offset = offset + padding = offset + (align - (offset mod align)) mod align
```

Exemple:

type car : taille 1, pas de contrainte d'alignement tpe entier : taille 4, contrainte d'alignement : multiple de 4 type reel : taille 8, contrainte d'alignement : multiple de 8

struct { car a ; entier b ; car c ; reel d ; car e ; }



car a entier b car c

placement de c offset = 8 align = 1 padding = (1-(8 mod 1))mod 1 = 0 new offset = 8+0


```
padding = (align - (offset mod align)) mod align
new offset = offset + padding = offset + (align - (offset mod align)) mod align
```

Exemple:

type car : taille 1, pas de contrainte d'alignement tpe entier : taille 4, contrainte d'alignement : multiple de 4

type reel : taille 8, contrainte d'alignement : multiple de 8

struct { car a ; entier b ; car c ; reel d ; car e ; }



car a entier b

car c

réel d

placement de d

offset = 9

align = 8


padding = $(8-(9 \mod 8)) \mod 8 = 7$

new offset = 9+7=16

```
padding = (align - (offset mod align)) mod align
new offset = offset + padding = offset + (align - (offset mod align)) mod align
```

Exemple:

type car: taille 1, pas de contrainte d'alignement tpe entier: taille 4, contrainte d'alignement: multiple de 4 type reel: taille 8, contrainte d'alignement: multiple de 8 struct { car a; entier b; car c; reel d; car e; }




```
padding = (align - (offset mod align)) mod align
new offset = offset + padding = offset + (align - (offset mod align)) mod align
```

Exemple:

type car : taille 1, pas de contrainte d'alignement

tpe entier : taille 4, contrainte d'alignement : multiple de 4 type reel : taille 8, contrainte d'alignement : multiple de 8

struct { car a ; entier b ; car c ; reel d ; car e ; }



Taille des unions

Alignement : tous les membres sont alignés par rapport au début les espaces mémoire se recouvrent

Contrainte d'alignement = max des contraintes d'alignement des membres


Pas de *padding* entre les membres


Taille = max des tailles des membres


Exemple: union { car a ; entier b ; car c ; réel d ; car e ; }
Contrainte d'alignement : celle des réels = 8


Taille : celle des réels = 8


Activation d'un appel : entrée dans la fonction -> sortie de la fonction


















Sauvegarder/restaurer les valeurs des paramètres, variables locales et autres informations sur l'exécution des fonctions



Les fonctions actives et leurs données sont conservées dans la pile. La liste des fonctions actives est le chemin de la racine vers la dernière fonction activée. La gestion en mémoire de la pile de contrôle permet d'implanter les langages procéduraux.

Chaque processus mémorise les variables locales et les paramètres des méthodes en cours d'exécution dans pile de *stack-frames* (cadres d'exécution)

Une *stack-frame* pour la méthode *m* contient en particulier

- ▶ l'espace nécessaire pour stocker chaque paramètre et chaque variable locale de m.
- une pile dont la taille maximale est calculée par le compilateur

Les instructions invokeX qui permettent d'appeler une méthode

- réalisent la résolution de la méthode *m* à appeler
- > créent une stack-frame s pour préparer l'appel à m et placent s dans la pile de stack-frames
- recopient les valeurs des paramètres dans les espaces de s qui leur sont réservés
- passent le contrôle d'exécution à m

En fin d'exécution de m

- le sommet de la pile de la stack-frame s contient la valeur de retour r
- elle est mémorisée par la VM
- la VM détruit s
- > la VM mets r en sommet de la pile d'exécution de la stack-frame de la fonction appelante
- le flot d'exécution de la fonction appelante reprends après invokeX

Dans la stack-frame, les variables locales et paramètres de *m* sont numérotés

Le *byte-code* permet de manipuler les variables locales et les paramètres uniquement par leur numéro


- Avantages :
 - la taille des stack-frames est constante, et calculée par le compilateur
 - comme les variables/paramètres ne sont accessibles que par leur numéro, pas de problème de sécurité

```
static int pair(int a, int b) {
  if ( a == 0 )
    return b;
  if ( b == 0 )
    return a;
  return impair(a-1, b) + impair(a, b-1);
}
```

```
static int pair(int, int);
  Code:
    0: iload 0
    1: ifne
    4: iload 1
    5: ireturn
    6: iload 1
    7: ifne
                  12
    10: iload 0
    11: ireturn
    12: iload 0
    13: iconst 1
    14: isub
    15: iload_1
    16: invokestatic #2
                                    // Method impair:(II)I
    19: iload 0
    20: iload 1
   21: iconst 1
    22: isub
                                    // Method impair:(II)I
    23: invokestatic #2
    26: iadd
    27: ireturn
```

```
static int pair(int, int);
  Code:
    0: iload 0
    1: ifne
                 6
    4: iload 1
    5: ireturn
    6: iload 1
                 12
    7: ifne
    10: iload 0
   11: ireturn
   12: iload 0
   13: iconst 1
   14: isub
   15: iload 1
   16: invokestatic #2
   19: iload 0
   20: iload 1
   21: iconst 1
   22: isub
   23: invokestatic #2
   26: iadd
```

27: ireturn



```
public static void main(java.lang.String[]);
static int pair(int, int);
                                   Code:
  Code:
                                                                 // Field java/lang/System.out:Ljava/io/PrintStream;
                                    0: getstatic
    0: iload 0
                                     3: iconst 2
    1: ifne
                 6
                                     4: iconst 2
    4: iload 1
                                                                   // Method pair:(II)I
                                    5: invokestatic #3
    5: ireturn
                                    8: invokevirtual #5
                                                                   // Method java/io/PrintStream.println:(I)V
    6: iload 1
                                    11: return
                 12
    7: ifne
   10: iload 0
   11: ireturn
   12: iload 0
   13: iconst 1
   14: isub
   15: iload 1
   16: invokestatic #2
   19: iload 0
                                              main
   20: iload 1
   21: iconst 1
   22: isub
   23: invokestatic #2
   26: iadd
   27: ireturn
```

java.lang.System.out

argv

```
public static void main(java.lang.String[]);
static int pair(int, int);
                                   Code:
  Code:
                                                                 // Field java/lang/System.out:Ljava/io/PrintStream;
                                    0: getstatic
                                                   #4
    0: iload 0
                                    3: iconst 2
    1: ifne
                 6
                                    4: iconst 2
    4: iload 1
                                                                   // Method pair:(II)I
                                    5: invokestatic #3
    5: ireturn
                                    8: invokevirtual #5
                                                                   // Method java/io/PrintStream.println:(I)V
    6: iload 1
                                    11: return
                 12
    7: ifne
   10: iload 0
   11: ireturn
   12: iload 0
   13: iconst 1
   14: isub
   15: iload 1
   16: invokestatic #2
   19: iload 0
                                              main
   20: iload 1
   21: iconst 1
   22: isub
   23: invokestatic #2
   26: iadd
   27: ireturn
```

java.lang.System.out

argv


```
public static void main(java.lang.String[]);
static int pair(int, int);
                                   Code:
  Code:
                                                                 // Field java/lang/System.out:Ljava/io/PrintStream;
                                    0: getstatic
                                                   #4
    0: iload 0
                                    3: iconst 2
    1: ifne
                 6
                                    4: iconst 2
    4: iload 1
                                                                   // Method pair:(II)I
                                    5: invokestatic #3
    5: ireturn
                                    8: invokevirtual #5
                                                                   // Method java/io/PrintStream.println:(I)V
    6: iload 1
                                    11: return
                 12
    7: ifne
   10: iload 0
   11: ireturn
   12: iload 0
   13: iconst 1
   14: isub
   15: iload 1
   16: invokestatic #2
   19: iload 0
                                              main
   20: iload 1
   21: iconst 1
   22: isub
   23: invokestatic #2
   26: iadd
   27: ireturn
```

java.lang.System.out


argv

```
static int pair(int, int);
  Code:
    0: iload 0
    1: ifne
                 6
    4: iload 1
    5: ireturn
    6: iload 1
                 12
    7: ifne
   10: iload 0
   11: ireturn
   12: iload 0
   13: iconst 1
   14: isub
   15: iload 1
   16: invokestatic #2
   19: iload 0
   20: iload 1
   21: iconst 1
   22: isub
   23: invokestatic #2
   26: iadd
```


27: ireturn



```
static int pair(int, int);
  Code:
    0: iload 0
    1: ifne
                 6
    4: iload 1
    5: ireturn
    6: iload 1
                 12
    7: ifne
   10: iload 0
   11: ireturn
   12: iload 0
   13: iconst 1
   14: isub
   15: iload 1
   16: invokestatic #2
   19: iload 0
   20: iload 1
   21: iconst 1
   22: isub
   23: invokestatic #2
   26: iadd
   27: ireturn
```




```
static int pair(int, int);
  Code:
    0: iload 0
    1: ifne
                 6
    4: iload 1
    5: ireturn
    6: iload 1
                 12
    7: ifne
   10: iload 0
   11: ireturn
   12: iload 0
   13: iconst 1
   14: isub
   15: iload 1
   16: invokestatic #2
   19: iload 0
   20: iload 1
   21: iconst 1
   22: isub
   23: invokestatic #2
   26: iadd
   27: ireturn
```




```
static int pair(int, int);
  Code:
    0: iload 0
    1: ifne
                 6
    4: iload 1
    5: ireturn
    6: iload 1
                 12
    7: ifne
   10: iload 0
   11: ireturn
   12: iload 0
   13: iconst 1
   14: isub
   15: iload 1
   16: invokestatic #2
   19: iload 0
   20: iload 1
   21: iconst 1
   22: isub
   23: invokestatic #2
   26: iadd
```

27: ireturn




```
static int pair(int, int);
  Code:
    0: iload 0
    1: ifne
                 6
    4: iload 1
    5: ireturn
    6: iload 1
                 12
    7: ifne
   10: iload 0
   11: ireturn
   12: iload 0
   13: iconst 1
   14: isub
   15: iload 1
   16: invokestatic #2
   19: iload 0
   20: iload 1
   21: iconst 1
   22: isub
   23: invokestatic #2
   26: iadd
```


27: ireturn



```
static int pair(int, int);
  Code:
    0: iload 0
    1: ifne
                 6
    4: iload 1
    5: ireturn
    6: iload 1
                 12
    7: ifne
   10: iload 0
   11: ireturn
   12: iload 0
   13: iconst 1
   14: isub
   15: iload 1
   16: invokestatic #2
   19: iload 0
   20: iload 1
   21: iconst 1
   22: isub
   23: invokestatic #2
   26: iadd
   27: ireturn
```




```
static int pair(int, int);
  Code:
    0: iload 0
    1: ifne
                 6
    4: iload 1
    5: ireturn
    6: iload 1
                 12
    7: ifne
   10: iload 0
   11: ireturn
   12: iload 0
   13: iconst 1
   14: isub
   15: iload 1
   16: invokestatic #2
   19: iload 0
   20: iload 1
   21: iconst 1
   22: isub
   23: invokestatic #2
   26: iadd
   27: ireturn
```




```
static int pair(int, int);
  Code:
    0: iload 0
    1: ifne
                 6
    4: iload 1
    5: ireturn
    6: iload 1
                 12
    7: ifne
   10: iload 0
   11: ireturn
   12: iload 0
   13: iconst 1
   14: isub
   15: iload 1
   16: invokestatic #2
   19: iload 0
   20: iload 1
   21: iconst 1
   22: isub
   23: invokestatic #2
   26: iadd
```

27: ireturn




```
static int pair(int, int);
  Code:
    0: iload 0
    1: ifne
                 6
    4: iload 1
    5: ireturn
    6: iload 1
                 12
    7: ifne
   10: iload 0
   11: ireturn
   12: iload 0
   13: iconst 1
   14: isub
   15: iload 1
   16: invokestatic #2
   19: iload 0
   20: iload 1
   21: iconst 1
   22: isub
   23: invokestatic #2
   26: iadd
```


27: ireturn



```
static int pair(int, int);
  Code:
    0: iload 0
    1: ifne
                 6
    4: iload 1
    5: ireturn
    6: iload 1
                 12
    7: ifne
    10: iload 0
   11: ireturn
   12: iload 0
   13: iconst 1
   14: isub
   15: iload 1
   16: invokestatic #2
   19: iload 0
   20: iload 1
   21: iconst 1
   22: isub
   23: invokestatic #2
   26: iadd
   27: ireturn
```




```
static int pair(int, int);
  Code:
    0: iload 0
    1: ifne
                 6
    4: iload 1
    5: ireturn
    6: iload 1
                 12
    7: ifne
   10: iload 0
   11: ireturn
   12: iload 0
   13: iconst 1
   14: isub
   15: iload 1
   16: invokestatic #2
   19: iload 0
   20: iload 1
   21: iconst 1
   22: isub
   23: invokestatic #2
   26: iadd
   27: ireturn
```




. . .


```
static int pair(int, int);
  Code:
    0: iload 0
    1: ifne
                 6
    4: iload 1
    5: ireturn
    6: iload 1
                 12
    7: ifne
    10: iload 0
   11: ireturn
   12: iload 0
   13: iconst 1
   14: isub
   15: iload 1
   16: invokestatic #2
   19: iload 0
   20: iload 1
   21: iconst 1
   22: isub
   23: invokestatic #2
   26: iadd
   27: ireturn
```




```
static int pair(int, int);
  Code:
    0: iload 0
    1: ifne
                 6
    4: iload 1
    5: ireturn
    6: iload 1
                 12
    7: ifne
    10: iload 0
   11: ireturn
   12: iload 0
   13: iconst 1
   14: isub
   15: iload 1
   16: invokestatic #2
   19: iload 0
   20: iload 1
   21: iconst 1
   22: isub
   23: invokestatic #2
   26: iadd
   27: ireturn
```




```
static int pair(int, int);
  Code:
    0: iload 0
    1: ifne
                 6
    4: iload 1
    5: ireturn
    6: iload 1
                 12
    7: ifne
    10: iload 0
   11: ireturn
   12: iload 0
   13: iconst 1
   14: isub
   15: iload 1
   16: invokestatic #2
   19: iload 0
   20: iload 1
   21: iconst 1
   22: isub
   23: invokestatic #2
   26: iadd
   27: ireturn
```



```
static int pair(int, int);
  Code:
    0: iload 0
    1: ifne
                 6
    4: iload 1
    5: ireturn
    6: iload 1
                 12
    7: ifne
    10: iload 0
   11: ireturn
   12: iload 0
   13: iconst 1
   14: isub
   15: iload 1
   16: invokestatic #2
   19: iload 0
   20: iload 1
   21: iconst 1
   22: isub
   23: invokestatic #2
   26: iadd
   27: ireturn
```




```
static int pair(int, int);
  Code:
    0: iload 0
    1: ifne
                 6
    4: iload 1
    5: ireturn
    6: iload 1
                 12
    7: ifne
    10: iload 0
   11: ireturn
   12: iload 0
   13: iconst 1
   14: isub
   15: iload 1
   16: invokestatic #2
   19: iload 0
   20: iload 1
   21: iconst 1
   22: isub
   23: invokestatic #2
   26: iadd
   27: ireturn
```



```
static int pair(int, int);
  Code:
    0: iload 0
    1: ifne
                 6
    4: iload 1
    5: ireturn
    6: iload 1
                 12
    7: ifne
   10: iload 0
   11: ireturn
   12: iload 0
   13: iconst 1
   14: isub
   15: iload 1
   16: invokestatic #2
   19: iload 0
   20: iload 1
   21: iconst 1
   22: isub
   23: invokestatic #2
   26: iadd
```


27: ireturn



. . .


```
static int pair(int, int);
  Code:
    0: iload 0
    1: ifne
                 6
    4: iload 1
    5: ireturn
    6: iload 1
                 12
    7: ifne
    10: iload 0
   11: ireturn
   12: iload 0
   13: iconst 1
   14: isub
   15: iload 1
   16: invokestatic #2
   19: iload 0
   20: iload 1
   21: iconst 1
   22: isub
   23: invokestatic #2
   26: iadd
```

27: ireturn




```
static int pair(int, int);
  Code:
    0: iload 0
    1: ifne
                 6
    4: iload 1
    5: ireturn
    6: iload 1
                 12
    7: ifne
    10: iload 0
   11: ireturn
   12: iload 0
   13: iconst 1
   14: isub
   15: iload 1
   16: invokestatic #2
   19: iload 0
   20: iload 1
   21: iconst 1
   22: isub
   23: invokestatic #2
   26: iadd
```

27: ireturn



java.lang.System.out

```
static int pair(int, int);
  Code:
    0: iload 0
    1: ifne
                 6
    4: iload 1
    5: ireturn
    6: iload 1
                 12
    7: ifne
    10: iload 0
   11: ireturn
   12: iload 0
   13: iconst 1
   14: isub
   15: iload 1
   16: invokestatic #2
   19: iload 0
   20: iload 1
   21: iconst 1
   22: isub
   23: invokestatic #2
   26: iadd
   27: ireturn
```




```
public static void main(java.lang.String[]);
static int pair(int, int);
                                   Code:
  Code:
                                                                 // Field java/lang/System.out:Ljava/io/PrintStream;
                                    0: getstatic
                                                   #4
    0: iload 0
                                    3: iconst 2
    1: ifne
                 6
                                    4: iconst 2
    4: iload 1
                                                                   // Method pair:(II)I
                                    5: invokestatic #3
    5: ireturn
                                    8: invokevirtual #5
                                                                   // Method java/io/PrintStream.println:(I)V
    6: iload 1
                                    11: return
                 12
    7: ifne
   10: iload 0
   11: ireturn
   12: iload 0
   13: iconst 1
   14: isub
   15: iload 1
   16: invokestatic #2
   19: iload 0
                                              main
   20: iload 1
   21: iconst 1
   22: isub
   23: invokestatic #2
                                              8
   26: iadd
   27: ireturn
```

java.lang.System.out

argv

```
static int pair(int, int);
  Code:
    0: iload 0
    1: ifne
                 6
    4: iload 1
    5: ireturn
    6: iload 1
                 12
    7: ifne
    10: iload 0
   11: ireturn
   12: iload 0
   13: iconst 1
   14: isub
   15: iload 1
   16: invokestatic #2
   19: iload 0
   20: iload 1
   21: iconst 1
   22: isub
   23: invokestatic #2
   26: iadd
   27: ireturn
```



```
static int pair(int, int);
  Code:
    0: iload 0
    1: ifne
    4: iload 1
    5: ireturn
    6: iload 1
                 12
    7: ifne
   10: iload 0
   11: ireturn
   12: iload 0
   13: iconst 1
   14: isub
   15: iload 1
   16: invokestatic #2
   19: iload 0
   20: iload 1
   21: iconst 1
   22: isub
   23: invokestatic #2
   26: iadd
```

27: ireturn

System.out.println main 8 argv java.lang.System.out

... System.out.println(8) s'exécute

et termine


_ _ _

```
public static void main(java.lang.String[]);
static int pair(int, int);
                                  Code:
  Code:
                                                  #4
                                                                 // Field java/lang/System.out:Ljava/io/PrintStream;
                                    0: getstatic
    0: iload 0
                                    3: iconst 2
    1: ifne
                 6
                                    4: iconst 2
    4: iload 1
                                                                  // Method pair:(II)I
                                    5: invokestatic #3
    5: ireturn
                                                                   // Method java/io/PrintStream.println:(I)V
                                    8: invokevirtual #5
    6: iload 1
                                    11: return
    7: ifne
                 12
   10: iload 0
   11: ireturn
   12: iload 0
   13: iconst 1
   14: isub
   15: iload 1
   16: invokestatic #2
   19: iload 0
                                              main
   20: iload 1
   21: iconst 1
   22: isub
   23: invokestatic #2
   26: iadd
   27: ireturn
```

argv


```
public static void main(java.lang.String[]);
static int pair(int, int);
                                  Code:
  Code:
                                                  #4
                                                                 // Field java/lang/System.out:Ljava/io/PrintStream;
                                    0: getstatic
    0: iload 0
                                    3: iconst 2
    1: ifne
                 6
                                    4: iconst 2
    4: iload 1
                                                                  // Method pair:(II)I
                                    5: invokestatic #3
    5: ireturn
                                                                   // Method java/io/PrintStream.println:(I)V
                                    8: invokevirtual #5
    6: iload 1
                                    11: return
    7: ifne
                 12
   10: iload 0
   11: ireturn
   12: iload 0
   13: iconst 1
   14: isub
   15: iload 1
   16: invokestatic #2
   19: iload 0
                                              main
   20: iload 1
   21: iconst 1
   22: isub
   23: invokestatic #2
   26: iadd
   27: ireturn
```

argv



Registres (chaque registre contient un *mot machine*)

Exemple d'enregistrement d'activation



Les tailles sont fixes, connues à la compilation, sauf pour des tableaux dont la taille dépend d'un argument.

Stratégies d'allocation des enregistrements d'activation : allocation statique

Tout doit être connu à la compilation taille totale des données

Une place est réservée par le compilateur pour chaque donnée

En fin de compilation toute l'allocation est réalisée

A l'exécution, plus aucun travail d'allocation n'est à faire

A l'exécution, chaque donnée est directement accédée

le programme n'a pas de calcul d'adresse à réaliser pour accéder aux données

- + facile à mettre en œuvre, exécution rapide, données compactes
- le compilateur doit tout connaître sur les données, pas de structures dynamiques, récursivité très limitée

Remarque : rien n'interdit d'allouer statiquement les enregistrements d'activation si la récursivité est interdite

code de f	données de f	code de g	données de g	

Stratégies d'allocation des enregistrements d'activation : allocation dans la pile

Toute exécution de fonction :

commence par la construction d'un enregistrement d'activation dans la pile termine par la destruction de cet enregistrement

les variables locales sont perdues en sortant de la fonction la durée de vie des variables locales interne à un bloc est celle de l'enregistrement d'activation

Nécessite deux registres de manipulation de pile :

Stack Pointer : désigne le sommet de pile

Base Pointer : désigne dans la pile l'enregistrement d'activation de la fonction en cours d'exécution

Le code de la fonction appelant f

crée l'enregistrement d'activation de f en haut de la pile avant l'appel détruit l'enregistrement après l'exécution de f

Il faut établir un protocole d'appel entre l'appelant et l'appelé


il définit le rôle de chacun dans la manipulation de l'enregistrement d'activation le compilateur implante ce protocole

il génère le code associé pour chaque appel de fonction ce protocole, très sollicité, est très dépendant de l'architecture matérielle

Responsabilité de l'appelé

Responsabilité de l'appelant

Sommet de pile



Enregistrement d'activation de l'appelé

Enregistrement d'activation de l'appelant


Exemple de protocole d'appel : l'appelant

- 1) réserve sur la pile de la place pour la valeur de retour
- 2) évalue dans l'ordre chacun des arguments et les empile
- 3) met sur la pile un pointeur sur son propre enregistrement d'activation
- 4) met sur la pile l'adresse de son instruction à exécuter au retour de l'appelant
- 5) l'exécution de l'appelé débute

l'appelé

- 6) sauvegarde sur la pile des registres qu'il va utiliser
- 7) réserve sur la pile de la place pour ses données locales
- 8) utilise ensuite la pile pour ses calculs. Dans le code généré par le compilateur, l'accès aux variables locales et paramètre est réalisé par un calcul relatif à BP
- 9) sauvegarde sa valeur de retour à l'emplacement réservé à cet effet par l'appelant
- 10) supprime de la pile la place réservée pour ses données locales
- 11) restaure les registres qu'il avait sauvegardé
- 12) se termine : saut à l'adresse de l'instruction que l'appelant avait mise sur la pile l'appelant
- 13) retire de la pile le pointeur sur son propre enregistrement d'activation
- 14) retire de la pile les arguments qu'il avait empilé
- 15) récupère la valeur de retour de l'appelé
- 16) continue son exécution

Sommet de pile



Dans le mécanisme précédent, le code de l'appelant généré par le compilateur accède aux variables locales et paramètres en calculant leurs adresses relativement à BP

Ce calcul n'est possible, si ce sont les valeurs des variables locales et paramètres qui sont empilées, que si leur taille est connue du compilateur

Dans le cas où la taille d'une valeur de variable locale ou de paramètre n'est pas connue du compilateur, il peut la remplacer par une structure.

Par exemple, remplacer un tableau de taille inconnue à *compile-time* par un couple (pointeur sur les données, nombre de données)

Plutôt que d'empiler la donnée de taille variable, le compilateur empile la structure, dont il connaît la taille

Le compilateur génère le code de l'appelant en sachant qu'il accède aux données à travers la structure

Remarque : l'utilisation de la structure est une indirection (perte de performances)

Remarque : la structure peut aussi être un simple pointeur.

C'est une des raisons pour lesquelles en C,

les chaînes de caractères sont toujours représentées par des pointeurs les tableaux sont toujours passés en paramètre de fonction par des pointeurs

Remarque : les données désignées par le compilateur peuvent être placées par l'appelant dans la zone « temporaires » de son propre enregistrement d'activation

Attention cependant, la zone réservée en mémoire pour la pile est souvent fixée par l'architecture matérielle et de petite taille!

dans le tas en réalisant de l'allocation dynamique


Pas de problème de taille, mais la gestion de l'allocation dynamique est lourde, peu efficace en terme de temps d'exécution et d'occupation de l'espace mémoire, et les accès peuvent être plus lents (défauts de page plus fréquents)

Une fonction f en appelle une autre g en lui passant un tableau t en paramètre :

 f commence par faire une copie de t (ici, sur sa zone « temporaires »)

2) dans son code préparant l'appel à *g*, le paramètre passé est en fait un pointeur

Sommet de pile



Enregistrement d'activation de l'appelé

BP

Enregistrement d'activation de l'appelant

Le processeur possède un ou plusieurs registres dédiés à la pile Exemple sur i86 :

SS (Stack Segment) : contient l'adresse de l'espace réservé à la pile

SP (Stack Pointer): contient l'adresse du sommet de pile relativement à SS

BP (Base Pointer) : contient l'adresse à partir de laquelle on trouve la sous-pile de la fonction en cours d'exécution

Les données locales (variables locales et paramètres) à l'exécution d'une fonction sont toutes mises dans la pile, à une adresse calculée par le compilateur relativement à BP et suivant un ordre convenu

Le processeur dispose de deux instructions *call* et *ret*

call x mets sur la pile l'adresse de l'instruction qui la suit, et demande au processeur d'exécuter l'instruction à l'adresse x

ret dépile, considère la valeur dépilée comme une adresse x, et demande au processeur d'exécuter l'instruction à l'adresse x

La pile contient donc :

des données provisoires des valeurs de paramètres de fonctions

des valeurs de variables locales de fonctions

des adresses d'instructions !

```
Exemple de convention d'appel (Il en existe beaucoup! (par processeur, compilateur, ...)):
     avant l'utilisation de call (pour appeler f, à l'adresse @f)
          réserver, sur le sommet de pile, la place nécessaire au stockage des variables
                locales de f
          empiler tous les arguments de f dans un ordre donné
     générer le call
          l'exécution de call mettra l'adresse de l'instruction suivant call en somme de pile
     le code de f
          commence par
                mettre bp en sommet de pile
                bp <- sp
          référence variables locales et arguments par leurs adresses relativement à BP
          garanti que, juste avant le ret, la pile aura
                a son sommet la valeur de retour,
                juste en dessous, l'ancienne valeur de BP
                (en donc, juste en dessous, l'adresse de l'instruction suivant le call)
          termine par
                dépiler la valeur de retour, la mettre dans un registre particulier
                restaurer l'ancienne valeur de BP
                exécuter le ret
```

10

. . .

8

```
Start of function f
push bp
cp bp,sp
push bx
push cx
push dx
      Local variable r
cp bx,bp
const cx.4
sub bx,cx
loadw ax.bx
push ax
pop ax
const bx,f:end
jmp bx
      End of function f
:f:end
pop dx
pop cx
pop bx
pop bp
ret
```

```
:main
       Start of function main
push bp
cp bp,sp
push bx
push cx
push dx
       Preparing function call for f
push ax
push ax
       Number constant
const ax.5
push ax
const ax,f
call ax
pop bx
pop bx
pop bx
push ax
pop ax
const bx,main:end
imp bx
       End of function main
:main:end
pop dx
pop cx
pop bx
pop bp
ret
```

```
int f(int r) { int a; int b; return r; }
int main() {
   return f(5);
24
22
                             IP
20
                             SP
                        8
18
16
                             BP
                        4
14
12
                             AX
                                   Processeur
```

BX

CX


DX

3

```
Start of function f
push bp
cp bp,sp
push bx
push cx
push dx
      Local variable r
cp bx.bp
const cx.4
sub bx,cx
loadw ax.bx
push ax
pop ax
const bx,f:end
jmp bx
      End of function f
:f:end
pop dx
pop cx
pop bx
pop bp
ret
```

```
:main
       Start of function main
push bp
cp bp,sp
push bx
push cx
push dx
       Preparing function call for f
push ax
push ax
       Number constant
const ax.5
push ax
const ax,f
call ax
pop bx
pop bx
pop bx
push ax
pop ax
const bx,main:end
imp bx
       End of function main
:main:end
pop dx
pop cx
pop bx
pop bp
ret
```

```
int f(int r) { int a; int b; return r; }
int main() {
   return f(5);
}
```



```
Start of function f
push bp
cp bp,sp
push bx
push cx
push dx
      Local variable r
cp bx.bp
const cx.4
sub bx,cx
loadw ax.bx
push ax
pop ax
const bx,f:end
jmp bx
      End of function f
:f:end
pop dx
pop cx
pop bx
pop bp
ret
```

```
:main
      Start of function main
push bp
cp bp,sp
push bx
push cx
bush dx
      Preparing function call for f
push ax
push ax
      Number constant
const ax.5
push ax
const ax.f
call ax
pop bx
pop bx
pop bx
push ax
pop ax
const bx.main:end
imp bx
      End of function main
:main:end
pop dx
pop cx
pop bx
pop bp
ret
```

```
int f(int r) { int a; int b; return r; }
int main() {
   return f(5);
24
22
                             IP
20
                             SP
                        12
18
16
                        4
                             BP
14
12
                             AX
                                   Processeur
10
                             BX
8
                        3
                             CX
```

DX

4

- - -

. . .

8

- - -

. . .

```
Start of function f
push bp
cp bp,sp
push bx
push cx
push dx
      Local variable r
cp bx.bp
const cx.4
sub bx,cx
loadw ax.bx
push ax
pop ax
const bx,f:end
jmp bx
      End of function f
:f:end
pop dx
pop cx
pop bx
pop bp
ret
```

```
:main
      Start of function main
push bp
cp bp,sp
push bx
push cx
bush dx
      Preparing function call for f
push ax
bush ax
      Number constant
const ax.5
push ax
const ax.f
call ax
pop bx
pop bx
pop bx
push ax
pop ax
const bx.main:end
imp bx
      End of function main
:main:end
pop dx
pop cx
pop bx
pop bp
ret
```

```
int f(int r) { int a; int b; return r; }
int main() {
   return f(5);
24
22
                             IP
20
                             SP
                        12
18
16
                        4
                             BP
14
12
                        5
                             AX
                                   Processeur
10
```

BX

CX

DX

3

```
Start of function f
push bp
cp bp,sp
push bx
push cx
push dx
      Local variable r
cp bx.bp
const cx.4
sub bx,cx
loadw ax.bx
push ax
pop ax
const bx,f:end
jmp bx
      End of function f
:f:end
pop dx
pop cx
pop bx
pop bp
ret
```

```
:main
      Start of function main
push bp
cp bp,sp
push bx
push cx
bush dx
      Preparing function call for f
push ax
bush ax
      Number constant
const ax.5
push ax
const ax.f
call ax
pop bx
pop bx
pop bx
push ax
pop ax
const bx.main:end
imp bx
      End of function main
:main:end
pop dx
рор сх
pop bx
pop bp
ret
```

```
int f(int r) { int a; int b; return r; }
int main() {
   return f(5);
24
22
                             IP
20
                             SP
                        14
18
16
                             BP
                        4
14
12
                        5
                             AX
                                   Processeur
        5
10
                        2
                             BX
8
                        3
                             CX
                             DX
                        4
```

- - -

. . .

```
Start of function f
push bp
cp bp,sp
push bx
push cx
push dx
      Local variable r
cp bx.bp
const cx.4
sub bx,cx
loadw ax.bx
push ax
pop ax
const bx,f:end
jmp bx
      End of function f
:f:end
pop dx
pop cx
pop bx
pop bp
ret
```

```
:main
      Start of function main
push bp
cp bp,sp
push bx
push cx
bush dx
      Preparing function call for f
push ax
bush ax
      Number constant
const ax.5
push ax
const ax.f
call ax
pop bx
pop bx
pop bx
push ax
pop ax
const bx.main:end
imp bx
      End of function main
:main:end
pop dx
рор сх
pop bx
pop bp
ret
```

```
int f(int r) { int a; int b; return r; }
int main() {
   return f(5);
24
22
                             IP
20
                             SP
                        14
18
16
                             BP
                        4
14
12
                        v(f)
                             AX
                                   Processeur
        5
10
                        2
                             BX
8
                        3
                             CX
                             DX
```

4

- - -

. . .

```
Start of function f
push bp
cp bp,sp
push bx
push cx
push dx
      Local variable r
cp bx.bp
const cx.4
sub bx,cx
loadw ax.bx
push ax
pop ax
const bx,f:end
jmp bx
      End of function f
:f:end
pop dx
pop cx
pop bx
pop bp
ret
```

```
:main
      Start of function main
push bp
cp bp,sp
push bx
push cx
bush dx
      Preparing function call for f
push ax
push ax
      Number constant
const ax.5
push ax
const ax.f
call ax; instruction à l'adresse x
pop bx; instruction à l'adresse x+2
pop bx
pop bx
push ax
pop ax
const bx,main:end
imp bx
      End of function main
:main:end
pop dx
pop cx
pop bx
pop bp
ret
```

```
int f(int r) { int a; int b; return r; }
int main() {
   return f(5);
24
22
                               IP
20
                         16
                               SP
18
16
                               BP
                         4
14
       x+2
                         v(f)
12
                               AX
                                     Processeur
        5
10
                         2
                               BX
                         3
                               CX
                               DX
                         4
        - - -
        . . .
```

```
Start of function f
push bp
cp bp,sp
push bx
push cx
push dx
      Local variable r
cp bx.bp
const cx.4
sub bx,cx
loadw ax.bx
push ax
pop ax
const bx.f:end
imp bx
      End of function f
:f:end
pop dx
pop cx
pop bx
pop bp
ret
```

```
:main
      Start of function main
push bp
cp bp,sp
push bx
push cx
bush dx
      Preparing function call for f
push ax
push ax
      Number constant
const ax.5
push ax
const ax.f
call ax; instruction à l'adresse x
pop bx; instruction à l'adresse x+2
pop bx
pop bx
push ax
pop ax
const bx,main:end
imp bx
      End of function main
:main:end
pop dx
pop cx
pop bx
pop bp
ret
```

```
int f(int r) { int a; int b; return r; }
int main() {
   return f(5);
24
22
                               IP
20
                               SP
                         18
18
16
        4
                               BP
                         4
14
       x+2
                         v(f)
12
                               AX
                                     Processeur
        5
10
                               BX
8
                         3
                               CX
                               DX
                         4
        - - -
        . . .
```

```
Start of function f
push bp
cp bp,sp
push bx
push cx
push dx
      Local variable r
cp bx.bp
const cx.4
sub bx,cx
loadw ax.bx
push ax
pop ax
const bx,f:end
jmp bx
      End of function f
:f:end
pop dx
pop cx
pop bx
pop bp
ret
```

```
:main
      Start of function main
push bp
cp bp,sp
push bx
push cx
bush dx
      Preparing function call for f
push ax
push ax
      Number constant
const ax.5
push ax
const ax.f
call ax; instruction à l'adresse x
pop bx; instruction à l'adresse x+2
pop bx
pop bx
push ax
pop ax
const bx,main:end
imp bx
      End of function main
:main:end
pop dx
pop cx
pop bx
pop bp
ret
```

```
int f(int r) { int a; int b; return r; }
int main() {
   return f(5);
24
22
                               IP
20
                               SP
                         18
18
16
        4
                         18
                               BP
14
       x+2
                         v(f)
12
                               AX
                                     Processeur
        5
10
                         2
                               BX
8
                         3
                               CX
                               DX
                         4
        - - -
        . . .
```

```
Start of function f
push bp
cp bp,sp
push bx
push cx
push dx
      Local variable r
cp bx.bp
const cx.4
sub bx,cx
loadw ax.bx
push ax
pop ax
const bx,f:end
jmp bx
      End of function f
:f:end
pop dx
pop cx
pop bx
pop bp
ret
```

```
:main
      Start of function main
push bp
cp bp,sp
push bx
push cx
bush dx
      Preparing function call for f
push ax
push ax
      Number constant
const ax.5
push ax
const ax.f
call ax; instruction à l'adresse x
pop bx; instruction à l'adresse x+2
pop bx
pop bx
push ax
pop ax
const bx,main:end
imp bx
      End of function main
:main:end
pop dx
pop cx
pop bx
pop bp
ret
```

```
int f(int r) { int a; int b; return r; }
int main() {
   return f(5);
24
22
                               IP
20
         2
                               SP
18
                          . . .
16
         4
                               BP
                          18
14
       x+2
                          v(f)
12
                               AX
                                      Processeur
         5
10
                          2
                               BX
                          3
                               CX
                               DX
                          4
        - - -
        . . .
```

24

22

20

18

16

14

12

10

```
Start of function f
push bp
cp bp,sp
push bx
push cx
push dx
      Local variable r
cp bx.bp
const cx.4
sub bx,cx
loadw ax.bx
push ax
pop ax
const bx.f:end
jmp bx
      End of function f
:f:end
pop dx
pop cx
pop bx
pop bp
ret
```

```
:main
      Start of function main
push bp
cp bp,sp
push bx
push cx
bush dx
      Preparing function call for f
push ax
push ax
      Number constant
const ax.5
push ax
const ax.f
call ax; instruction à l'adresse x
pop bx; instruction à l'adresse x+2
pop bx
pop bx
push ax
pop ax
const bx,main:end
imp bx
      End of function main
:main:end
pop dx
pop cx
pop bx
pop bp
ret
```

```
int f(int r) { int a; int b; return r; }
int main() {
   return f(5);
        3
                               IP
        2
                               SP
        4
                               BP
                         18
       x+2
                         v(f)
                               AX
                                     Processeur
        5
                         2
                               BX
                         3
                               CX
                               DX
                         4
        - - -
        . . .
```

```
Start of function f
push bp
cp bp,sp
push bx
push cx
push dx
      Local variable r
cp bx.bp
const cx.4
sub bx,cx
loadw ax.bx
push ax
pop ax
const bx.f:end
jmp bx
      End of function f
:f:end
pop dx
pop cx
pop bx
pop bp
ret
```

```
:main
      Start of function main
push bp
cp bp,sp
push bx
push cx
bush dx
      Preparing function call for f
push ax
push ax
      Number constant
const ax.5
push ax
const ax.f
call ax; instruction à l'adresse x
pop bx; instruction à l'adresse x+2
pop bx
pop bx
push ax
pop ax
const bx,main:end
imp bx
      End of function main
:main:end
pop dx
pop cx
pop bx
pop bp
ret
```

```
int f(int r) { int a; int b; return r; }
int main() {
   return f(5);
24
        4
22
        3
                               IP
20
        2
                               SP
18
16
        4
                               BP
                         18
14
       x+2
                         v(f)
12
                               AX
                                     Processeur
        5
10
                         2
                               BX
                         3
                               CX
                               DX
                         4
        - - -
        . . .
```

24

22

20

18

16

14

12

10

```
Start of function f
push bp
cp bp,sp
push bx
push cx
push dx
      Local variable r
cp bx.bp
const cx.4
sub bx,cx
loadw ax.bx
push ax
pop ax
const bx.f:end
jmp bx
      End of function f
:f:end
pop dx
pop cx
pop bx
pop bp
ret
```

```
:main
      Start of function main
push bp
cp bp,sp
push bx
push cx
bush dx
      Preparing function call for f
push ax
push ax
      Number constant
const ax.5
push ax
const ax.f
call ax; instruction à l'adresse x
pop bx; instruction à l'adresse x+2
pop bx
pop bx
push ax
pop ax
const bx,main:end
imp bx
      End of function main
:main:end
pop dx
pop cx
pop bx
pop bp
ret
```

```
int f(int r) { int a; int b; return r; }
int main() {
   return f(5);
        4
        3
                               IP
        2
                               SP
        4
                               BP
                          18
       x+2
                         v(f)
                               AX
                                     Processeur
        5
                          18
                               BX
                         3
                               CX
                               DX
                         4
        - - -
        . . .
```

24

22

20

18

16

14

12

10

```
Start of function f
push bp
cp bp,sp
push bx
push cx
push dx
      Local variable r
cp bx.bp
const cx.4
sub bx.cx
loadw ax.bx
push ax
pop ax
const bx.f:end
jmp bx
      End of function f
:f:end
pop dx
pop cx
pop bx
pop bp
ret
```

```
:main
      Start of function main
push bp
cp bp,sp
push bx
push cx
bush dx
      Preparing function call for f
push ax
push ax
      Number constant
const ax.5
push ax
const ax.f
call ax; instruction à l'adresse x
pop bx; instruction à l'adresse x+2
pop bx
pop bx
push ax
pop ax
const bx,main:end
imp bx
      End of function main
:main:end
pop dx
pop cx
pop bx
pop bp
ret
```

```
int f(int r) { int a; int b; return r; }
int main() {
   return f(5);
         4
        3
                               IP
        2
                               SP
        4
                               BP
                          18
       x+2
                         v(f)
                               AX
                                     Processeur
        5
                          18
                               BX
                         4
                               CX
                               DX
                         4
        - - -
        . . .
```

```
Start of function f
push bp
cp bp,sp
push bx
push cx
push dx
      Local variable r
cp bx.bp
const cx.4
sub bx.cx
loadw ax.bx
push ax
pop ax
const bx.f:end
jmp bx
      End of function f
:f:end
pop dx
pop cx
pop bx
pop bp
ret
```

```
:main
      Start of function main
push bp
cp bp,sp
push bx
push cx
bush dx
      Preparing function call for f
push ax
push ax
      Number constant
const ax.5
push ax
const ax.f
call ax; instruction à l'adresse x
pop bx; instruction à l'adresse x+2
pop bx
pop bx
push ax
pop ax
const bx,main:end
imp bx
      End of function main
:main:end
pop dx
pop cx
pop bx
pop bp
ret
```

```
int f(int r) { int a; int b; return r; }
int main() {
   return f(5);
24
         4
22
        3
                               IP
20
        2
                               SP
18
16
        4
                               BP
                         18
14
       x+2
                         v(f)
12
                               AX
                                     Processeur
        5
10
                         14
                               BX
                         4
                               CX
                               DX
                         4
        - - -
        . . .
```

```
Start of function f
push bp
cp bp,sp
push bx
push cx
push dx
      Local variable r
cp bx.bp
const cx.4
sub bx,cx
loadw ax,bx
push ax
pop ax
const bx.f:end
jmp bx
      End of function f
:f:end
pop dx
pop cx
pop bx
pop bp
ret
```

```
:main
      Start of function main
push bp
cp bp,sp
push bx
push cx
bush dx
      Preparing function call for f
push ax
push ax
      Number constant
const ax.5
push ax
const ax.f
call ax; instruction à l'adresse x
pop bx; instruction à l'adresse x+2
pop bx
pop bx
push ax
pop ax
const bx,main:end
imp bx
      End of function main
:main:end
pop dx
pop cx
pop bx
pop bp
ret
```

```
int f(int r) { int a; int b; return r; }
int main() {
   return f(5);
24
        4
22
        3
                               IP
20
        2
                               SP
18
                          ...
16
        4
                               BP
                          18
14
       x+2
                         5
12
                               AX
                                     Processeur
        5
10
                          14
                               BX
                         4
                               CX
                               DX
                         4
        - - -
        . . .
```

```
Start of function f
push bp
cp bp,sp
push bx
push cx
push dx
      Local variable r
cp bx.bp
const cx.4
sub bx,cx
loadw ax.bx
push ax
pop ax
const bx,f:end
jmp bx
      End of function f
:f:end
pop dx
pop cx
pop bx
pop bp
ret
```

```
:main
      Start of function main
push bp
cp bp,sp
push bx
push cx
bush dx
      Preparing function call for f
push ax
push ax
      Number constant
const ax.5
push ax
const ax.f
call ax; instruction à l'adresse x
pop bx; instruction à l'adresse x+2
pop bx
pop bx
push ax
pop ax
const bx,main:end
imp bx
      End of function main
:main:end
pop dx
pop cx
pop bx
pop bp
ret
```

```
int f(int r) { int a; int b; return r; }
int main() {
   return f(5);
        5
24
        4
22
        3
                               IP
20
        2
                               SP
18
16
        4
                               BP
                         18
14
       x+2
                         5
12
                               AX
                                     Processeur
        5
10
                         14
                               BX
8
                         4
                               CX
                               DX
                         4
        - - -
        . . .
```

24

22

20

18

16

14

12

10

```
Start of function f
push bp
cp bp,sp
push bx
push cx
push dx
      Local variable r
cp bx.bp
const cx.4
sub bx,cx
loadw ax.bx
push ax
pop ax
const bx,f:end
imp bx
      End of function f
:f:end
pop dx
pop cx
pop bx
pop bp
ret
```

```
:main
      Start of function main
push bp
cp bp,sp
push bx
push cx
bush dx
      Preparing function call for f
push ax
push ax
      Number constant
const ax.5
push ax
const ax.f
call ax; instruction à l'adresse x
pop bx; instruction à l'adresse x+2
pop bx
pop bx
push ax
pop ax
const bx,main:end
imp bx
      End of function main
:main:end
pop dx
pop cx
pop bx
pop bp
ret
```

```
int f(int r) { int a; int b; return r; }
int main() {
   return f(5);
        4
        3
                               IP
        2
                               SP
        4
                               BP
                         18
       x+2
                         5
                               AX
                                     Processeur
        5
                         14
                               BX
                         4
                               CX
                               DX
                         4
        - - -
        . . .
```

24

22

20

18

16

14

12

10

```
Start of function f
push bp
cp bp,sp
push bx
push cx
push dx
      Local variable r
cp bx.bp
const cx.4
sub bx,cx
loadw ax.bx
push ax
pop ax
const bx,f:end
jmp bx
      End of function f
:f:end
pop dx
pop cx
pop bx
pop bp
ret
```

```
:main
      Start of function main
push bp
cp bp,sp
push bx
push cx
bush dx
      Preparing function call for f
push ax
push ax
      Number constant
const ax.5
push ax
const ax.f
call ax; instruction à l'adresse x
pop bx; instruction à l'adresse x+2
pop bx
pop bx
push ax
pop ax
const bx,main:end
imp bx
      End of function main
:main:end
pop dx
pop cx
pop bx
pop bp
ret
```

```
int f(int r) { int a; int b; return r; }
int main() {
   return f(5);
         4
         3
                                IP
         2
                                SP
         4
                                BP
                          18
        x+2
                          5
                                AX
                                      Processeur
         5
                                BX
                         v(f:end)
                          4
                                CX
                                DX
                          4
        - - -
        . . .
```

24

22

20

18

16

14

12

10

```
Start of function f
push bp
cp bp,sp
push bx
push cx
push dx
      Local variable r
cp bx.bp
const cx.4
sub bx,cx
loadw ax.bx
push ax
pop ax
const bx.f:end
imp bx
      End of function f
:f:end
pop dx
pop cx
pop bx
pop bp
ret
```

```
:main
      Start of function main
push bp
cp bp,sp
push bx
push cx
bush dx
      Preparing function call for f
push ax
push ax
      Number constant
const ax.5
push ax
const ax.f
call ax; instruction à l'adresse x
pop bx; instruction à l'adresse x+2
pop bx
pop bx
push ax
pop ax
const bx,main:end
imp bx
      End of function main
:main:end
pop dx
pop cx
pop bx
pop bp
ret
```

```
int f(int r) { int a; int b; return r; }
int main() {
   return f(5);
         4
         3
                                IP
         2
                                SP
         4
                                BP
                          18
        x+2
                          5
                                AX
                                      Processeur
         5
                                BX
                         v(f:end)
                          4
                                CX
                                DX
                          4
        - - -
        . . .
```

```
Start of function f
push bp
cp bp,sp
push bx
push cx
push dx
      Local variable r
cp bx.bp
const cx.4
sub bx,cx
loadw ax.bx
push ax
pop ax
const bx,f:end
jmp bx
      End of function f
:f:end
pop dx
pop cx
pop bx
pop bp
ret
```

```
:main
      Start of function main
push bp
cp bp,sp
push bx
push cx
bush dx
      Preparing function call for f
push ax
push ax
      Number constant
const ax.5
push ax
const ax.f
call ax; instruction à l'adresse x
pop bx; instruction à l'adresse x+2
pop bx
pop bx
push ax
pop ax
const bx,main:end
imp bx
      End of function main
:main:end
pop dx
pop cx
pop bx
pop bp
ret
```

```
int f(int r) { int a; int b; return r; }
int main() {
   return f(5);
24
         4
22
         3
                                IP
20
         2
                                SP
18
                          ...
16
         4
                                BP
                          18
14
        x+2
12
                          5
                                AX
                                      Processeur
         5
10
                                BX
                         v(f:end)
                          4
                                CX
                                DX
                          4
        - - -
        . . .
```

24

22

20

18

16

14

12

10

```
Start of function f
push bp
cp bp,sp
push bx
push cx
push dx
      Local variable r
cp bx.bp
const cx.4
sub bx,cx
loadw ax.bx
push ax
pop ax
const bx,f:end
jmp bx
      End of function f
:f:end
pop dx
pop cx
pop bx
pop bp
ret
```

```
:main
      Start of function main
push bp
cp bp,sp
push bx
push cx
bush dx
      Preparing function call for f
push ax
push ax
      Number constant
const ax.5
push ax
const ax.f
call ax; instruction à l'adresse x
pop bx; instruction à l'adresse x+2
pop bx
pop bx
push ax
pop ax
const bx,main:end
imp bx
      End of function main
:main:end
pop dx
pop cx
pop bx
pop bp
ret
```

```
int f(int r) { int a; int b; return r; }
int main() {
   return f(5);
         4
         3
                                IP
         2
                                SP
                          ...
         4
                                BP
                          18
        x+2
                          5
                                AX
                                      Processeur
         5
                                BX
                         v(f:end)
                          3
                                CX
                                DX
                          4
        - - -
        . . .
```

24

22

20

18

16

14

12

10

```
Start of function f
push bp
cp bp,sp
push bx
push cx
push dx
      Local variable r
cp bx.bp
const cx.4
sub bx,cx
loadw ax.bx
push ax
pop ax
const bx,f:end
jmp bx
      End of function f
:f:end
pop dx
pop cx
pop bx
pop bp
ret
```

```
:main
      Start of function main
push bp
cp bp,sp
push bx
push cx
bush dx
      Preparing function call for f
push ax
push ax
      Number constant
const ax.5
push ax
const ax.f
call ax; instruction à l'adresse x
pop bx; instruction à l'adresse x+2
pop bx
pop bx
push ax
pop ax
const bx,main:end
imp bx
      End of function main
:main:end
pop dx
pop cx
pop bx
pop bp
ret
```

```
int f(int r) { int a; int b; return r; }
int main() {
   return f(5);
         4
         3
                               IP
         2
                               SP
                          ...
         4
                               BP
                          18
       x+2
                          5
                               AX
                                     Processeur
         5
                          2
                               BX
                          3
                               CX
                               DX
                          4
        - - -
        . . .
```

```
Start of function f
push bp
cp bp,sp
push bx
push cx
push dx
      Local variable r
cp bx.bp
const cx.4
sub bx,cx
loadw ax.bx
push ax
pop ax
const bx.f:end
jmp bx
      End of function f
:f:end
pop dx
pop cx
pop bx
pop bp
ret
```

```
:main
      Start of function main
push bp
cp bp,sp
push bx
push cx
bush dx
      Preparing function call for f
push ax
push ax
      Number constant
const ax.5
push ax
const ax.f
call ax; instruction à l'adresse x
pop bx; instruction à l'adresse x+2
pop bx
pop bx
push ax
pop ax
const bx,main:end
imp bx
      End of function main
:main:end
pop dx
pop cx
pop bx
pop bp
ret
```

```
int f(int r) { int a; int b; return r; }
int main() {
   return f(5);
24
         4
22
         3
                               IP
20
         2
                               SP
18
                          ...
16
         4
                               BP
                          4
14
       x+2
12
                          5
                               AX
                                     Processeur
         5
10
                          2
                               BX
8
                          3
                               CX
                               DX
                          4
        - - -
        . . .
```

```
Start of function f
push bp
cp bp,sp
push bx
push cx
push dx
      Local variable r
cp bx.bp
const cx.4
sub bx,cx
loadw ax.bx
push ax
pop ax
const bx.f:end
jmp bx
      End of function f
:f:end
pop dx
pop cx
pop bx
pop bp
ret
```

```
:main
      Start of function main
push bp
cp bp,sp
push bx
push cx
bush dx
      Preparing function call for f
push ax
push ax
      Number constant
const ax.5
push ax
const ax.f
call ax; instruction à l'adresse x
pop bx; instruction à l'adresse x+2
pop bx
pop bx
push ax
pop ax
const bx,main:end
imp bx
      End of function main
:main:end
pop dx
pop cx
pop bx
pop bp
ret
```

```
int f(int r) { int a; int b; return r; }
int main() {
   return f(5);
24
        4
22
        3
                               IP
20
        2
                               SP
18
                          ...
16
        4
                               BP
                          4
14
       x+2
12
                          5
                               AX
                                     Processeur
        5
10
                          2
                               BX
8
                          3
                               CX
                               DX
                          4
        - - -
        . . .
```

```
Start of function f
push bp
cp bp,sp
push bx
push cx
push dx
      Local variable r
cp bx.bp
const cx.4
sub bx,cx
loadw ax.bx
push ax
pop ax
const bx.f:end
jmp bx
      End of function f
:f:end
pop dx
pop cx
pop bx
pop bp
ret
```

```
:main
      Start of function main
push bp
cp bp,sp
push bx
push cx
bush dx
      Preparing function call for f
push ax
push ax
      Number constant
const ax.5
push ax
const ax.f
call ax; instruction à l'adresse x
pop bx; instruction à l'adresse x+2
pop bx
pop bx
push ax
pop ax
const bx,main:end
imp bx
      End of function main
:main:end
pop dx
pop cx
pop bx
pop bp
ret
```

```
int f(int r) { int a; int b; return r; }
int main() {
   return f(5);
24
        4
22
        3
                               IP
20
        2
                               SP
18
                         ...
        4
16
                               BP
                         4
14
       x+2
12
                         5
                               AX
                                     Processeur
        5
10
                         5
                               BX
8
                         3
                               CX
                               DX
                         4
        - - -
        . . .
```

```
Start of function f
push bp
cp bp,sp
push bx
push cx
push dx
      Local variable r
cp bx.bp
const cx.4
sub bx,cx
loadw ax.bx
push ax
pop ax
const bx.f:end
jmp bx
      End of function f
:f:end
pop dx
pop cx
pop bx
pop bp
ret
```

```
:main
      Start of function main
push bp
cp bp,sp
push bx
push cx
bush dx
      Preparing function call for f
push ax
push ax
      Number constant
const ax.5
push ax
const ax.f
call ax; instruction à l'adresse x
pop bx; instruction à l'adresse x+2
pop bx
pop bx
push ax
pop ax
const bx,main:end
imp bx
      End of function main
:main:end
pop dx
pop cx
pop bx
pop bp
ret
```

```
int f(int r) { int a; int b; return r; }
int main() {
   return f(5);
24
        4
22
        3
                               IP
20
        2
                               SP
18
                          ...
        4
16
                               BP
                         4
14
       x+2
12
                               AX
                                     Processeur
        5
10
                               BX
8
                         3
                               CX
                               DX
                         4
        - - -
        . . .
```

```
Start of function f
push bp
cp bp,sp
push bx
push cx
push dx
      Local variable r
cp bx.bp
const cx.4
sub bx,cx
loadw ax.bx
push ax
pop ax
const bx.f:end
jmp bx
      End of function f
:f:end
pop dx
pop cx
pop bx
pop bp
ret
```

```
:main
      Start of function main
push bp
cp bp,sp
push bx
push cx
bush dx
      Preparing function call for f
push ax
push ax
      Number constant
const ax.5
push ax
const ax.f
call ax; instruction à l'adresse x
pop bx; instruction à l'adresse x+2
pop bx
pop bx
push ax
pop ax
const bx,main:end
imp bx
      End of function main
:main:end
pop dx
pop cx
pop bx
pop bp
ret
```

```
int f(int r) { int a; int b; return r; }
int main() {
   return f(5);
24
        4
22
        3
                               IP
20
        2
                               SP
18
                         ...
        4
16
                               BP
                         4
14
       x+2
12
                               AX
                                     Processeur
        5
10
                               BX
8
                         3
                               CX
                               DX
                         4
        - - -
        . . .
```

Notion de bloc

Notion introduite par ALGOL (1960).

Les blocs comportent une partie déclaration de variables locales et des instructions.

Les blocs ne doivent pas se chevaucher (imbrication hiérarchique).

La portée de la déclaration d'une variable s'étend à tous les blocs inclus où cette variable n'est pas redéclarée.

Ceci permet d'implanter les blocs dans la pile de contrôle comme des procédures sans paramètres et ne retournant pas de valeur.

la notion d'enregistrement d'activation est généralisée aux blocs, avec une version simplifiée entrée dans le bloc : création d'un nouvel enregistrement d'activation sortie du bloc : suppression de l'enregistrement d'activation peut être simplifié

pas d'enregistrement d'activation pour les blocs seulement pour les fonctions les enregistrements d'activation des fonctions contiennent de la place pour toutes les variables locales

les noms des variables locales et leurs portées sont gérées par du masquage

Attention aux instructions de saut, si les sauts sont autorisés !

Table des symboles

Elle associe des informations à chaque symbole (nom de variable, fonction, classe, étiquette, ...) Par exemple :

- classe de stockage (tas, pile, zone des constantes, ...)
- accessibilité (restreinte, ouverte, ...)
- adresse (pour les fonctions, les I-values, ...)
- type (entier, réel, fonction, ...)
- nature (variable globale, locale, paramètre de fonction, classe, interface, ...)
- valeur (pour les langages fonctionnels, par exemple)

Table: chaîne -> information

Fonctionnalités de base :

- insertion d'une nouvelle association chaîne -> information
- suppression des informations associées à une chaîne
- recherche des informations associées à une chaîne

Fonctionnalités avancées

- intégration de la notion de portée des identificateurs

Implantations courantes

- liste chaînée
- table de hachage

Table des symboles, portée des identificateurs et masquage

```
Tout symbole défini dans un bloc est associé au bloc
Les autres symboles sont globaux
```

```
int a = 1;

void f(int a) {
    int b = 2;
    printf(«%d %d », a, b);
    {
        int a = 3;
        printf(«%d », a, b);
        {
            int a = 4;
            printf(«%d », a, b);
        }
        printf(«%d », a, b);
    }
    printf(«%d », a, b);
}
```

```
int a_0 = 1;
void f(int a_1) \{
        int b_1 = 2;
        printf(<%d %d >, a_1, b_1);
        {2
                int a_2 = 3;
                printf(^{\circ}%d ^{\circ}, a_{2}, b_{1});
                        int a_3 = 4;
                         printf(\langle wd \rangle, a_3, b_1);
                printf(\langle wd \rangle, a<sub>2</sub>, b<sub>1</sub>);
        printf(\text{``d'}, a_1, b_1);
}<sub>1</sub>
```

Table des symboles, portée des identificateurs et masquage

La numérotation peut être réalisée pendant l'analyse syntaxique

Les noms peuvent aussi être modifiés pendant l'analyse syntaxique a -> a#bloc

Remarque:

à l'extérieur d'un bloc, l'ensemble des symboles qui y sont définis sont inutiles mais la durée de vie de l'espace mémoire désigné par le symbole peut être supérieure à celle du symbole

Gestion efficace des symboles

Ils sont ajoutés dans la table des symboles ou dans l'environnement d'exécution à l'entrée du bloc

Ils sont supprimés de la table des symboles ou de l'environnement d'exécution à la sortie du bloc

Ils sont accédés prioritairement aux autres

Dernier élément inséré en tête de liste. Exemple pour un schéma de traduction LR :

```
prog : prog definition | definition ;
definition: function | decl;
function: type ID '(' lparams ')' {
       S'il existe déjà une fonction de nom ID
              Erreur (ni surcharge ni redéfinition)
       Sinon
              Calcul des informations
              Ajouter (ID, infos) à la table
} blocinstr ; {
       Supprimer les |$4| premiers éléments
              de la table
lparams : lparams ',' param {
       S'il existe déjà un paramètre de même nom que
                     celui de $3
              Erreur
       Sinon
              $$ = ajouter $3 à $1 }
 param \{ \$\$ = \$1 : \}
```

```
param: type ID; {
               Calcul des informations
               Ajouter (ID, infos) à la table
               $$ = nouvelle liste ($1, $2)
de la table
idecl : Idecl decl {
       S'il existe déjà dans $1 une déclaration de
                      même nom que celui de $2
               Erreur
       Sinon
               $$ = ajouter $2 à $1
 %empty
               { $$ = liste vide ; };
decl: type ID';' {
       Calcul des informations
       Ajouter (ID, informations) à la table
       $ = nouvelle liste ($1, $2)
instr dépendant de ID: ...
       rechercher ID dans la table
       utiliser sa valeur...
```

Table des symboles, portée des

identificateurs et masquage : implantation par liste chaînée


```
int a = 1;
void f(int a) {
    int b = 2:
     printf(«%d %d », a, b);
         int a = 3:
         printf(«%d », a, b);
              int a = 4;
              printf(«%d », a, b);
         printf(«%d », a, b);
    printf(«%d », a, b);
```

```
int a = 1;
void f(int a) {
     int b = 2:
     printf(«%d %d », a, b);
         int a = 3:
         printf(«%d », a, b);
              int a = 4;
              printf(«%d », a, b);
         printf(«%d », a, b);
     printf(«%d », a, b);
```

```
(a,infos)
                                                                       (a,infos)
int a = 1;
void f(int a)√
    int b = 2:
     printf(«%d %d », a, b);
         int a = 3:
         printf(«%d », a, b);
              int a = 4;
              printf(«%d », a, b);
         printf(«%d », a, b);
    printf(«%d », a, b);
```

```
int a = 1;


void f(int a) {
    int b = 2;
    printf(«%d %d », a, b);
    {
        int a = 3;
        printf(«%d », a, b);
        {
            int a = 4;
            printf(«%d », a, b);
        }
        printf(«%d », a, b);
    }
    printf(«%d », a, b);
}
```



```
int a = 1;


void f(int a) {
    int b = 2;
    printf(«%d %d », a, b);
    {
        int a = 3;
        printf(«%d », a, b);
        {
            int a = 4;
            printf(«%d », a, b);
        }
        printf(«%d », a, b);
}

printf(«%d », a, b);
}
```




```
int a = 1;

void f(int a) {
    int b = 2;
    printf(«%d %d », a, b);
    {
        int a = 3;
        printf(«%d », a, b);
        {
            int a = 4;
            printf(«%d », a, b);
        }
        printf(«%d », a, b);
    }
    printf(«%d », a, b);
}
```




```
int a = 1;

void f(int a) {
    int b = 2;
    printf(«%d %d », a, b);
    {
        int a = 3;
        printf(«%d », a, b);
        {
            int a = 4;
            printf(«%d », a, b);
        }
        printf(«%d », a, b);
    }
    printf(«%d », a, b);
}
```



```
int a = 1;
void f(int a) {
    int b = 2:
    printf(«%d %d », a, b);
         int a = 3:
         printf(«%d », a, b);
              int a = 4;
              printf(«%d », a, b);
         printf(«%d », a, b);
    printf(«%d », a, b);
```



```
int a = 1;
void f(int a) {
    int b = 2:
     printf(«%d %d », a, b);
         int a = 3:
         printf(«%d », a, b);
              int a = 4;
              printf(«%d », a, b);
         printf(«%d », a, b);
    printf(«%d », a, b);
```

Evolution de la liste pendant l'analyse syntaxique

```
int a = 1;
void f(int a) {
    int b = 2:
    printf(«%d %d », a, b);
         int a = 3:
         printf(«%d », a, b);
              int a = 4;
              printf(«%d », a, b);
         printf(«%d », a, b);
    printf(«%d », a, b);
```



Avantage:

très simple à implanter

Inconvénient :

- complexités des opérations élémentaires : linéaire

Alternative : table de hachage

- plus difficile à implanter
- moins économique en mémoire
- complexité des opérations élémentaires : constante

Hachage « fermé » : pas de re-hachage, le hachage amène à la liste des éléments ayant la même valeur de hachage

En sortie de bloc, il faut pouvoir détruire tous les symboles du bloc gestion d'une liste de pointeurs de maillons de la table de hachage, qu'on utilise pour réaliser les destructions

chaque maillon de liste de la table de hachage doit pouvoir être supprimé en temps constant

il contient l'adresse du pointeur qui le désigne

```
int a = 1;
void f(int a) {
     int b = 2:
     printf(«%d %d », a, b);
         int a = 3:
         printf(«%d », a, b);
              int a = 4;
              printf(«%d », a, b);
         printf(«%d », a, b);
     printf(«%d », a, b);
```

```
int a = 1;

void f(int a) {
    int b = 2;
    printf(«%d %d », a, b);
    {
        int a = 3;
        printf(«%d », a, b);
        {
            int a = 4;
            printf(«%d », a, b);
        }
        printf(«%d », a, b);
    }
    printf(«%d », a, b);
}
```

```
int a = 1;
void f(int a)

▼
     int b = 2:
     printf(«%d %d », a, b);
         int a = 3:
         printf(«%d », a, b);
                                                        (a,infos)
                                                                                 (a,infos)
              int a = 4;
              printf(«%d », a, b);
         printf(«%d », a, b);
     printf(«%d », a, b);
```

```
int a = 1;
void f(int a) {
     int b = 2:
     printf(^{\circ}d^{\rightarrow}, a, b);
                                                            (b,infos)
          int a = 3:
          printf(«%d », a, b);
                                                                                       (a,infos)
                                                            (a,infos)
               int a = 4;
               printf(«%d », a, b);
          printf(«%d », a, b);
     printf(«%d », a, b);
```

```
int a = 1;

void f(int a) {
    int b = 2;
    printf(«%d %d », a, b);
    {
        int a = 3;
        printf(«%d », a, b);
        }
        printf(«%d », a, b);
    }
    printf(«%d », a, b);
    }
    printf(«%d », a, b);
}

printf(«%d », a, b);
```

```
int a = 1;

void f(int a) {
    int b = 2;
    printf(«%d %d », a, b);
    {
        int a = 3;
        printf(«%d », a, b);
        }
        printf(«%d », a, b);
    }
    printf(«%d », a, b);
}

printf(«%d », a, b);
}
```

```
int a = 1;
void f(int a) {
    int b = 2:
     printf(«%d %d », a, b);
                                                       (b,infos)
         int a = 3:
         printf(«%d », a, b);
                                                                                 (a,infos)
                                                        (a,infos)
              int a = 4;
              printf(«%d », a, b);
         printf(«%d », a, b);
     printf(«%d », a, b);
```

```
int a = 1;
void f(int a) {
    int b = 2:
     printf(«%d %d », a, b);
         int a = 3:
         printf(«%d », a, b);
                                                         (a,infos)
              int a = 4;
              printf(«%d », a, b);
         printf(«%d », a, b);
    printf(«%d », a, b);
```

Ils sont tous globaux, comme en C.

Les espaces mémoires correspondant peuvent être localisés dans une zone globale et statique Facilite l'implantation de langages dans lesquels les fonctions peuvent être des paramètres ou des retours d'autres fonctions

```
int m;
int f(int n) { return m+n; }
int g(int n) { return m*n; }
void b(int x(int n)) { printf("%d", x(2)); }
int main(int argc, char *argv[]) {
    m=0;
    b(f);
    b(g);
    return EXIT_SUCCESS;
}
```

La zone de stockage globale contient les codes de f, g, b, main l'espace mémoire pour m

Leurs adresses sont calculées par le compilateur et sont fixes

Les fonctions sont passées en paramètres en utilisant leurs adresses

Idem si une fonction doit en retourner une autre

```
program Statique (input, output)
    var r : real;

procedure Montrer :
    begin write r end;

procedure A :
    var r : real;
    begin r:=0.125; Montrer end;

begin
    r:= 0.25;
    Montrer; A;
    end.

Affichage : 0.25 0.25
```

```
N'existe pas en C, existe en Pascal:
 program Trier (input, output) ;
    var t : array [0..10] of integer ;
    x : integer ;
    procedure Echanger (i, j :integer) ;
       begin
          x := t [i] ; t [i] := t [j] ; t [j] := x
       end { Echanger } ;
    procedure TriRapide (m, n : integer) ;
       var k, v : integer ;
       function Partition (y, z : integer) : integer ;
          var i, j : integer ;
             begin ... t ... v ... Echanger (i,j) ; ...
             end { Partition } ;
       begin ... end { TriRapide } ;
    begin ... end { Trier }.
```

L'implantation utilise la *profondeur d'imbrication* d'une fonction, définie de manière similaire à celle sur les blocs

On ajoute aux enregistrements d'activation un lien d'accès :

si la procédure P est immédiatement imbriquée dans T dans le source, le lien d'accès d'un enregistrement d'activation de P référence le lien d'accès de l'enregistrement d'activation le plus récent de T.

Mise en place des liens d'accès (P de profondeur *np* appelle X de profondeur *nx*) :

np < nx : X est nécessairement déclarée dans P.


Le lien d'accès de l'enregistrement de X référence celui de P


sinon : X et P ont mêmes fonctions englobantes jusqu'au niveau nx - 1.

Il faut donc remonter les niveaux d'imbrication à partir de l'enregistrement de P en suivant np - nx + 1 liens.

Cela donne la référence du lien d'accès de X.

Accès aux noms non locaux : (P de profondeur *np* référence T de profondeur *nt* ≤ *np*) : on suit *np* − *nt* liens d'accès à partir de l'enregistrement d'activation de P (actif) pour obtenir l'enregistrement de la procédure où T est locale puis on sait où se situe l'emplacement associé relativement au lien d'accès.





Cas du passage d'une fonction en paramètre :

```
program Param (input, output);

procedure b (function h (n : integer) : integer);
  begin writeln (h (2)) end { b } ;

procedure c ;
  var m : integer ;

  function f (n : integer) : integer ;
    begin f := m + n end { f } ;

begin m := 0 ; b (f) end { c } ;

begin c end.
```

Lorsque c appelle b, il fournit le paramètre f ; mais quand b devient active, f est normalement hors de portée de b. Donc c fournit le lien d'accès de f, qui est dans sa portée.

Noms non locaux avec imbrication de fonctions : portée dynamique

```
program Dynamique (input, output)
var r : real ;

procedure Montrer :
begin write r end ;

procedure A :
var r : real ;
begin r:=0.125 ; Montrer end ;

begin
r:= 0.25 ;
Montrer ; A ;
end.
```

Plutôt que d'utiliser les liens d'accès, on utilise les liens de contrôle.


Seconde implantation : similaire à l'utilisation des accesseurs


Affichage: 0.25 0.125

Rappel : sans portée dynamique, l'exécution du même programme affiche 0.25 0.25

Table des symboles et imbrication de fonctions : une technique

- Une table des symboles par fonctions
- Les tables des symboles sont chaînées
- Le chaînage reflète l'imbrication des fonctions







C'est le plus courant (C, C++, Java, Pascal, ocaml, etc. C'est le seul possible en C et en Java)
Chaque argument est évalué avant l'appel de fonction
Sa valeur est mise dans l'enregistrement d'activation de l'appelé
Toute modification par l'appelé est réalisée dans sur sa copie
Il faut utiliser des noms non locaux ou des pointeurs pour que la fonction appelante
puisse changer des valeurs à l'extérieur de son corps





argc argv 2 b 3

Évaluation des arguments
le premier vaut 3
le second pointe sur
l'espace de a
dans l'enregistrement
d'activation de main









C'est le plus courant (C, C++, Java, Pascal, ocaml, etc. C'est le seul possible en C et en Java)
Chaque argument est évalué avant l'appel de fonction
Sa valeur est mise dans l'enregistrement d'activation de l'appelé
Toute modification par l'appelé est réalisée dans sur sa copie
Il faut utiliser des noms non locaux ou des pointeurs pour que la fonction appelante
puisse changer des valeurs à l'extérieur de son corps

main

argc


argv

a 3

b 3


```
Courant également. Possible en C++, Pascal, ...
Si l'argument a une l-value, c'est la l-value qui est passée en argument Si l'argument n'en a pas un emplacement mémoire est créé l'argument est stocké dans cet emplacement c'est la l-value correspondante qui est passée en argument
```

```
void f(int a, int &b) {
    ++a;
    b += 2;
}
int main(int argc, char *argv[]) {
    int a = 2;
    f(a, a);
    return 0;
}
```




```
Courant également. Possible en C++, Pascal, ...
Si l'argument a une l-value, c'est la l-value qui est passée en argument
Si l'argument n'en a pas
un emplacement mémoire est créé
l'argument est stocké dans cet emplacement
c'est la l-value correspondante qui est passée en argument
```

```
void f(int a, int &b) {
    ++a;
    b += 2;
}
int main(int argc, char *argv[]) {
    int a = 2;
    f(a, a);
    return 0;
}
```




```
Courant également. Possible en C++, Pascal, ...
Si l'argument a une l-value, c'est la l-value qui est passée en argument Si l'argument n'en a pas un emplacement mémoire est créé l'argument est stocké dans cet emplacement c'est la l-value correspondante qui est passée en argument
```

```
void f(int a, int &b) {
    ++a;
    b += 2;
}
int main(int argc, char *argv[]) {
    int a = 2;
    f(a, a);
    return 0;
}
```




```
Courant également. Possible en C++, Pascal, ...
Si l'argument a une l-value, c'est la l-value qui est passée en argument Si l'argument n'en a pas un emplacement mémoire est créé l'argument est stocké dans cet emplacement c'est la l-value correspondante qui est passée en argument
```

```
void f(int a, int &b) {
    ++a;
    b += 2;
}
int main(int argc, char *argv[]) {
    int a = 2;
    f(a, a);
    return 0;
}
```




```
Courant également. Possible en C++, Pascal, ...
Si l'argument a une l-value, c'est la l-value qui est passée en argument Si l'argument n'en a pas un emplacement mémoire est créé l'argument est stocké dans cet emplacement c'est la l-value correspondante qui est passée en argument
```

```
void f(int a, int &b) {
    ++a;
    b += 2;
}
int main(int argc, char *argv[]) {
    int a = 2;
    f(a, a);
    return 0;
}
```



```
Courant également. Possible en C++, Pascal, ...
Si l'argument a une l-value, c'est la l-value qui est passée en argument Si l'argument n'en a pas un emplacement mémoire est créé l'argument est stocké dans cet emplacement c'est la l-value correspondante qui est passée en argument
```

```
void f(int a, int &b) {
    ++a;
    b += 2;
}
int main(int argc, char *argv[]) {
    int a = 2;
    f(a, a);
    return 0;
}
```



Utilisé en programmation concurrente pour éviter des problèmes liés au passage par référence.

Les arguments sont évalués

Leurs valeurs sont copiés dans l'enregistrement d'activation de l'appelé (passage par valeur) Au retour de l'appelé, ces valeurs de l'enregistrement d'activation de l'appelé sont recopiées dans l'enregistrement d'activation de l'appelant

```
fonction f(entier a, entier b) {
    a:=a+1;
    b:=b+2;
}

principal {
    entier a=1;
    f(a, a);
}
```

principal

a

Utilisé en programmation concurrente pour éviter des problèmes liés au passage par référence.

Les arguments sont évalués

Leurs valeurs sont copiés dans l'enregistrement d'activation de l'appelé (passage par valeur) Au retour de l'appelé, ces valeurs de l'enregistrement d'activation de l'appelé sont recopiées dans l'enregistrement d'activation de l'appelant

```
fonction f(entier a, entier b) {
    a:=a+1;
    b:=b+2;
}

principal {
    entier a=1;
    f(a, a);
}
```

principal


a 1

Utilisé en programmation concurrente pour éviter des problèmes liés au passage par référence.

Les arguments sont évalués

```
fonction f(entier a, entier b) {
    a:=a+1;
    b:=b+2;
}

principal {
    entier a=1;
    f(a, a);
}
```




Utilisé en programmation concurrente pour éviter des problèmes liés au passage par référence.

Les arguments sont évalués

```
fonction f(entier a, entier b) {
    a:=a+1;
    b:=b+2;
}

principal {
    entier a=1;
    f(a, a);
}
```




Utilisé en programmation concurrente pour éviter des problèmes liés au passage par référence.

Les arguments sont évalués

```
fonction f(entier a, entier b) {
    a:=a+1;
    b:=b+2;
}

principal {
    entier a=1;
    f(a, a);
}
```




Utilisé en programmation concurrente pour éviter des problèmes liés au passage par référence.

Les arguments sont évalués

```
fonction f(entier a, entier b) {
    a:=a+1;
    b:=b+2;
}

principal {
    entier a=1;
    f(a, a);
}
```




Utilisé en programmation concurrente pour éviter des problèmes liés au passage par référence.

Les arguments sont évalués

Leurs valeurs sont copiés dans l'enregistrement d'activation de l'appelé (passage par valeur) Au retour de l'appelé, ces valeurs de l'enregistrement d'activation de l'appelé sont recopiées dans l'enregistrement d'activation de l'appelant

```
fonction f(entier a, entier b) {
    a:=a+1;
    b:=b+2;
}

principal {
    entier a=1;
    f(a, a);
}
```



Au retour de *f* les arguments sont recopiés dans leur endroit de provenance de l'enregistrement d'activation


Utilisé en programmation concurrente pour éviter des problèmes liés au passage par référence.

Les arguments sont évalués

Leurs valeurs sont copiés dans l'enregistrement d'activation de l'appelé (passage par valeur) Au retour de l'appelé, ces valeurs de l'enregistrement d'activation de l'appelé sont recopiées dans l'enregistrement d'activation de l'appelant

```
fonction f(entier a, entier b) {
    a:=a+1;
    b:=b+2;
}

principal {
    entier a=1;
    f(a, a);
}
```



Au retour de *f* les arguments sont recopiés dans leur endroit de provenance de l'enregistrement d'activation


Utilisé en programmation concurrente pour éviter des problèmes liés au passage par référence.

Les arguments sont évalués

Leurs valeurs sont copiés dans l'enregistrement d'activation de l'appelé (passage par valeur) Au retour de l'appelé, ces valeurs de l'enregistrement d'activation de l'appelé sont recopiées dans l'enregistrement d'activation de l'appelant

```
fonction f(entier a, entier b) {
    a:=a+1;
    b:=b+2;
}

principal {
    entier a=1;
    f(a, a);
}
```




Au retour de *f* les arguments sont recopiés dans leur endroit de provenance de l'enregistrement d'activation

Utilisé en programmation concurrente pour éviter des problèmes liés au passage par référence.

Les arguments sont évalués

Leurs valeurs sont copiés dans l'enregistrement d'activation de l'appelé (passage par valeur) Au retour de l'appelé, ces valeurs de l'enregistrement d'activation de l'appelé sont recopiées dans l'enregistrement d'activation de l'appelant

```
fonction f(entier a, entier b) {
    a:=a+1;
    b:=b+2;
principal {
    entier a=1;
    f(a, a);
```



Au retour de f les arguments sont recopiés

dans leur endroit de provenance de l'enregistrement d'activation

Attention : l'ordre dépends de l'implantation !

Passage des arguments : par nom

Les arguments ne sont pas évalués avant d'être passés à l'appelant. Ils sont remplacés dans le corps de la fonction appelée. Équivalent des macros du C.


```
#define min(X, Y) ((X) < (Y) ? (X) : (Y))

x = min(a, b); ==> x = ((a) < (b) ? (a) : (b));

y = min(1, 2); ==> y = ((1) < (2) ? (1) : (2));

z = min(a + 28, *p); ==> z = ((a + 28) < (*p) ? (a + 28) : (*p));
```

Code intermédiaire



Sépare les parties frontales et finales de la compilation Facilite la portabilité, l'optimisation Les programmes sont représentés par des arbres abstraits ou des graphes acycliques

Génération de code proche de l'assembleur, machine indépendant

- code à trois adresses


Le code produit doit

- préserver la sémantique du code d'entrée
- être efficace
 - temps d'exécution
 - compacité du code produit
 - consommation d'énergie

Le temps de production doit rester raisonnable

- les problèmes d'optimalité du code sont difficiles (temps de calculs longs)
- des heuristiques efficaces peuvent être utilisées en remplacement

Code intermédiaire



Sépare les parties frontales et finales de la compilation Facilite la portabilité, l'optimisation Les programmes sont représentés par des arbres abstraits ou des graphes acycliques

Code à trois adresses :


- adapté aux structures de contrôles imbriquées et aux expressions algébriques
- proche d'un langage d'assemblage


Instructions:

$$x := y op z$$
 $x := op z$

- x, y et z sont des constantes ou des noms
- op un opérateur quelconque.

Code à 3 adresses





Optimisé Graphe acyclique

Code à 3 adresses

- Affectation
- Affectation
- Copie
- Branchement inconditionnel
- Branchement conditionnel
- Affectation avec indices
- Pointeurs et adresses
- Appels de procédure

$$x := y op z$$

$$x := op y$$

$$x := y$$

goto L

$$x := y [i] x [i] := y$$

$$x := & y$$

$$x := & y$$
 $x := * y$

* x := y

Génération de code à 3 adresses Expressions

Dirigée par la syntaxe

| : concaténation NouveauTemp : création nouveau temporaire

Prod: production d'une instruction

```
Rèale
                              Action
I \rightarrow id := E
                              I.code := E.code || Prod (id.place ':=' E.place)
E \rightarrow E + E
                              E.place := NouveauTemp();
                              E.code := E_1.code \mid\mid E_2.code\mid\mid
                                Prod(E. place':='E_1. place'+'E_2. place)
E \rightarrow E^*E
                              E.place := NouveauTemp();
                              E.code := E_1 .code || E_2 .code ||
                                Prod(E. place':='E_1. place'*'E_2. place)
F \rightarrow -F
                              E.place := NouveauTemp();
                              E.code := E_1.code \parallel
                                Prod (E. place ':=' 'MoinsUnaire' E, . place )
E \rightarrow (E)
                              E.place := E_1 .place ; E.code := E_1 .code
F \rightarrow id
                              E.place := id.place ; E.code := '
```

Génération de code à 3 adresses Instructions

```
Règle Action

I \rightarrow \text{ while } E \text{ do } I \qquad I.start := NouveauLabel(); \\ I.end := NouveauLabel(); \\ I.code := Prod (I. start `:`) \\ || E.code \\ || Prod ( `if`E. place `=` `0` `goto` I.end ) \\ || I_1 . code \\ || Prod ( `goto` I.start ) \\ || Prod ( I.end `:`)
```

Convention pour les booléens: 0 = faux non 0 = vrai comme en C

Génération de code à 3 adresses Déclarations

lci, la technique d'une table des symboles par fonction avec chaînage des tables est utilisée La création des tables des symboles est réalisée pendant l'analyse syntaxique une pile PtrTbl sert à gérer les tables des symboles au fur et à mesure de l'analyse les variables locales sont stockées dans un espace mémoire propre à chaque fonction une pile depl contient les tailles de ces espaces pour stocker les variables locales aux fonction la production *D* → **proc** id; *N D*; *I* représente la déclaration d'une procédure interne, ses déclarations locales et ses instructions (version simplifiée)

```
P \rightarrow M \, D \qquad \{ \, \textit{AjouterTaille} \, ( \, \textit{Sommet} \, ( \, \textit{PtrTbI} \, ) \, , \, \textit{Sommet} \, ( \, \textit{depI} \, ) \, ) \, ; \\ Depiler \, ( \, \textit{PtrTbI} \, ) \, ; \, \textit{Depiler} \, ( \, \textit{depI} \, ) \, \} \\ M \rightarrow \varepsilon \qquad \{ \, t := \, \textit{CreerTable} \, ( \, \textbf{niI} \, ) \, ; \, \textit{Empiler} \, ( \, t , \, \textit{PtrTbI} \, ) \, ; \, \textit{Empiler} \, ( \, 0 , \, \textit{depI} \, ) \, \} \\ D \rightarrow D \, ; \, D \\ D \rightarrow \text{proc} \quad \text{id} \, ; \, N \, D \, ; \, I \\ \{ \, t := \, \textit{Sommet} \, ( \, \textit{PtrTbI} \, ) \, ; \, \textit{AjouterTaille} \, ( \, t , \, \textit{Sommet} \, ( \, \textit{depI} \, ) \, ) \, ; \\ D \rightarrow \text{proc} \quad \text{id} \, ; \, N \, D \, ; \, I \\ EntrerProcedure \, ( \, \textit{Sommet} \, ( \, \textit{PtrTbI} \, ) \, ; \, \text{ad.nom} \, , \, t \, ) \, \} \\ D \rightarrow \text{id} \quad : \, T \, \{ \, \textit{Entrer} \, ( \, \textit{Sommet} \, ( \, \textit{PtrTbI} \, ) \, ; \, \text{id.nom} \, , \, T.type, \, Sommet \, ( \, \textit{depI} \, ) \, ) \, ; \\ Sommet \, ( \, \textit{depI} \, ) \, := \, Sommet \, ( \, \textit{depI} \, ) \, + \, T.taille \, \} \\ N \rightarrow \varepsilon \qquad \{ t := \, \textit{CreerTable} \, ( \, \textit{Sommet} \, ( \, \textit{PtrTbI} \, ) \, ; \, Empiler \, ( \, t , \, \textit{PtrTbI} \, ) \, ; \, Empiler \, ( \, t , \, \textit{PtrTbI} \, ) \, \}
```

Génération de code à 3 adresses Déclarations

```
P \rightarrow M \, D \qquad \{ \, \textit{AjouterTaille} \, ( \, \textit{Sommet} \, ( \, \textit{PtrTbI} \, ) \, ; \, \textit{Sommet} \, ( \, \textit{depI} \, ) \, ) \, ; \\ Depiler \, ( \, \textit{PtrTbI} \, ) \, ; \, \textit{Depiler} \, ( \, \textit{depI} \, ) \, \} \\ M \rightarrow \epsilon \qquad \{ \, t := \, \textit{CreerTable} \, ( \, \textbf{niI} \, ) \, ; \, \textit{Empiler} \, ( \, t , \, \textit{PtrTbI} \, ) \, ; \, \textit{Empiler} \, ( \, 0 , \, \textit{depI} \, ) \, \} \\ D \rightarrow D \, ; \, D \\ D \rightarrow \text{proc} \quad \text{id} \, ; \, N \, D \, ; \, I \\ \{ \, t := \, \textit{Sommet} \, ( \, \textit{PtrTbI} \, ) \, ; \, \textit{AjouterTaille} \, ( \, t , \, \textit{Sommet} \, ( \, \textit{depI} \, ) \, ) \, ; \\ D \rightarrow \text{proc} \quad \text{id} \, ; \, N \, D \, ; \, I \\ EntrerProcedure \, ( \, \textit{Sommet} \, ( \, \textit{PtrTbI} \, ) \, ; \, \text{id} \, .nom \, , \, t \, ) \, \} \\ D \rightarrow \text{id} \quad : \, T \quad \{ \, \textit{Entrer} \, ( \, \textit{Sommet} \, ( \, \textit{PtrTbI} \, ) \, ; \, \text{id} \, .nom \, , \, T.type, \, Sommet \, ( \, \textit{depI} \, ) \, ) \, ; \\ Sommet \, ( \, \textit{depI} \, ) \, := \, Sommet \, ( \, \textit{depI} \, ) \, + \, T.taille \, \} \\ N \rightarrow \epsilon \qquad \{ t := \, \textit{CreerTable} \, ( \, \textit{Sommet} \, ( \, \textit{PtrTbI} \, ) \, ; \, Empiler \, ( \, t , \, \textit{PtrTbI} \, ) \, ; \, Empiler \, ( \, t , \, \textit{PtrTbI} \, ) \, ; \, Empiler \, ( \, t , \, \textit{PtrTbI} \, ) \, \}
```

CreerTable(x) crée une nouvelle table initialisée par un pointeur vers x.

Entrer(table, nom, type, place) et EntrerProcedure(table, nom, table_nom) gèrent les insertions dans la table des symboles.

AjouterTaille (table, taille) stocke dans la table sa taille totale.

Génération de code à 3 adresses Affectations

Version simplifiée :

Il faudrait aussi:

- vérifier le typage des membres gauche et droit de l'affectation attribut synthétisé « type »
- pouvoir remplacer id par une *l-value*

```
Exemple du C (ou de Java) int t[N_1]...[N_k]: t est un tableau de N_1 tableaux de ... de N_{\kappa} int
```

On pose

- $w_k = \text{taille d'un int}$
- w_{k-1} = taille d'un tableau de N_k int = $N_k^* w_k$
- w_{k-2} = taille d'un tableau de N_{k-1} tableaux de N_k int = N_{k-1} * w_{k-1}
- . . .
- w_1 = taille d'un tableau de N_2 tableaux de ... de N_k int = $N_2^*w_2$
- base = adresse du premier élément du tableau


Les w_i peuvent être calculés par le compilateur quand l'analyse de la déclaration du tableau est terminée.

Hypothèse : les éléments du tableau sont rangés en mémoire

- de manière contiguë
- par ordre croissant des indices des éléments

Adresse de
$$t[j_1]...[j_k] = base + j_1^* w_1^* + ... + j_k^* w_k$$

int t[2][3]: t est un tableau de 2 tableaux de 3 entiers



L'analyse de la gauche vers la droite du type du tableau fourni des sous-tableaux dont les dimensions vont en décroissant


Dans la grammaire, le non terminal L représente les expressions extraites des tableaux

Attributs synthétisés :

- L.array : pointeur sur la table des symboles pour ce tableau
- L.type : type du sous-tableau engendré par L
- L.offset : décalage par rapport à l'adresse de base du tableau

```
S → id := E { Comme précédemment }
S \rightarrow L := E \{ S.code := E_1.code || Prod(L.array.base '['L.offset '] := 'E_1.place) \}
E → E+E { Comme précédemment }
E → id { Comme précédemment }
E \rightarrow L \{ E.place := NouveauTemp();
                                   E.code := L<sub>1</sub> .code || Prod( E.place ':=' L.array.base '[ L.offset ']) }
L \rightarrow id [E] \{ L.array := Rechercher (id.nom) \}
                                                if L.array <> nil then
                                                                    L.offset := NouveauTemp();
                                                                     L.type:= L.array.elementType
                                                                     L.code:= E.code | Prod(L.offset ':=' E.place*width(L.array.elementType))
                                                    else erreur }
L \rightarrow L[E] \{ L.array:= L_1.array ; L.type:= L_1.type.elementType ; t:= NouveauTemp() ;
                                         L.offset:= NouveauTemp();
                                         L.code:= E.code | Prod( telescope '*'width(L.type)) | Prod( L.offset ':=' L,.offset '+' t) }
```

Exemple: code produit par l'analyse de t[a+b][c]:=u[a][b+c] avec int t[10][20] et int u[5][15]



```
Si la syntaxe des tableaux est T [n_1, ..., n_k]
```

la grammaire naturelle est $G \rightarrow \mathbf{id}$ [Eliste] | \mathbf{id} Eliste \rightarrow Eliste , $E \mid E$

Dans ce cas les dimensions du tableau doivent être passées comme attributs hérités de *Eliste*. On pourra plutôt utiliser la grammaire suivante, moins naturelle mais qui ne nécessite pas d'attributs hérités:

```
G \rightarrow Eliste] | id
Eliste \rightarrow Eliste, E | id [ E
```

Optimisation de la création des temporaires

Idée sur la réduction de $E \rightarrow E + E$ pour éviter de créer trop de temporaires

On utilise un compteur de temporaires c

- Si les deux *E* en partie droite ont comme attribut *E.place* des noms explicites, on utilise un nouveau temporaire t_c comme *E.place* de la réduction.
- Si l'un des deux a comme attribut *E.place* un nom et l'autre un temporaire t_i , celui-ci peut être réutilisé comme *E.place* de la réduction (c est inchangé).
- Si les deux ont comme attributs des temporaires, ce sont nécessairement t_i et t_{i+1} . On peut donc réutiliser t_i comme *E.place* de la réduction. Le futur nouveau temporaire sera donc t_{i+1} (c=i+1).

On ne peut évidemment réutiliser des temporaires que s'ils ont le même type, ce que sait le compilateur.

Génération de code à 3 adresses Fonctions


On ajoute au jeu d'instruction du code à 3 adresses :

- param t : ajouter de la valeur de la variable t à une liste de paramètres
- t = call *nomFonction*, nombreParamètres : appel de la fonction *nomFonction* à *nombreParamètres* paramètres, stockage du résultat dans *t*

Les codes à 3 adresses de chaque fonction sont générés séparément, et associés à la déclaration de chaque fonction dans la table des symboles

```
• L'instruction (a est un tableau d'entiers) n = f(a[i]) est compilée en t_1 = i*width(int) t_2 = a[t_1] param t_2 t_3 = call \ f, \ 1 n = t_3
```

Production de code cible



Exemple de code intermédiaire : code à 3 adresses

Hypothèses sur le code intermédiaire :

- les valeurs qui y apparaissent sont toutes manipulables par la machine cible
- les opérations de contrôle, conversions, etc. ont toutes eu lieu

Problématique:

- produire le code cible le plus efficace possible (temps d'exécution ? taille ? consommation d'énergie ?)
- très souvent, les problèmes d'optimisation qui apparaissent sont difficiles, voire NP-complets
- on utilise alors des heuristiques qui fonctionnent suffisamment bien
- plus la machine cible a un langage complet, plus il est facile de produire du code efficace

Production de code cible

Pour réaliser une traduction efficace il faut :

- placer chaque variable pertinemment
 - dans un registre de préférence (surtout pour les variables utilisées intensivement localement)
 - dans la mémoire sinon
- il faut donc une stratégie d'utilisation des registres
 - allocation des registres : choix de l'ensemble des variables qui vont résider dans les registres à un point donné du programme
 - assignation des registres: choix du registre dans lequel une variable va être stockée
 - l'assignation optimale est un problème NP-complet
- traduire les instructions à 3 adresses dans les meilleurs instructions de la machine cible
 - individuellement
 - il peut aussi être pertinent de regrouper les instructions à 3 adresses pour mieux les traduire
 - il peut aussi être pertinent de permuter des instructions pour avoir un code produit plus efficace
 - à nouveau, le choix de la meilleure permutation est un problème NP-complet
- placer les instructions et les données en mémoire (calcul effectif des adresses)
 - si le code cible est destinée à un programme d'assemblage, alors ce dernier peut le faire (les adresses restent alors des noms symboliques dans le programme traduit)

Découpage du flot d'instructions à 3 adresses : blocs de base

Un bloc de base est formé de la plus grande suite d'instructions possible

- sans possibilité d'arrêt
- sans branchement autre qu'à la fin de la séquence

Instruction de tête : première instruction d'un bloc de base

Algorithme : dans la suite des instructions, on repère

- les instructions de branchement ou d'arrêt
- leurs destinations

La première instruction est une instruction de tête Toute instruction destination d'un branchement est une instruction de tête Toute instruction suivant une instruction de branchement est une instruction de tête

Les instructions de tête obtenues délimitent les blocs de base

L'organisation du code en blocs de base peut être représenté par un graphe

- les nœuds sont les blocs de base
- les arcs la relation entre les blocs de base donnée par le flot de contrôle (sauts, suite)
- un nœud initial : le premier bloc de base
- des nœuds finaux : ceux terminant le flot d'exécution

Découpage du flot d'instructions à 3 adresses : blocs de base

Exemple:

```
\begin{array}{l} \text{prod:= 0 ;} \\ \text{i:=1 ;} \\ \text{do} \\ \text{prod:= prod+a[i]*b[i] ;} \\ \text{i:=i+1 ;} \\ \text{while (i \le 20) ;} \end{array}
```

```
1) prod := 0
2) i:=1
3) t_1 := 4 * i
4) t_2 := a[t_1]
5) t_3 := 4 * i
6) t_4 := b[t_3]
7) t_5 := t_2 * t_4
8) t_6 := prod + t_5
9) prod := t_6
10) t_7 := i + 1
11) i := t_7
12) si i \leq 20 aller à (3)
```

Noms actifs dans les blocs de base

Pour chaque bloc de base, une analyse en partant de la fin :

Pour chaque symbole, on détermine

- l'instruction de sa dernière utilisation
- s'il est actif ou non (actif=utilisé plus tard)


Au départ,

- toutes les variables non temporaires du bloc sont marquées actives à la sortie du bloc
- si la production de code a 3 adresses a été faite pour, aucune variable temporaire n'est active en fin de bloc
- sinon, on peut supposer que le producteur de code a 3 adresses a marqué les variables temporaires qui sont actives en fin de bloc

Pour l'instruction i) x = y op z

- associer à l'instruction i les informations de la table relatives à l'activation et à l'utilisation ultérieure de x, y et z
- dans la table des symboles
 - désactiver x
 - pas de prochaine utilisation de x
 - activer y et z : instruction de prochaine utilisation i

Pour les autres instructions, même principe



Noms actifs dans les blocs de base

Représentation graphique du résultat de l'application de l'algorithme

Exemple d'interprétation : après exécution de l'instruction 6, sont actives : t_2 , t_4 , i, prod, a , b

Exemple d'utilisation : après exécution de l'instruction 4, t₁ n'est plus nécessaire. Il est donc possible de réutiliser la variable t₁ plutôt que t₂ en membre gauche de l'affectation

4)
$$t_2 = a[t_1]$$

3) $t_1 := 4 * i$

5)
$$t_3 := 4 * i$$

6)
$$t_4 = b[t_3]$$

7)
$$t_5 := t_2 * t_4$$

8)
$$t_6 := prod + t_5$$

9) prod :=
$$t_6$$

10)
$$t_7 := i + 1$$

12) si i \leq 20 aller à (3)

i, prod,a et b sont actives au début du bloc

i, prod,a et b sont actives en fin de bloc

Noms actifs dans les blocs de base

4)
$$t_2 := a[t_1]$$

5)
$$t_3 := 4 * i$$

6)
$$t_4 = b[t_3]$$

7)
$$t_5 := t_2 * t_4$$

8)
$$t_6 = \text{prod} + t_5$$

9) prod :=
$$t_6$$

10)
$$t_7 := i + 1$$

En parcourant les instructions de haut en bas et en utilisant le calcul précédent, on peut réduire de beaucoup le nombre de variables

4)
$$t_1 := a[t_1]$$

5)
$$t_2 := 4 * i$$

6)
$$t_2 := b[t_2]$$

7)
$$t_1 := t_1 * t_2$$

8)
$$t_1 := prod + t_1$$

9) prod :=
$$t_1$$

10)
$$t_1 := i + 1$$

12) si i \leq 20 aller à (3)

Un générateur de code simple

Il faut utiliser les registres de manière appropriée :

- peut être imposé dans certaines situations (instructions) par la machine cible
- le plus possible pour éviter les temporaires
- certains registres sont spécialisés (pointeurs de pile, d'instruction, etc)

Hypothèses sur les instructions de la machine cible :

- LÖAD registre, adresse
- STORE adresse, registre
- OP reg₁, reg₂, reg₃ pour chaque opération OP

Si ça n'est pas le cas, on remplace chacune de ces instructions par une combinaison des instructions de la machine cible

Structures de données :

- Pour chaque registre, la liste des variables qu'il contient (descripteur de registres)
- Pour chaque variable, la liste des emplacements mémoire et des registres où se trouve sa valeur (descripteur de données)
- Une fonction getRegs(instruction) qui sélectionne des registres à utiliser pour exécuter cette instruction
 - getRegs à accès aux descripteurs de registres et de données


Un générateur de code simple


Pour chaque instruction, on définit un schéma de traduction

- X=Y+Z
 - appeler getRegs(x=y+z): on obtient trois registres R_x, R_y, R_z
 - si y n'est pas déjà dans R_v,
 - I'y charger par un LOAD R_v,y
 - mettre à jour les descripteurs de données et de registres
 - idem pour z
 - générer ADD R_x,R_v,R_z
 - mettre à jour les déscripteurs de données et de registres
- X=V
 - appeler getRegs(x=y), qui ne doit retourner qu'un seul registre R_v
 - si y n'est pas dans R_y, charger y dans R_y par LOAD R_y,y
 - mettre à jour les descripteurs de données et de registre
 - x et y se trouvent dans R_v
- ...
- fin de bloc
 - si une variable est active à la fin d'un bloc, il faut la placer dans l'espace mémoire qui lui est dédié


Un générateur de code simple : getRegs(x=y+z)


- si y est déjà dans un registre, le sélectionner pour le stockage de y
- sinon, s'il y a un registre vide, le sélectionner pour le stockage de y
- sinon on sélectionne un registre R contenant une variable v
 - si v est stocké quelque part ailleurs que dans R, alors on sélectionne R pour y
 - sinon si v est x et si x n'est ni y ni z, alors on sélectionne R pour y
 - sinon si v n'est pas réutilisée plus tard, on sélectionne R pour y
 - dans tous les autres cas on copie v dans son espace mémoire
- pareil pour z
- pour x, les règles sont quasiment identiques. Les différences sont :
 - comme on calcule une nouvelle valeur pour x, un registre contenant uniquement x est toujours un bon choix, même quand y ou z est x
 - si y n'est plus utilisé après l'instruction, et que R ne contient que y, alors $R_y = R_y + R_z$ est un choix pertinent






a	b	С	d	t_1	t_2	t_3
а	b	С	d			






а	b	С	d	$t_{_1}$	t_2	t_3
a,R ₁	b	С	d	R ₂		


LOAD R₁,a LOAD R₂,b SUB R₂,R₁,R₂






а	b	С	d	$t_{_1}$	t_2	t_3
а	b	c,R ₃	d	R ₂	R ₁	

LOAD R₁,a LOAD R₂,b SUB R₂,R₁,R₂ LOAD R₃,c SUB R₁,R₁,R₃






а	b	С	d	$t_{_1}$	t_2	t_3
а	b	С	d	R ₂	R ₁	R_3

LOAD R₁,a LOAD R₂,b SUB R₂,R₁,R₂ LOAD R₃,c SUB R₁,R₁,R₃ ADD R₃,R₂,R₁


$$t_1 = a - b$$


 $t_2 = a - c$
 $t_3 = t_1 + t_2$
 $a = d$
 $d = t_3 + t_2$



a	b	С	d	$t_{_1}$	t_2	t_3
R ₂	b	С	d,R ₂		R ₁	R ₃

LOAD R₁,a LOAD R₂,b SUB R₂,R₁,R₂ LOAD R₃,c SUB R₁,R₁,R₃ ADD R₃,R₂,R₁ LD R₂,d





a	b	С	d	t ₁	t_2	t_3
R_2	b	С	R ₁			R_3

LOAD R₁,a LOAD R₂,b SUB R₂,R₁,R₂ LOAD R₃,c SUB R₁,R₁,R₃ ADD R₃,R₂,R₁ LD R₂,d ADD R₁,R₃,R₁

 $t_1 = a - b$ $t_2 = a - c$ $t_3 = t_1 + t_2$ a = d $d = t_3 + t_2$ $\begin{array}{c|c} R_1 & R_2 R_3 \\ \hline d & a & t_3 \end{array}$

a	b	С	d	$t_{_1}$	t_2	t_3
R_2 ,a	b	С	R_1,d			R_3

SORTIE DE BLOC

LOAD R₁,a LOAD R₂,b SUB R₂,R₁,R₂ LOAD R₃,c SUB R₁,R₁,R₃ ADD R₃,R₂,R₁ LD R₂,d ADD R₁,R₃,R₁ STORE R₂,a STORE R₁,d

La suite?

Les optimisations présentées ici sont élémentaires.

Beaucoup d'optimisations sont encore possibles :

- optimisations locales du code des blocs de base : factoriser les expressions communes, etc
- optimisations globales du code

• ...

Mais le cours s'arrête ici!



Bibliothèque de symboles

Uγ•ε∈ N≠ØU⊆